

Statistiques et science des données (LEPL1109)

Réalisé par
Quentin Aubecq
avec l'aide de

—
relu par

—
2026

SYNTEX

Cette synthèse est une **synthèse collaborative**, écrite en $\text{\LaTeX}$.
Elle est améliorée régulièrement, grâce à la participation de quelques étudiants.

La version que vous avez sous les yeux n'est sans doute pas la plus récente !

Alors...

...si vous désirez rester au courant des améliorations et corrections...

...si vous trouvez une erreur ou une imprécision...

...si vous souhaitez apporter votre aide à la réalisation...

...ou si vous voulez accéder à des synthèses d'autres cours...

...**rejoignez-nous** sur le serveur SYNTEX !



<https://discord.gg/BdFgQbCTag>

Remarque

Ce document est un support complémentaire au cours.
Nous déclinons toute responsabilité pour les éventuelles erreurs, omissions ou interprétations susceptibles de vous induire en erreur.
Les images, liens et autres contenus appartiennent exclusivement à leurs détenteurs respectifs.

Table des matières

1	Rappels	4
1.1	Variable aléatoire	4
1.2	Distribution de probabilités	4
1.3	Densité de probabilités	4
1.4	Espérance	5
1.5	Variance	5
1.6	Loi des grands nombres (LLN)	5
1.7	Quantiles	6
1.8	Fonction d'une variable aléatoire	6
2	Statistiques descriptives et outil de visualisation	7
2.1	Moyenne, Médiane et Quantiles	7
2.2	Range, IQR, Outliers	7
2.3	Analyse graphique	7
3	Indépendance et indépendance linéaire	9
3.1	Indépendance	9
3.2	Covariance	9
3.3	Corrélation	10
4	Variable aléatoire normale et théorème central limite	11
4.1	Standardisation	11
4.2	Théorème Central Limite	11
5	Autres variables aléatoires fondamentales	12
5.1	Distribution Chi-square (χ^2)	12
5.2	Student's T	12
5.3	Fisher-Snedecor	12
6	Variable aléatoires multivariées	13
6.1	Distribution marginale	13
6.2	Distribution conditionnelle	14
6.3	Espérances	14
6.4	Espérance conditionnelle	15
6.5	Covariance	15
6.6	Indépendance	16
6.7	Distribution normale multivariée	16
7	Estimation	18
7.1	Méthode des moments	18
7.2	Maximum de vraisemblance	19

8	Simulations et Bootstrapping	19
8.1	Variable aléatoire continue	19
8.2	Bootstrapping	20
9	Moyenne et déviation standard empirique	21
9.1	Propriétés de $\bar{X}$ et S^2 (moyenne et variance empirique)	21
9.2	Propriétés de $\bar{X}$ et S^2 à 2 populations normales	22

1 Rappels

1.1 Variable aléatoire

Une **variable aléatoire** est une fonction mesurable d'un espace Ω à un ensemble de nombres réels :

$$X : \Omega \rightarrow \mathbb{R}$$

On note $X(\omega) = x$

1.2 Distribution de probabilités

La **pmf** (probability mass function) $p(x)$ d'une variable aléatoire discrète, est une fonction qui associe une probabilité $P(X = x)$ à chaque valeur x de X

$$p(x) = P(X = x)$$

Si le domaine de X est $R = \{x_1, x_2, \dots\}$ alors $p(x) > 0 \forall x \in R$ et $p(x) = 0 \forall x \notin R$

$$\sum_i p(x_i) = 1$$

1.3 Densité de probabilités

La **pdf** (probability density function) $f(x) \geq 0$ d'une variable aléatoire continue X est une fonction tel que $\forall I \subset \mathbb{R}$

$$P(X \in I) = \int_I f(x) dx$$

La **cdf** (cumulative distribution function) $F(x)$ indique la probabilité que $X \leq x$

$$F(x) = P(X \leq x)$$

$$F(x) = \sum_{i: x_i \leq x} p(x_i)$$

$$F(x) = \int_{-\infty}^x f(u) du$$

$$f(x) = \frac{d}{dx} F(x)$$

1.4 Espérance

L'espérance d'une variable aléatoire X est notée $\mathbb{E}(X) = \mu_X$

$$\mu_X = \sum_{x \in \text{dom}(X)} xp(x)$$
$$\mu_X = \int_{-\infty}^{\infty} xf(x) dx$$

Propriétés :

- $\mathbb{E}(X + Y) = \mathbb{E}(X) + \mathbb{E}(Y)$
- $\mathbb{E}(aX + b) = a\mathbb{E}(X) + b$
- $\mathbb{E}(h(X)) = \sum_{x \in \text{dom}(X)} h(x)p(x)$
- $\mathbb{E}(h(X)) = \int_{-\infty}^{\infty} h(x)f(x) dx$

1.5 Variance

La variance d'une variable aléatoire X est

$$\text{Var}(X) = \mathbb{V}(X) = \sigma_X^2$$
$$\sigma_X^2 = \mathbb{E}((X - \mu_X)^2)$$

Avec σ_X la déviation standard

Propriétés :

- $\mathbb{V}(X) = \mathbb{E}(X^2) - (\mathbb{E}(X))^2$
- $\mathbb{V}(a) = 0$
- $\mathbb{V}(a + bX) = b^2\mathbb{V}(X)$
- $\mathbb{V}(X + Y) \neq \mathbb{V}(X) + \mathbb{V}(Y)$ Sauf si X et Y indépendants

Si on observe n événements $(x_k)_{k=1, \dots, n}$, la variance empirique est estimée avec

$$\sigma_X^2 \approx \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1} = s^2$$

1.6 Loi des grands nombres (LLN)

Soit $X_{i=1, \dots, n}$ une séquence d'événements aléatoires indépendants avec la même espérance $\mu_X = \mathbb{E}(X_i)$ et de variance σ_X^2 . Lorsque $n \rightarrow \infty$, la moyenne $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ converge vers μ_X

$$\forall \varepsilon > 0 \quad \lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu_X| \geq \varepsilon) = 0$$

On note $\bar{X}_n \xrightarrow{p} \mu_X$

1.7 Quantiles

Soit p une probabilité et X une variable aléatoire. Le nombre q_p satisfaisant la relation

$$P(X \leq q_p) = p$$

est le quantile d'ordre p pour X . Si X est continu et si son cdf $F(x)$ est inversible, alors $q_p = F^{-1}(p)$

1.8 Fonction d'une variable aléatoire

Soit X une variable aléatoire continue de densité (pdf) $f_X(x)$. La densité de $Y = a + bX$ est donnée par

$$f_Y(y) = \frac{1}{|b|} f_X\left(\frac{y-a}{b}\right)$$

2 Statistiques descriptives et outil de visualisation

- **Population** : Collection de tout les résultats possible qui nous intéressent
- **Échantillon** : Un subset de population
- **Statistiques** descriptives : Branche des statistiques qui s'occupe de l'organisation et de l'affichage des données

2.1 Moyenne, Médiane et Quantiles

- **Moyenne** :

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

- **Médiane** : La valeur $q_{0.5}$ telle que la moitié des résultats sont en dessous, et l'autre moitié au dessus
- **Quantile** : On trie les résultats par ordre croissant $x_{(1)} \leq \dots \leq x_{(n)}$, on a

$$q_p = x_{(1+(n-1)p)}$$


2.2 Range, IQR, Outliers

- **Range** : $x_{max} - x_{min}$
- **Inter-Quartile Range (IQR)** : La différence entre des quartiles symétriques, par exemple $IQR = q_{0.75} - q_{0.25}$
- **Outliers** : Observations qui sont trop loin du reste des données, qui pourraient être due à des erreurs


Une observation est considérée comme suspecte si elle est plus bas que $q_{0.25} - 1.5 \times IQR$ ou plus haut que $q_{0.75} + 1.5 \times IQR$

2.3 Analyse graphique

Boxplot :



Histogram :



3 Indépendance et indépendance linéaire

3.1 Indépendance

Deux variables aléatoires X et Y sont **indépendantes** ($X \perp\!\!\!\perp Y$) si $\forall A, B \in \mathbb{R}$:

$$P(X \in A, Y \in B) = P(X \in A)P(Y \in B)$$

Conséquences :


- $p(x, y) = p_X(x)p_Y(y)$ quand X et Y sont discrets
- $f(x, y) = f_X(x)f_Y(y)$ quand X et Y sont continus

3.2 Covariance

$$\begin{aligned}\sigma_{XY} &= \text{Cov}(X, Y) = \mathbb{E}[(X - \mu_X)(Y - \mu_Y)] \\ &= \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y) \\ &= \mu_{XY} - \mu_X\mu_Y\end{aligned}$$

Si on observe n événements $(x_k)_{k=1, \dots, n}$ et $(y_k)_{k=1, \dots, n}$, la covariance empirique est estimée avec

$$\sigma_{XY} \approx s_{XY} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$



Propriétés :

- $\mathbb{C}(X, Y) = \mathbb{C}(Y, X)$
- $\mathbb{C}(X, X) = \mathbb{V}(X)$ et $\mathbb{C}(a, X) = 0 \quad \forall a \in \mathbb{R}$
- Si $X \perp\!\!\!\perp Y$ alors $\mathbb{C}(X, Y) = 0$
- $\mathbb{C}(aX + bY, Z) = a\mathbb{C}(X, Z) + b\mathbb{C}(Y, Z)$

- $\boxed{\mathbb{V}(aX + bY) = a^2\mathbb{V}(X) + b^2\mathbb{V}(Y) + 2ab\mathbb{C}(X, Y)}$

(Attention si $\mathbb{C}(X, Y) = 0 \nRightarrow X \perp\!\!\!\perp Y$)

La covariance est une mesure de la dépendance linéaire entre deux variables aléatoires.

La taille d'une covariance dépend de l'échelle des variables : $\mathbb{C}(aX, Y) = a\mathbb{C}(X, Y)$

3.3 Corrélation

La **corrélation** entre X et Y est défini comme

$$\rho_{XY} = \frac{\mathbb{C}(X, Y)}{\sqrt{\mathbb{V}(X)\mathbb{V}(Y)}} = \frac{\sigma_{XY}}{\sigma_X \sigma_Y}$$

L'inégalité de Cauchy Schwarz donne

$$|\sigma_{XY}| \leq \sigma_X \sigma_Y \text{ avec égalité si et seulement si } Y = aX + b$$

On en déduit les propriétés suivantes :

- ρ_{XY} est invariant à l'échelle
- $-1 \leq \rho_{XY} \leq 1$
- Si $\rho_{XY} = 1$ alors $Y = a + bX$ avec $b \in \mathbb{R}^+$ (Y proportionnel à X)
- Si $\rho_{XY} = -1$ alors $Y = a + bX$ avec $b \in \mathbb{R}^-$ (Y inversement proportionnel à X)

La corrélation est une mesure de la dépendance linéaire entre deux variables aléatoires.

Elle n'a pas d'unité et est dans $[-1, 1]$

On peut estimer la corrélation de manière empirique :

$$\rho_{XY} \approx r_{XY} = \frac{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2}}$$

4 Variable aléatoire normale et théorème central limite

Une variable aléatoire suit une **distribution normale** si sa densité est donnée par

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right) \quad x \in \mathbb{R}$$

avec $\mu \in \mathbb{R}$ et $\sigma \in \mathbb{R}^+$ des paramètres. On note $X \sim \mathcal{N}(\mu, \sigma^2)$

$$\mathbb{E}(X) = \mu \quad , \quad \mathbb{V}(X) = \sigma^2$$

$$m_X(t) := \mathbb{E}(e^{tX}) = \exp\left(\mu t + \frac{1}{2}t^2\sigma^2\right)$$

$m_X(t)$ fonction génératrice des moments $\left.\frac{\partial^n m_X(t)}{\partial t^n}\right|_{t=0} = \mathbb{E}(X^n)$

4.1 Standardisation

- Si $X \sim \mathcal{N}(\mu, \sigma^2)$, alors $a + bX \sim \mathcal{N}(a + b\mu, b^2\sigma^2)$
- Si $X \sim \mathcal{N}(\mu_x, \sigma_x^2)$ et $Y \sim \mathcal{N}(\mu_y, \sigma_y^2)$ avec la covariance $\sigma_{x,y} = \mathbb{C}(X, Y)$, alors

$$aX + bY \sim \mathcal{N}(a\mu_x + b\mu_y, a^2\sigma_x^2 + b^2\sigma_y^2 + 2ab\sigma_{x,y})$$
- Si $X \sim \mathcal{N}(\mu, \sigma^2)$ alors $\frac{X-\mu}{\sigma} \sim Z = \mathcal{N}(0, 1)$ et

$$P(X \leq x) = P\left(Z \leq \frac{x-\mu}{\sigma}\right)$$

4.2 Théorème Central Limite

Soit $X_1, \dots, X_n$ une séquence de variables aléatoires indépendantes et identiquement distribuées, avec $\mathbb{E}(X_i) = \mu$ et $\mathbb{V}(X_i) = \sigma^2$ lorsque $n \rightarrow \infty$

$$Z_n = \sqrt{n} \frac{\bar{X}_n - \mu}{\sigma} \xrightarrow{d} Z \sim \mathcal{N}(0, 1)$$

$$P(Z_n \leq z) \xrightarrow{n \rightarrow \infty} P(Z \leq z) \forall z$$

5 Autres variables aléatoires fondamentales

5.1 Distribution Chi-square (χ^2)

Une variable aléatoire X définie sur $\mathbb{R}^+$ suit une distribution χ^2 de paramètre n si sa densité (pdf) est donnée par

$$\frac{1}{2^{n/2}\Gamma(n/2)} x^{n/2-1} e^{-x/2}$$

où $\Gamma(\alpha) = \int_0^\infty t^{\alpha-1} e^{-t} dt$ (Fonction Gamma).

On a $\mathbb{E}(X) = n$ et $\mathbb{V}(X) = 2n$

5.2 Student's T

Soit Z et Y deux variables aléatoires indépendantes $Z \sim \mathcal{N}(0, 1)$ et $Y \sim \chi_n^2$ alors

$$T_n = \frac{Z}{\sqrt{Y/n}}$$

est la variable aléatoire **Student's T** avec n degrés de liberté. Sa pdf est

$$f_{T_n}(t) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi}\Gamma\left(\frac{n}{2}\right)} \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}} \quad t \in \mathbb{R}$$

5.3 Fisher-Snedecor

Soit X et Y deux variables aléatoires χ^2 indépendantes avec n_1 et n_2 degrés de liberté, alors

$$F_{n_1, n_2} = \frac{X/n_1}{Y/n_2}$$

suis la distribution de **Fisher-Snedecor**, sa pdf est

$$f_{F_{n_1, n_2}}(z) = \frac{\Gamma\left(\frac{n_1+n_2}{2}\right) \left(\frac{n_1}{n_2}\right)^{\frac{n_1}{2}} z^{\left(\frac{n_1}{2}-1\right)}}{\Gamma\left(\frac{n_1}{2}\right) \Gamma\left(\frac{n_2}{2}\right) \left(1 + \frac{n_1}{n_2} z\right)^{\frac{n_1+n_2}{2}}} \quad z \in \mathbb{R}$$

6 Variable aléatoires multivariées

Un **vecteur aléatoire** $\mathbf{X} = (X_1, \dots, X_d)^\top$ est une application $\Omega \rightarrow \mathbb{R}^p$

Si $X_1, \dots, X_d$ sont continues, la fonction de distribution de probabilité multivariée (pdf) est

$$\begin{aligned} P(\mathbf{X} \leq \mathbf{x}) &= P(X_1 \leq x_1, \dots, X_d \leq x_d) \\ &= \int_{-\infty}^{x_d} \cdots \int_{-\infty}^{x_1} f(u_1, \dots, u_d) du_1 \dots du_d \end{aligned}$$

Si $X_1, \dots, X_d$ sont discrètes, la fonction de masse multivariée (pmf) est

$$\begin{aligned} P(\mathbf{X} = \mathbf{x}) &= P(X_1 = x_1, \dots, X_d = x_d) \\ &= p(x_1, \dots, x_d). \end{aligned}$$

6.1 Distribution marginale

Continu :

Soit $\mathbf{X} = (X_1, \dots, X_d)^\top$ un vecteur aléatoire continu. La pdf marginale de X_k pour $k = 1, \dots, d$ est

$$\begin{aligned} P(X_k \leq x) &= P(X_1 \leq \infty, \dots, X_k \leq x, \dots, X_d \leq \infty) \\ &= \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^x \cdots \int_{-\infty}^{+\infty} f(u_1, \dots, u_d) du_1 \dots du_d \end{aligned}$$

On a

$$\begin{aligned} f_{X_k}(x) &= \frac{\partial}{\partial x} P(X_k \leq x) \\ &= \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} f(u_1, \dots, u_{k-1}, x, u_{k+1}, \dots, u_d) du_1 \dots du_d. \end{aligned}$$

La distribution bivariable de X_i et X_j est

$$f_{X_i, X_j}(x_i, x_j) = \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} f(u_1, \dots, X_i, \dots, X_j, \dots, u_d) du_1 \dots du_d$$

Discret :

Soit $\mathbf{X} = (X_1, \dots, X_d)^\top$ un vecteur aléatoire discret. La pmf marginale de X_k pour $k = 1, \dots, d$ est

$$P(X_k = x_{k,j}) = \sum_{i_d=1}^{m_d} \cdots \sum_{i_{k+1}=1}^{m_{k+1}} \sum_{i_{k-1}=1}^{m_{k-1}} \cdots \sum_{i_1=1}^{m_1} p(x_{1,i_1}, \dots, x_{k,j}, \dots, x_{d,i_d})$$

$$= p_{\bullet, \dots, j, \dots, \bullet}$$

6.2 Distribution conditionnelle

Pour un petit Δ , la pdf peut être interprétée comme une probabilité

$$f(x_1, \dots, x_d) \Delta^d \approx P(x_1 \leq X_1 \leq x_1 + \Delta, \dots, x_d \leq X_d \leq x_d + \Delta)$$

Le théorème de Bayes dit que pour tout sous-ensemble A et B de $\mathbb{R}^p$, la probabilité que $X \in A$, en sachant que $X \in B$ est :

$$P(\mathbf{X} \in A | \mathbf{X} \in B) = \frac{P(\mathbf{X} \in A \cap B)}{P(\mathbf{X} \in B)}$$

Si $d = 2$, on définit la pdf conditionnelle de la variable aléatoire $X_1 | X_2$:

$$f_{X_1|X_2}(x_1|x_2) = \frac{f(x_1, x_2)}{f_{X_2}(x_2)}$$

$$f_{X_1|X_2}(x_1|x_2) \Delta \approx P(x_1 \leq X_1 \leq x_1 + \Delta | X_2 = x_2)$$

Si on partitionne $\mathbf{X}$ en $\mathbf{X}_A | \mathbf{X}_B$, la pdf conditionnelle est donnée par

$$f_{\mathbf{X}_A|\mathbf{X}_B}(\mathbf{x}_A|\mathbf{x}_B) = \frac{f((\mathbf{x}_A, \mathbf{x}_B))}{f_{\mathbf{X}_B}(\mathbf{x}_B)}$$

$$p_{\mathbf{X}_A|\mathbf{X}_B}(\mathbf{x}_A|\mathbf{x}_B) = \frac{p((\mathbf{x}_A, \mathbf{x}_B))}{p_{\mathbf{X}_B}(\mathbf{x}_B)}$$

6.3 Espérances

Continu :

$$\mathbb{E}(\mathbf{X}) = \begin{pmatrix} \mathbb{E}(X_1) \\ \vdots \\ \mathbb{E}(X_d) \end{pmatrix} = \begin{pmatrix} \int_{-\infty}^{+\infty} x f_1(x) dx \\ \vdots \\ \int_{-\infty}^{+\infty} x f_d(x) dx \end{pmatrix}$$

Discret :

$$\mathbb{E}(\mathbf{X}) = \begin{pmatrix} \mathbb{E}(X_1) \\ \vdots \\ \mathbb{E}(X_d) \end{pmatrix} = \begin{pmatrix} \sum_{j=1}^{m_1} x_{1,j} p_{j,\bullet,\dots,\bullet} \\ \vdots \\ \sum_{j=1}^{m_d} x_{d,j} p_{\bullet,\dots,\bullet,j} \end{pmatrix}$$

Propriétés :

- $\mathbb{E}(\alpha \mathbf{X} + \beta \mathbf{Y}) = \alpha \mathbb{E}(\mathbf{X}) + \beta \mathbb{E}(\mathbf{Y})$
- Si $\mathbf{X}$ et $\mathbf{Y}$ indépendants : $\mathbb{E}(\mathbf{X}^\top \mathbf{Y}) = \mathbb{E}(\mathbf{X})^\top \mathbb{E}(\mathbf{Y})$

6.4 Espérance conditionnelle

On divise $\mathbf{X}$ en deux vecteurs disjoints $\mathbf{X}_A$ et $\mathbf{X}_B$.

L'espérance conditionnelle de $\mathbf{X}_A$ si $\mathbf{X}_B = \mathbf{x}_B$ est

$$\begin{aligned} \mathbb{E}(\mathbf{X}_A | \mathbf{X}_B = \mathbf{x}_B) &= \int_{u \in A} \mathbf{u} f_{\mathbf{X}_A | \mathbf{X}_B}(\mathbf{u} | \mathbf{x}_B) d\mathbf{u}, \\ \mathbb{E}(\mathbf{X}_A | \mathbf{X}_B = \mathbf{x}_B) &= \sum_{u \in A} \mathbf{u} p_{\mathbf{X}_A | \mathbf{X}_B}(\mathbf{u} | \mathbf{x}_B). \end{aligned}$$

On a

$$\mathbb{E}(\mathbf{X}_A) = \mathbb{E}(\mathbb{E}(\mathbf{X}_A | \mathbf{X}_B)).$$

Propriété :

Soit $\mathbf{X}_A$ et $\mathbf{X}_B$ des partitions de $\mathbf{X}$. La fonction $g(\cdot)$ solution de

$$\min_g \mathbb{E} \left((\mathbf{X}_A - g(\mathbf{X}_B))^2 \right),$$

est $g(\mathbf{X}_B) = \mathbb{E}(\mathbf{X}_A | \mathbf{X}_B)$

6.5 Covariance

Soit $\boldsymbol{\mu} = (\mu_1, \dots, \mu_d)^\top = \mathbb{E}(\mathbf{X})$ le d-vecteur des espérances.

La **matrice de covariance** de $\mathbf{X}$ est une matrice $d \times d$

$$\begin{aligned} \Sigma &= \mathbb{E}((\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^\top) \\ &= \mathbb{E}(\mathbf{X}\mathbf{X}^\top) - \boldsymbol{\mu}\boldsymbol{\mu}^\top \end{aligned}$$

Soit $\mathbf{X}$ d'espérance $\boldsymbol{\mu}$ et covariance $\Sigma_{\mathbf{X}}$.

Soit M une matrice $p \times d$ et $\mathbf{m}$ un vecteur de taille p .

Alors $\mathbf{Y} = M\mathbf{X} + \mathbf{m}$ est un vecteur aléatoire de taille p tel que

$$\begin{aligned} \boldsymbol{\mu}_{\mathbf{Y}} &= M\boldsymbol{\mu} + \mathbf{m} \\ \Sigma_{\mathbf{Y}} &= M\Sigma_{\mathbf{X}}M^\top \end{aligned}$$

6.6 Indépendance

Les variables aléatoires X_k pour $k = 1, \dots, d$ sont indépendants ssi la pdf est le produit des pdfs marginaux

$$f(x_1, \dots, x_d) = \prod_{k=1}^d f_{X_k}(x_k).$$

$$p(x_1, \dots, x_d) = \prod_{k=1}^d P(X_k = x_k).$$

Conséquence 1 :

$$\mathbb{E}(\mathbf{X}_A | \mathbf{X}_B = x_B) = \mathbb{E}(\mathbf{X}_A)$$

Conséquence 2 :

La matrice de covariance est diagonal puisque

$$f_{X_i, X_j}(x_i, x_j) = f_{X_i}(x_i) f_{X_j}(x_j) :$$

$$\begin{aligned} \sigma_{i,j} &= \int \int (x_i - \mu_i)(x_j - \mu_j) f_{X_i, X_j}(x_i, x_j) dx_i dx_j \\ &= \underbrace{\int (x_i - \mu_i) f_{X_i}(x_i) dx_i}_{=0} \underbrace{\int (x_j - \mu_j) f_{X_j}(x_j) dx_j}_{=0} \end{aligned}$$

6.7 Distribution normale multivariée

$\mathbf{X}$ suit une **distribution normale multivariée** $\mathcal{N}(\mu, \Sigma)$ si sa pdf pour $\mathbf{x} = (x_1, \dots, x_d) \in \mathbb{R}^d$

$$f(x_1, \dots, x_d) = \frac{1}{\sqrt{\det(2\pi\Sigma)}} \exp\left(-\frac{1}{2}(\mathbf{x} - \mu)\Sigma^{-1}(\mathbf{x} - \mu)^\top\right)$$

avec Σ la matrice de covariance $d \times d$, et $\mu = (\mu_1, \dots, \mu_d)$ le vecteur moyenne

Propriétés :

- Σ est diagonale $\Leftrightarrow X_1, \dots, X_d$ sont indépendants
- Si $\mathbf{m} \in \mathbb{R}^d$ et $\mathbf{M}$ une matrice $d \times d$ alors

$$\mathbf{Y} = \mathbf{m} + \mathbf{M}\mathbf{X}$$

est une normale multivariée $\mathcal{N}(\mu_Y, \Sigma_Y)$ avec comme moyenne et covariance :

$$\mu_Y = \mathbf{m} + \mathbf{M}\mu$$

$$\Sigma_Y = \mathbf{M}\Sigma\mathbf{M}^\top$$

Conséquences

- $\mathbf{Y} = \Sigma^{-1/2}\mathbf{X} - \boldsymbol{\mu}$ est $\mathcal{N}(0, I_d)$ (avec $\Sigma^{1/2}$ tel que $\Sigma^{1/2}\Sigma^{1/2\top} = \Sigma$)
- $X_j \sim \mathcal{N}(\mu_j, \sigma_{jj})$

Soit $\mathbf{X} = (\mathbf{X}_A, \mathbf{X}_B)^\top \sim \mathcal{N}(\boldsymbol{\mu}, \Sigma)$ avec $\mathbf{X}_A$ et $\mathbf{X}_B$ de dimensions p et $d - p$. On a

$$\boldsymbol{\mu} = \begin{pmatrix} \boldsymbol{\mu}_A \\ \boldsymbol{\mu}_B \end{pmatrix} \quad \Sigma = \begin{pmatrix} \Sigma_{AA} & \Sigma_{AB} \\ \Sigma_{BA} & \Sigma_{BB} \end{pmatrix}$$

On a

$$\begin{aligned} \boldsymbol{\mu}_{B|A}(\mathbf{x}_A) &= \boldsymbol{\mu}_B + \Sigma_{BA}\Sigma_{AA}^{-1}(\mathbf{x}_A - \boldsymbol{\mu}_A) \\ \Sigma_{B|A}(\mathbf{x}_A) &= \Sigma_{BB} - \Sigma_{BA}\Sigma_{AA}^{-1}\Sigma_{AB} \end{aligned}$$

et

$$\mathbf{X}_A \sim \mathcal{N}(\boldsymbol{\mu}_A, \Sigma_{AA})$$

et

$$\mathbf{X}_B | \mathbf{X}_A = \mathbf{x}_A \sim \mathcal{N}(\boldsymbol{\mu}_{B|A}(\mathbf{x}_A), \Sigma_{B|A})$$

7 Estimation

Si $X_i \sim (\mu, \sigma)$ alors $\theta = (\mu, \sigma) \in \Theta = \mathbb{R}_+^2$, comment estimer θ

Un **estimateur** de θ , noté $\hat{\theta}$ est une fonction $h(\cdot)$

$$\hat{\theta} = h(X_1, \dots, X_n) \in \Theta$$

Une **estimation** de θ est une valeur observée d'un **estimateur** calculé à partir d'un échantillon $x_1, \dots, x_n$

$$\hat{\theta}_{\text{obs}} = h(x_1, \dots, x_n) \in \Theta$$

L'estimateur est une variable aléatoire

$\hat{\theta}$ est un estimateur non-biaisé de θ si

$$\mathbb{E}(\hat{\theta}) = \mathbb{E}(h(X_1, \dots, X_n)) = \theta.$$

Le **biais** est la différence entre l'espérance et la vraie valeur inconnue :

$$B(\hat{\theta}) = \mathbb{E}(\hat{\theta}) - \theta$$

La MSE (mean square error) mesure l'erreur moyenne

$$MSE(\hat{\theta}) = \mathbb{E}((\hat{\theta} - \theta)^2) = B(\hat{\theta})^2 + \mathbb{V}(\hat{\theta})$$

7.1 Méthode des moments

On observe $x_1, \dots, x_n$ résultats de $X_{i=1:n}$. On pense que $X_{i=1:n}$ a la même pdf $f(x|\theta)$ que X .

Pour estimer $\theta \in \mathbb{R}^d$, on match les d moments

$$\mu_k(\theta) = \mathbb{E}((X)^k) \quad k = 1, \dots, d$$

avec les d moments empiriques

$$M_k = \frac{1}{n} \sum_{i=1}^n X_i^k \quad k = 1, \dots, d$$

L'estimateur des moments $\hat{\theta}$ est solution d'un système de d équations

$$\mu_k(\hat{\theta}) = M_k \quad k = 1, \dots, d.$$

$$\mu_k(\hat{\theta}_{\text{obs}}) = m_k \quad k = 1, \dots, d.$$

$\bar{X}$ est un estimateur non-biaisé de $\mathbb{E}(X)$

Cette méthode est facile à appliquer, mais elle peut avoir des résultats moins précis que d'autres méthodes

7.2 Maximum de vraisemblance

Soit un échantillon aléatoire $X_{1:n} \sim X$. On pense que X a une pdf $f(x|\theta)$ où θ est un vecteur de paramètres aléatoires. On a

$$P(x \leq X \leq x + dx) \approx f(x|\theta)dx$$

Puisque $X_{i:n}$ sont indépendants, la probabilité d'observer les réalisations $x_{1:n}$ de $X_{1:n}$ est

$$\begin{aligned} &P(x_1 \leq X_1 \leq x_1 + dx, \dots, x_n \leq X_n \leq x_n + dx) \\ &= P(x_1 \leq X_1 \leq x_1 + dx) \dots P(x_n \leq X_n \leq x_n + dx) \\ &= \prod_{k=1}^n f(x_k|\theta)dx. \end{aligned}$$

La probabilité que l'échantillon observée a été générée par le modèle est proportionnel à la fonction de vraisemblance :

$$L(x_1, \dots, x_n|\theta) := \prod_{k=1}^n f(x_k|\theta)$$

Le MLE (maximum likelihood estimator) de θ est la valeur qui maximise la vraisemblance de l'échantillon observé

$$\hat{\theta} = \arg \max_{\theta} L(x_1, \dots, x_n|\theta)$$

Propriétés de la MLE :

- Une MLE est asymptotiquement sans biais, et asymptotiquement normale
- Une MLE est de variance minimum (par rapport à tout autre estimateur asymptotiquement sans biais)

En discret :

$$\hat{\theta} = \arg \max_{\theta} l(x_1, \dots, x_n|\theta)$$

où $l(\cdot)$ est la somme des log de la pmf:

$$l(x_1, \dots, x_n|\theta) = \sum_{i=1}^n \ln(p(x_i|\theta))$$

8 Simulations et Bootstrapping

8.1 Variable aléatoire continue

Soit une cdf continue $F(x)$ inversible, on définit

$$X = F^{-1}(U)$$

où U est une variable aléatoire continue et uniforme sur $[0, 1]$. Alors X a $F(x)$ comme cdf

8.2 Bootstrapping

Le bootstrapping permet d'estimer la variance d'un estimateur. On a qu'un seul échantillon $X = (X_1, \dots, X_n)$, on simule donc de nouveaux échantillons en repiochant dans l'échantillon initial.

Soit $X^* = (X_1^*, \dots, X_n^*)$ tel que $P(X_i^* = X_j) = \frac{1}{n}$ pour $1 \leq i, j \leq n$.

$\hat{\theta}(X^*)$ est une réplique bootstrap de $\hat{\theta}(X)$. Le nombre d'échantillon bootstrap possible est $C_{2n-1}^n = \frac{(2n-1)!}{n!(n-1)!}$

La variance est obtenue en tirant M échantillon bootstrap :

$$\mathbf{X}^{*m} = (X_1^{*m}, \dots, X_n^{*m}) m = 1 \dots M$$

θ est estimé par

$$\bar{\theta}^* = \frac{1}{M} \sum_{m=1}^M \hat{\theta}(X^{*m})$$

où $\hat{\theta}(X^{*m})$ est la réplique bootstrap de $\hat{\theta}(X)$

La variance empirique de l'estimateur est :

$$s^2(\hat{\theta}) = \frac{1}{M-1} \sum_{m=1}^M (\hat{\theta}(X^{*m}) - \bar{\theta}^*)^2$$

9 Moyenne et déviation standard empirique

9.1 Propriétés de $\bar{X}$ et S^2 (moyenne et variance empirique)

Un **intervall de confiance** pour μ au niveau $1 - \alpha$ est un interval $[\mu_L, \mu_U]$ tel que μ est dans l'intervall avec probabilité de $1 - \alpha$

Considérons n variables aléatoires $X_{i=1:n} \sim X$, $\mu = \mathbb{E}(X)$ et $\sigma^2 = \mathbb{V}(V)$. Le CLT (théorème central limite) dit que quel que soit la distribution de $X_{i=1:n}$, la moyenne empirique tend à une normale

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right) \quad \frac{\bar{X} - \mu}{\sqrt{\sigma^2/n}} \sim N(0, 1)$$

Dans ce cas $\bar{X}$ est un estimateur de μ et σ^2 est connu, on peut trouver

$$P\left(z_{\alpha/2} \leq \frac{\bar{X} - \mu}{\sqrt{\sigma^2/n}} \leq z_{1-\alpha/2}\right) = 1 - \alpha$$

Comme $-z_{1-\alpha/2} = z_{\alpha/2}$. L'intervall de confiance $1 - \alpha$ pour μ est

$$\left[\bar{X} - z_{1-\alpha/2} \sqrt{\sigma^2/n}; \bar{X} + z_{1-\alpha/2} \sqrt{\sigma^2/n}\right]$$

- $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ est un estimateur non biaisé de $\mathbb{V}(X)$
- Si $X_i \sim \mathcal{N}(\mu, \sigma^2)$, S^2 et $\bar{X}$ sont indépendants, donc

$$(n-1) \frac{S^2}{\sigma^2} = \sum_{i=1}^n \left(\frac{X_i - \bar{X}}{\sigma}\right)^2 \sim \chi_{n-1}^2$$

Si $X \sim N(\mu, \sigma^2)$, alors S^2 est un estimateur de σ . Puisque $(n-1) \frac{S^2}{\sigma^2} \sim \chi_{n-1}^2$, on trouve que

$$P\left(\chi_{n-1, \alpha/2}^2 \leq (n-1) \frac{S^2}{\sigma^2} \leq \chi_{n-1, 1-\alpha/2}^2\right) = 1 - \alpha$$

L'intervall de confiance $1 - \alpha$ est donc

$$\left[\frac{(n-1)}{\chi_{n-1, 1-\alpha/2}^2} S^2; \frac{(n-1)}{\chi_{n-1, \alpha/2}^2} S^2\right]$$

Une variable variable aléatoire Student's T est $T_n = \frac{Y}{\sqrt{Z/n}}$ où $Z \sim \chi_n^2$ et $Y \sim N(0, 1)$, alors :

Si $X_i \sim \mathcal{N}(\mu, \sigma^2)$ alors le ratio suivant est une variable aléatoire Student's T

$$\frac{\bar{X} - \mu}{\sqrt{\frac{S^2}{n}}} \sim t_{n-1}$$

Dans ce cas, $\bar{X}$ est un estimateur de μ , et σ est inconnu :

$$P\left(t_{n-1, \alpha/2} \leq \frac{\bar{X} - \mu}{\sqrt{S^2/n}} \leq t_{n-1, 1-\alpha/2}\right) = 1 - \alpha$$

la Student's T est symétrique : $-t_{n-1, \alpha/2} = t_{n-1, 1-\alpha/2}$. L'intervall de confidence $1 - \alpha$ est donc

$$\mu \in \left[\bar{X} - t_{n-1, 1-\alpha/2} \sqrt{S^2/n}; \bar{X} + t_{n-1, 1-\alpha/2} \sqrt{S^2/n}\right]$$

	Distribution of X	μ	σ^2	Statistics
$\bar{X}$	unknown and large n	ok	ok	$\frac{\bar{X} - \mu}{\sqrt{\sigma^2/n}} \sim \mathcal{N}(0, 1)$
S^2	$\mathcal{N}(\mu, \sigma^2)$	-	ok	$(n-1) \frac{S^2}{\sigma^2} \sim \chi_{n-1}^2$
$\bar{X}$	$\mathcal{N}(\mu, \sigma^2)$	ok	-	$\frac{\bar{X} - \mu}{\sqrt{\frac{S^2}{n}}} \sim t_{n-1}$

9.2 Propriétés de $\bar{X}$ et S^2 à 2 populations normales

		μ_1, μ_2	σ_1^2, σ_2^2	Statistics
$\bar{X}_1 - \bar{X}_2$	$\sigma_1^2 \neq \sigma_2^2$	ok	ok	$\frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim \mathcal{N}(0, 1)$
S_{pool}^2	$\sigma_1^2 = \sigma_2^2$	-	ok	$(n_1 + n_2 - 2) \frac{S_{pool}^2}{\sigma^2} \sim \chi_{n_1+n_2-2}^2$
S_1^2, S_2^2	$\sigma_1^2 \neq \sigma_2^2$	-	ok	$\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F_{n_1-1, n_2-1}$
$\bar{X}_1 - \bar{X}_2$	$\sigma_1^2 = \sigma_2^2$	ok	-	$\frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{S_{pool} \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t_{n_1+n_2-2}$