

Statistiques et science des données (LEPL1109)

Réalisé par
Quentin Aubecq
avec l'aide de

—
relu par

—
2026

SYNTEX

Cette synthèse est une **synthèse collaborative**, écrite en $\text{\LaTeX}$.
Elle est améliorée régulièrement, grâce à la participation de quelques étudiants.

La version que vous avez sous les yeux n'est sans doute pas la plus récente !

Alors...

...si vous désirez rester au courant des améliorations et corrections...

...si vous trouvez une erreur ou une imprécision...

...si vous souhaitez apporter votre aide à la réalisation...

...ou si vous voulez accéder à des synthèses d'autres cours...

...**rejoignez-nous** sur le serveur SYNTEX !



<https://discord.gg/BdFgQbCTag>

Remarque

Ce document est un support complémentaire au cours.
Nous déclinons toute responsabilité pour les éventuelles erreurs, omissions ou interprétations susceptibles de vous induire en erreur.
Les images, liens et autres contenus appartiennent exclusivement à leurs détenteurs respectifs.

Table des matières

1	Rappels	3
1.1	Variable aléatoire	3
1.2	Distribution de probabilités	3
1.3	Densité de probabilités	3
1.4	Espérance	4
1.5	Variance	4
1.6	Loi des grands nombres (LLN)	5
1.7	Quantiles	5
2	Statistiques descriptives et outil de visualisation	5
3	Indépendance et indépendance linéaire	5
3.1	Indépendance	5
3.2	Covariance	5

1 Rappels

1.1 Variable aléatoire

Une **variable aléatoire** est une fonction mesurable d'un espace Ω à un ensemble de nombres réels :

$$X : \Omega \rightarrow \mathbb{R}$$

On note $X(\omega) = x$

1.2 Distribution de probabilités

La **pmf** (probability mass function) $p(x)$ d'une variable aléatoire discrète, est une fonction qui associe une probabilité $P(X = x)$ à chaque valeur x de X

$$p(x) = P(X = x)$$

Si le domaine de X est $R = \{x_1, x_2, \dots\}$ alors $p(x) > 0 \forall x \in R$ et $p(x) = 0 \forall x \notin R$

$$\sum_i p(x_i) = 1$$

1.3 Densité de probabilités

La **pdf** (probability density function) $f(x) \geq 0$ d'une variable aléatoire continue X est une fonction tel que $\forall I \subset \mathbb{R}$

$$P(X \in I) = \int_I f(x) dx$$

La **cdf** (cumulative distribution function) $F(x)$ indique la probabilité que $X \leq x$

$$F(x) = P(X \leq x)$$

$$F(x) = \sum_{i: x_i \leq x} p(x_i)$$

$$F(x) = \int_{-\infty}^x f(u) du$$

$$f(x) = \frac{d}{dx} F(x)$$

1.4 Espérance

L'**espérance** d'une variable aléatoire X est notée $\mathbb{E}(X) = \mu_x$

$$\mu_X = \sum_{x \in \text{dom}(X)} xp(x)$$
$$\mu_x = \int_{-\infty}^{\infty} xf(x) dx$$

Propriétés :

- $\mathbb{E}(X + Y) = \mathbb{E}(X) + \mathbb{E}(Y)$
- $\mathbb{E}(aX + b) = a\mathbb{E}(X) + b$
- $\mathbb{E}(h(X)) = \sum_{x \in \text{dom}(X)} h(x)p(x)$
- $\mathbb{E}(h(X)) = \int_{-\infty}^{\infty} h(x)f(x) dx$

1.5 Variance

La **variance** d'une variable aléatoire X est

$$\mathbb{V}ar(X) = \mathbb{V}(X) = \sigma_X^2$$
$$\sigma_X^2 = \mathbb{E}((X - \mu_X)^2)$$

Avec σ_X la déviation standard

Propriétés :

- $\mathbb{V}(X) = \mathbb{E}(X^2) - (\mathbb{E}(X))^2$
- $\mathbb{V}(a) = 0$
- $\mathbb{V}(a + bX) = b^2\mathbb{V}(X)$
- $\mathbb{V}(X + Y) \neq \mathbb{V}(X) + \mathbb{V}(Y)$ Sauf si X et Y indépendant

Si on observe n événements $(x_k)_{k=1, \dots, n}$, la variance empirique est estimée avec

$$\sigma_X^2 \approx \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}$$

1.6 Loi des grands nombres (LLN)

Soit $X_{i=1,\dots,n}$ une séquence d'événements aléatoires indépendants avec la même espérance $\mu_X = \mathbb{E}(X_i)$ et de variance σ_X^2 . Lorsque $n \rightarrow \infty$, la moyenne $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ converge vers μ_X

$$\forall \varepsilon > 0 \quad \lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu_X| \geq \varepsilon) = 0$$

On note $\bar{X}_n \xrightarrow{p} \mu_X$
<...>

1.7 Quantiles

<...>

2 Statistiques descriptives et outil de visualisation

<...>

3 Indépendance et indépendance linéaire

3.1 Indépendance

Deux variables aléatoires X et Y sont **indépendantes** ($X \perp\!\!\!\perp Y$) si $\forall A, B \in \mathbb{R}$:

$$P(X \in A, Y \in B) = P(X \in A)P(Y \in B)$$

Conséquences :

- $p(x, y) = p_X(x)p_Y(y)$ quand X et Y sont discrets
- $f(x, y) = f_X(x)f_Y(y)$ quand X et Y sont continus

3.2 Covariance

$$\begin{aligned}\sigma_{XY} &= \text{Cov}(X, Y) = \mathbb{E}[(X - \mu_X)(Y - \mu_Y)] \\ &= \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y) \\ &= \mu_{XY} - \mu_X\mu_Y\end{aligned}$$

Si on observe n événements $(x_k)_{k=1,\dots,n}$ et $(y_k)_{k=1,\dots,n}$, la covariance empirique est estimée avec

$$\sigma_{XY} \approx s_{XY} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

Propriétés :

- $\mathbb{C}(X, Y) = \mathbb{C}(Y, X)$
- $\mathbb{C}(X, X) = \mathbb{V}(X)$ et $\mathbb{C}(a, X) = 0 \quad \forall a \in \mathbb{R}$
- Si $X \perp\!\!\!\perp Y$ alors $\mathbb{C}(X, Y) = 0$
- $\mathbb{C}(aX + bY, Z) = a\mathbb{C}(X, Z) + b\mathbb{C}(Y, Z)$
- $\mathbb{V}(aX + bY) = a^2\mathbb{V}(X) + b^2\mathbb{V}(Y) + 2ab\mathbb{C}(X, Y)$

(Attention si $\mathbb{C}(X, Y) = 0 \nRightarrow X \perp\!\!\!\perp Y$)

<... jusqu'à Normal random variable and Central Limit Theorem>