Statistiques et science des données (LEPL1109)

Réalisé par
Quentin Aubecq
avec l'aide de

–
relu par
Basile Audeval

2026

SYNTEX

Cette synthèse est une **synthèse collaborative**, écrite en LaTeX.
Elle est améliorée régulièrement, grâce à la participation de quelques étudiants.

La version que vous avez sous les yeux n'est sans doute pas la plus récente !

Alors...
...si vous désirez rester au courant des améliorations et corrections...
...si vous trouvez une erreur ou une imprécision...
...si vous souhaitez apporter votre aide à la réalisation...
...ou si vous voulez accéder à des synthèses d'autres cours...
...**rejoignez-nous** sur le serveur SYNTEX !

https://discord.gg/BdFgQbCTag

Remarque

Ce document est un support complémentaire au cours.
Nous déclinons toute responsabilité pour les éventuelles erreurs, omissions ou interprétations susceptibles de vous induire en erreur.
Les images, liens et autres contenus appartiennent exclusivement à leurs détenteurs respectifs.

Table des matières

1 Rappels **4**
- 1.1 Variable aléatoire . . . 4
- 1.2 Distribution de probabilités . . . 4
- 1.3 Densité de probabilités . . . 4
- 1.4 Espérance . . . 5
- 1.5 Variance . . . 5
- 1.6 Loi des grands nombres (LLN) . . . 5
- 1.7 Quantiles . . . 6
- 1.8 Fonction d'une variable aléatoire . . . 6

2 Statistiques descriptives et outil de visualisation **7**
- 2.1 Moyenne, Médiane et Quantiles . . . 7
- 2.2 Range, IQR, Outliers . . . 7
- 2.3 Analyse graphique . . . 7

3 Indépendance et indépendance linéaire **9**
- 3.1 Indépendance . . . 9
- 3.2 Covariance . . . 9
- 3.3 Corrélation . . . 10

4 Variable aléatoire normale et théorème central limite **11**
- 4.1 Standardisation . . . 11
- 4.2 Théorème Central Limite . . . 11

5 Autres variables aléatoires fondamentales **12**
- 5.1 Distribution Chi-square (χ^2) . . . 12
- 5.2 Student's T . . . 12
- 5.3 Fisher-Snedecor . . . 12

6 Variable aléatoires multivariées **13**
- 6.1 Distribution marginale . . . 13
- 6.2 Distribution conditionelle . . . 14
- 6.3 Espérances . . . 14
- 6.4 Espérance conditionnelle . . . 15
- 6.5 Covariance . . . 15
- 6.6 Indépendance . . . 16
- 6.7 Distribution normale multivariée . . . 16

7 Estimation **18**
- 7.1 Méthode des moments . . . 18
- 7.2 Maximum de vraisemblance . . . 19

8 Simulations et Bootstrapping **19**
8.1 Variable aléatoire continue 19
8.2 Bootstrapping 20

9 Moyenne et déviation standard empirique **21**
9.1 Propriétés de $\bar{X}$ et S^2 (moyenne et variance empirique) 21
9.2 Propriétés de $\bar{X}$ et S^2 à 2 populations normales 22

10 Test d'hypothèse à 1 population **23**
10.1 Introduction 23
10.2 Single mean test, θ^2 inconnu 23
10.3 Single variance test 24
10.4 P-valeur 25

11 Test d'hypothèse à 2 populations **26**
11.1 Comparaison de 2 médiane 26
11.1.1 Cas 1 : σ connu 26
11.1.2 Cas 2 : σ connu 27
11.2 Comparaison de 2 variances 27

12 Régression linéaire **28**
12.1 Moindre carré 28
12.2 Régression linéaire simple 29

13 Propriétés des coefficients de régression **30**
13.1 Régression linéaire simple 30
13.2 Test de signification de régression linéaire 30

1 Rappels

1.1 Variable aléatoire

Une **variable aléatoire** est une fonction mesurable d'un espace Ω à un ensemble de nombres réels :

$$X : \Omega \to \mathbb{R}$$

On note $X(\omega) = x$

1.2 Distribution de probabilités

La **pmf** (probability mass function) $p(x)$ d'une variable aléatoire discrète, est une fonction qui associe une probabilité $P(X = x)$ à chaque valeur x de X

$$p(x) = P(X = x)$$

Si le domaine de X est $R = \{x_1, x_2, \dots\}$ alors $p(x) > 0 \; \forall x \in R$ et $p(x) = 0 \; \forall x \notin R$

$$\sum_i p(x_i) = 1$$

1.3 Densité de probabilités

La **pdf** (probability density function) $f(x) \geq 0$ d'une variable aléatoire continue X est une fonction tel que $\forall I \subset \mathbb{R}$

$$P(X \in I) = \int_I f(x)\, dx$$

La **cdf** (cumulative distribution function) $F(x)$ indique la probablité que $X \leq x$

$$F(x) = P(X \leq x)$$

$$F(x) = \sum_{i:x_i \leq x} p(x_i)$$

$$F(x) = \int_{-\infty}^{x} f(u)\, du$$

$$f(x) = \frac{d}{dx} F(x)$$

1.4 Espérance

L'**espérance** d'une variable aléatoire X est notée $\mathbb{E}(X) = \mu_x$

$$\mu_X = \sum_{x \in dom(X)} xp(x)$$

$$\mu_x = \int_{-\infty}^{\infty} xf(x)\,dx$$

Propriétés :

- $\mathbb{E}(X+Y) = \mathbb{E}(X) + \mathbb{E}(Y)$
- $\mathbb{E}(aX+b) = a\mathbb{E}(X) + b$
- $\mathbb{E}(h(X)) = \sum_{x \in dom(X)} h(x)p(x)$
- $\mathbb{E}(h(X)) = \int_{-\infty}^{\infty} h(x)f(x)\,dx$

1.5 Variance

La **variance** d'une variable aléatoire X est

$$\mathbb{V}ar(X) = \mathbb{V}(X) = \sigma_X^2$$

$$\sigma_X^2 = \mathbb{E}\left((X - \mu_X)^2\right)$$

Avec σ_X la déviation standard
Propriétés :

- $\mathbb{V}(X) = \mathbb{E}(X^2) - (\mathbb{E}(X))^2$
- $\mathbb{V}(a) = 0$
- $\mathbb{V}(a+bX) = b^2\mathbb{V}(X)$
- $\mathbb{V}(X+Y) \neq \mathbb{V}(X) + \mathbb{V}(Y)$ Sauf si X et Y indépendant

Si on observe n événements $(x_k)_{k=1\ldots,n}$, la variance empirique est estimée avec

$$\sigma_X^2 \approx \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1} = s^2$$

1.6 Loi des grands nombres (LLN)

Soit $X_{i=1,\ldots,n}$ une séquence d'événements aléatoires indépendants avec la même espérance $\mu_X = \mathbb{E}(X_i)$ et de variance σ_X^2. Lorsque $n \to \infty$, la moyenne $\bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i$ converge vers μ_X

$$\forall \varepsilon > 0 \qquad \lim_{n\to\infty} P(|\bar{X}_n - \mu_X| \geq \varepsilon) = 0$$

On note $\bar{X}_n \xrightarrow{p} \mu_X$

1.7 Quantiles

Soit p une probabilité et X une variable aléatoire. Le nombre q_p satisfaisant la relation

$$P(X \leq q_p) = p$$

est le quantile d'ordre p pour X. Si X est continu et si son cdf $F(x)$ est inversible, alors $q_p = F^{-1}(p)$

1.8 Fonction d'une variable aléatoire

Soit X une variable aléatoire continue de densité (pdf) $f_X(x)$. La densité de $Y = a + bX$ est donnée par

$$f_Y(y) = \frac{1}{|b|} f_X\left(\frac{y-a}{b}\right)$$

2 Statistiques descriptives et outil de visualisation

- **Population** : Collection de tous les résultats possibles qui nous intéressent
- **Échantillon** : Un subset de population
- **Statistiques** descriptives : Branche des statistiques qui s'occupe de l'organisation et de l'affichage des données

2.1 Moyenne, Médiane et Quantiles

- **Moyenne** :

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

- **Médiane** : La valeur $q_{0.5}$ telle que la moitié des résultats sont en dessous, et l'autre moitiée au dessus
- **Quantile** : On trie les résultats par ordre croissant $x_{(1)} \leq \cdots \leq x_{(n)}$, on a

$$q_p = x_{(1+(n-1)p)}$$

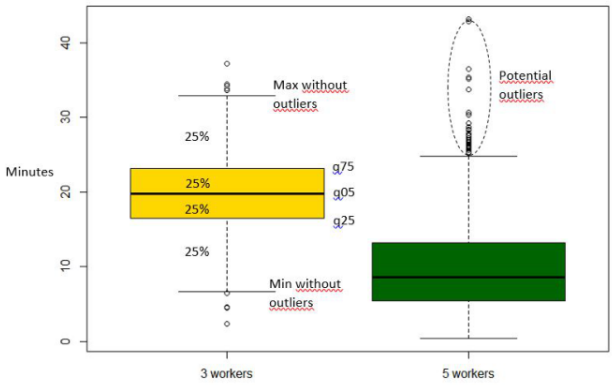
2.2 Range, IQR, Outliers

- **Range** : $x_{max} - x_{min}$
- **Inter-Quartile Range (IQR)** : La différence entre des quartiles symétriques, par exemple $IQR = q_{0.75} - q_{0.25}$
- **Outliers** : Observations qui sont trop loin du reste des données, qui pourraient être due à des erreurs

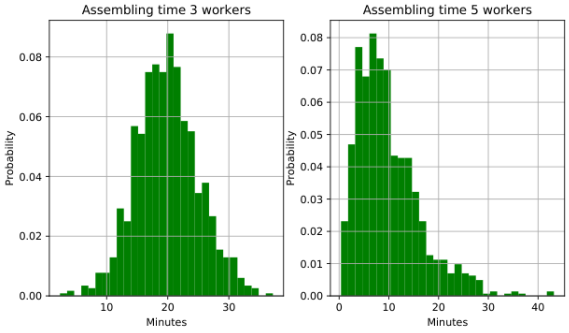
  Une observation est considérée comme susbecte si elle est plus bas que $q_{0.25} - 1.5 \times IQR$ ou plus haut que $q_{0.75} + 1.5 \times IQR$

2.3 Analyse graphique

Boxplot :


Minutes
0
10
20
30
40
Max without outliers
25%
25%
25%
25%
g75
g05
g25
Min without outliers
Potential outliers
3 workers
5 workers

Histogram :


Assembling time 3 workers
Probability
0.00
0.02
0.04
0.06
0.08
10
20
30
Minutes
Assembling time 5 workers
Probability
0.00
0.01
0.02
0.03
0.04
0.05
0.06
0.07
0.08
0
10
20
30
40
Minutes

3 Indépendance et indépendance linéaire

3.1 Indépendance

Deux variables aléatoires X et Y sont **indépendantes** ($X \perp\!\!\!\perp Y$) si $\forall A, B \in \mathbb{R}$:

$$P(X \in A, Y \in B) = P(X \in A)P(Y \in B)$$

Conséquences :

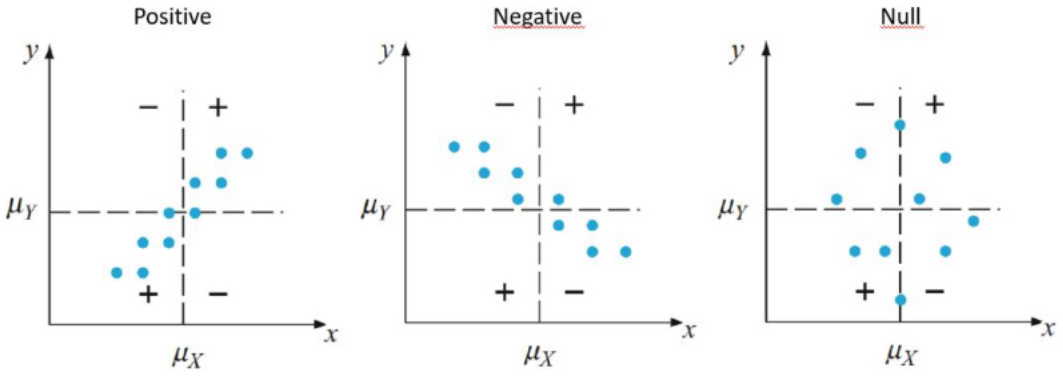
- $p(x,y) = p_X(x)p_Y(y)$ quand X et Y sont discrets
- $f(x,y) = f_X(x)f_Y(y)$ quand X et Y sont continus

3.2 Covariance

$$\begin{aligned}\sigma_{XY} &= \mathbb{C}ov(X,Y) = \mathbb{E}[(X-\mu_X)(Y-\mu_Y)] \\ &= \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y) \\ &= \mu_{XY} - \mu_x\mu_Y\end{aligned}$$

Si on observe n événements $(x_k)_{k=1,\dots,n}$ et $(y_k)_{k=1,\dots,n}$, la covariance empirique est estimée avec

$$\sigma_{XY} \approx s_{XY} = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})$$



Propriétés :

- $\mathbb{C}(X,Y) = \mathbb{C}(Y,X)$
- $\mathbb{C}(X,X) = \mathbb{V}(X)$ et $\mathbb{C}(a,X) = 0 \quad \forall a \in \mathbb{R}$
- Si $X \perp\!\!\!\perp Y$ alors $\mathbb{C}(X,Y) = 0$
- $\mathbb{C}(aX + bY, Z) = a\mathbb{C}(X,Z) + b\mathbb{C}(Y,Z)$

- $\boxed{\mathbb{V}(aX+bY) = a^2\mathbb{V}(X) + b^2\mathbb{V}(Y) + 2ab\mathbb{C}(X,Y)}$

(Attention si $\mathbb{C}(X,Y) = 0 \not\Rightarrow X \perp\!\!\!\perp Y$)

La covariance est une mesure de la dépendance linéaire entre deux variables aléatoires.
La taille d'une covariance dépend de l'échelle des variables : $\mathbb{C}(aX,Y) = a\mathbb{C}(X,Y)$

3.3 Corrélation

La **corrélation** entre X et Y est défini comme

$$\rho_{XY} = \frac{\mathbb{C}(X,Y)}{\sqrt{\mathbb{V}(X)\mathbb{V}(Y)}} = \frac{\sigma_{XY}}{\sigma_X \sigma_Y}$$

L'inégalité de Cauchy Schwarz donne
$|\sigma_{XY}| \leq \sigma_X \sigma_Y$ avec égalité si et seulement si $Y = aX + b$
On en déduit les propriétés suivantes :

- ρ_{XY} est invariant à l'échelle
- $-1 \leq \rho_{XY} \leq 1$
- Si $\rho_{XY} = 1$ alors $Y = a + bX$ avec $b \in \mathbb{R}^+$ (Y proportionnel à X)
- Si $\rho_{XY} = -1$ alors $Y = a + bX$ avec $b \in \mathbb{R}^-$ (Y inversément proportionnel à X)

La corrélation est une mesure the la dépendance linéaire entre deux variables aléatoires.
Elle n'a pas d'unité et est dans $[-1,1]$

On peut estimer la correlation de manière empirique :

$$\rho_{XY} \approx r_{XY} = \frac{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2}\sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(y_i - \bar{y})^2}}$$

4 Variable aléatoire normale et théorème central limite

Une variable aléatoire suit une **distribution normale** si sa densité est donnée par

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right) \quad x \in \mathbb{R}$$

avec $\mu \in \mathbb{R}$ et $\sigma \in \mathbb{R}^+$ des paramètres. On note $X \sim \mathcal{N}(\mu, \sigma^2)$

$$\mathbb{E}(X) = \mu \quad , \quad \mathbb{V}(X) = \sigma^2$$

$$m_X(t) := \mathbb{E}\left(e^{tX}\right) = \exp\left(\mu t + \frac{1}{2}t^2\sigma^2\right)$$

$m_X(t)$ fonction génératrice des moments $\left.\frac{\partial^n m_X(t)}{\partial t^n}\right|_{t=0} = \mathbb{E}(X^n)$

4.1 Standardisation

- Si $X \sim \mathcal{N}(\mu, \sigma^2)$, alors $a + bX \sim \mathcal{N}(a + b\mu, b^2\sigma^2)$
- Si $X \sim \mathcal{N}(\mu_x, \sigma_x^2)$ et $Y \sim \mathcal{N}(\mu_y, \sigma_y^2)$ avec la covariance $\sigma_{x,y} = \mathbb{C}(X, Y)$, alors
$$aX + bY \sim \mathcal{N}(a\mu_x + b\mu_y, a^2\sigma_x^2 + b^2\sigma_y^2 + 2ab\sigma_{x,y})$$
- Si $X \sim \mathcal{N}(\mu, \sigma^2)$ alors $\frac{X-\mu}{\sigma} \sim Z = \mathcal{N}(0, 1)$ et

$$P(X \leq x) = P\left(Z \leq \frac{x-\mu}{\sigma}\right)$$

4.2 Théorème Central Limite

Soit $X_1, \ldots, X_n$ une séquence de variables aléatoires indépendantes et identiquement distribuées, avec $\mathbb{E}(X_i) = \mu$ et $\mathbb{V}(X_i) = \sigma^2$ lorsque $n \to \infty$

$$Z_n = \sqrt{n}\frac{\bar{X}_n - \mu}{\sigma} \xrightarrow{d} Z \sim \mathcal{N}(0, 1)$$

$$P(Z_n \leq z) \xrightarrow{n\to\infty} P(Z \leq z) \forall z$$

5 Autres variables aléatoires fondamentales

5.1 Distribution Chi-square (χ^2)

Une variable aléatoire X définie sur $\mathbb{R}^+$ suit une distribution χ^2 de paramètre n si sa densitée (pdf) est donnée par

$$\frac{1}{2^{n/2}\Gamma(n/2)} x^{n/2-1} e^{-x/2}$$

$$\text{où } \Gamma(\alpha) = \int_0^\infty t^{\alpha-1} e^{-t} dt \quad \text{(Fonction Gamma).}$$

On a $\mathbb{E}(X) = n$ et $\mathbb{V}(X) = 2n$

5.2 Student's T

Soit Z et Y deux variables aléatoires indépendantes $Z \sim \mathcal{N}(0,1)$ et $Y \sim \chi^2_n$ alors

$$T_n = \frac{Z}{\sqrt{Y/n}}$$

est la variable aléatoire **Student'T** avec n degrés de liberté. Sa pdf est

$$f_{T_n}(t) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi}\Gamma\left(\frac{n}{2}\right)} \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}} \qquad t \in \mathbb{R}$$

5.3 Fisher-Snedecor

Soit X et Y deux variables aléatoires χ^2 indépendantes avec n_1 et n_2 degrés de liberté, alors

$$F_{n_1,n_2} = \frac{X/n_1}{Y/n_2}$$

suis la distribution de **Fisher-Snedecor**, sa pdf est

$$f_{F_{n1,n2}}(z) = \frac{\Gamma\left(\frac{n_1+n_2}{2}\right)\left(\frac{n_1}{n_2}\right)^{\frac{n_1}{2}} z^{\left(\frac{n_1}{2}-1\right)}}{\Gamma\left(\frac{n_1}{2}\right)\Gamma\left(\frac{n_2}{2}\right)\left(1+\frac{n_1}{n_2}x\right)^{\frac{n_1+n_2}{2}}} t \in \mathbb{R}$$

6 Variable aléatoires multivariées

Un **vecteur aléatoire** $\mathbf{X} = (X_1, \ldots, X_d)^\top$ est une application $\Omega \to \mathbb{R}^p$

Si $X_1, \ldots, X_d$ sont continues, la fonction de distribution de probablité multivariée (pdf) est

$$\begin{aligned} P(\mathbf{X} \leq \mathbf{x}) &= P(X_1 \leq x_1, \ldots, X_d \leq x_d) \\ &= \int_{-\infty}^{x_d} \cdots \int_{-\infty}^{x_1} f(u_1, \ldots, u_d)\, du_1 \ldots du_d \end{aligned}$$

Si $X_1, \ldots, X_d$ sont discrètes, la fonction de masse multivariée (pmf) est

$$\begin{aligned} P(\mathbf{X} = \mathbf{x}) &= P(X_1 = x_1, \ldots, X_d = x_d) \\ &= p(x_1, \ldots, x_d). \end{aligned}$$

6.1 Distribution marginale

Continu :
Soit $\mathbf{X} = (X_1, \ldots, X_d)^\top$ un vecteur aléatoire continu. La pdf marginale de X_k pour $k = 1, \ldots, d$ est

$$\begin{aligned} P(X_k \leq x) &= P(X_1 \leq \infty, \ldots, X_k \leq x, \ldots, X_d \leq \infty) \\ &= \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{x} \cdots \int_{-\infty}^{+\infty} f(u_1, \ldots, u_d) du_1 \ldots du_d \end{aligned}$$

On a

$$\begin{aligned} f_{X_k}(x) &= \frac{\partial}{\partial x} P(X_k \leq x) \\ &= \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} f(u_1, \ldots, u_{k-1}, x, u_{k+1}, \ldots, u_d) du_1 \ldots du_d. \end{aligned}$$

La distribution bivariée de X_i et X_j est

$$f_{X_i, X_j}(x_i, x_j) = \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} f(u_1, \ldots, X_i, \ldots, X_j, \ldots, u_d)\, du_1 \ldots du_d$$

Discret :
Soit $\mathbf{X} = (X_1, \ldots, X_d)^\top$ un vecteur aléatoire discret. La pmf marginale de X_k pour $k = 1, \ldots, d$ est

$$P(X_k = x_{k,j}) = \sum_{i_d=1}^{m_d} \cdots \sum_{i_{k+1}=1}^{m_{k+1}} \sum_{i_{k-1}=1}^{m_{k-1}} \cdots \sum_{i_1=1}^{m_1} p(x_{1,i_1}, \ldots, x_{k,j}, \ldots, x_{d,i_d})$$
$$= p_{\bullet,\ldots,j,\ldots,\bullet}$$

6.2 Distribution conditionelle

Pour un petit Δ, la pdf peut être interprétée comme une probabilitée

$$f(x_1, \ldots, x_d)\Delta^d \approx P(x_1 \leq X_1 \leq x_1 + \Delta, \ldots, x_d \leq X_d \leq x_d + \Delta)$$

Le théorème de Bayes dit que pour tout sous-ensemble A et B de $\mathbb{R}^p$, la probabilité que $X \in A$, en sachant que $X \in B$ est :

$$P(\mathbf{X} \in A | \mathbf{X} \in B) = \frac{P(\mathbf{X} \in A \cap B)}{P(\mathbf{X} \in B)}$$

Si $d = 2$, on défini la pdf conditionelle de la variable aléatoire $X_1|X_2$:

$$f_{X_1|X_2}(x_1|x_2) = \frac{f(x_1, x_2)}{f_{X_2}(x_2)}$$

$$f_{X_1|X_2}(x_1|x_2)\Delta \approx P(x_1 \leq X_1 \leq x_1 + \Delta | X_2 = x_2)$$

Si on partitionne $\mathbf{X}$ en $\mathbf{X}_A|\mathbf{X}_B$, la pdf conditionnelle est donnée par

$$f_{\mathbf{X}_A|\mathbf{X}_B}(\mathbf{x}_A|\mathbf{x}_B) = \frac{f((\mathbf{x}_A, \mathbf{x}_A))}{f_{\mathbf{X}_B}(\mathbf{x}_B)}$$

$$p_{\mathbf{X}_A|\mathbf{X}_B}(\mathbf{x}_A|\mathbf{x}_B) = \frac{p((\mathbf{x}_A, \mathbf{x}_B))}{p_{\mathbf{X}_B}(\mathbf{x}_B)}$$

6.3 Espérances

Continu :

$$\mathbb{E}(\mathbf{X}) = \begin{pmatrix} \mathbb{E}(X_1) \\ \vdots \\ \mathbb{E}(X_d) \end{pmatrix} = \begin{pmatrix} \int_{-\infty}^{+\infty} x f_1(x)\, dx \\ \vdots \\ \int_{-\infty}^{+\infty} x f_d(x)\, dx \end{pmatrix}$$

Discret :

$$\mathbb{E}(\mathbf{X}) = \begin{pmatrix} \mathbb{E}(X_1) \\ \vdots \\ \mathbb{E}(X_d) \end{pmatrix} = \begin{pmatrix} \sum_{j=1}^{m_1} x_{1,j} p_{j,\bullet,\ldots,\bullet} \\ \vdots \\ \sum_{j=1}^{m_d} x_{d,j} p_{\bullet,\ldots,\bullet,j} \end{pmatrix}$$

Propriétés :

- $\mathbb{E}(\alpha\mathbf{X} + \beta\mathbb{Y}) = \alpha\mathbb{E}(\mathbf{X}) + \beta\mathbb{E}(\mathbf{Y})$
- Si $\mathbf{X}$ et $\mathbf{Y}$ indépendants : $\mathbb{E}(\mathbf{X}^\top\mathbf{Y}) = \mathbb{E}(\mathbf{X})^\top\mathbb{E}(\mathbf{Y})$

6.4 Espérance conditionnelle

On divise $\mathbf{X}$ en deux vecteurs disjoints $\mathbf{X}_A$ et $\mathbf{X}_B$.
L'espérance conditionnelle de $\mathbf{X}_A$ si $\mathbf{X}_B = \mathbf{x}_B$ est

$$\mathbb{E}(\mathbf{X}_A|\mathbf{X}_B = \mathbf{x}_B) = \int_{u\in A} \mathbf{u} f_{\mathbf{X}_A|\mathbf{X}_B}(\mathbf{u}|\mathbf{x}_B) d\mathbf{u},$$
$$\mathbb{E}(\mathbf{X}_A|\mathbf{X}_B = \mathbf{x}_B) = \sum_{u\in A} \mathbf{u} p_{\mathbf{X}_A|\mathbf{X}_B}(\mathbf{u}|\mathbf{x}_B).$$

On a

$$\mathbb{E}(\mathbf{X}_A) = \mathbb{E}(\mathbb{E}(\mathbf{X}_A|\mathbf{X}_B)).$$

Propriété :
Soit $\mathbf{X}_A$ et $\mathbf{X}_B$ des partitions de $\mathbf{X}$. La fonction $g(.)$ solution de

$$\min_g \mathbb{E}\left((\mathbf{X}_A - g(\mathbf{X}_B))^2\right),$$

est $g(\mathbf{X}_B) = \mathbb{E}(\mathbf{X}_A|\mathbf{X}_B)$

6.5 Covariance

Soit $\mu = (\mu_1, \ldots, \mu_d)^\top = \mathbb{E}(\mathbf{X})$ le d-vecteur des espérances.
La **matrice de covariance** de $\mathbf{X}$ est une matrice $d \times d$

$$\begin{aligned} \Sigma &= \mathbb{E}\left((\mathbf{X} - \mu)(\mathbf{X} - \mu)^{\mathrm{T}}\right) \\ &= \mathbb{E}\left(\mathbf{X}\mathbf{X}^{\mathrm{T}}\right) - \mu\mu^{\mathrm{T}} \end{aligned}$$

Soit $\mathbf{X}$ d'espérance μ et covariance $\sum_{\mathbf{X}}$.
Soit M une matrice $p \times d$ et $\mathbf{m}$ un vecteur de taille p.
Alors $\mathbf{Y} = M\mathbf{X} + \mathbf{m}$ est un vecteur aléatoire de taille p tel que

$$\mu_{\mathbf{Y}} = M\mu + \mathbf{m}$$
$$\Sigma_{\mathbf{Y}} = M\Sigma_X M^\top$$

6.6 Indépendance

Les variables aléatoires X_k pour $k = 1, \ldots, d$ sont indépendants ssi la pdf est le produit des pdfs marginaux

$$f(x_1, \ldots, x_d) = \prod_{k=1}^{d} f_{X_k}(x_k).$$

$$p(x_1, \ldots, x_d) = \prod_{k=1}^{d} P(X_k = x_k).$$

Conséquence 1 :

$$\mathbb{E}(\mathbf{X}_A | \mathbf{X}_B = x_B) = \mathbb{E}(\mathbf{X}_A)$$

Conséquence 2 :
La matrice de covariance est diagonal puisque
$f_{X_i,X_j}(x_i, x_j) = f_{X_i}(x_i) f_{X_j}(x_j)$:

$$\begin{aligned}\sigma_{i,j} &= \int\int (x_i - \mu_i)(x_j - \mu_j) f_{X_i,X_j}(x_i, x_j)\, dx_i dx_j \\ &= \underbrace{\int (x_i - \mu_i) f_{X_i}(x_i)\, dx_i}_{=0} \underbrace{\int (x_j - \mu_j) f_{X_j}(x_j)\, dx_j}_{=0}\end{aligned}$$

6.7 Distribution normale multivariée

$\mathbf{X}$ suit une **distribution normale multivariée** $\mathcal{N}(\mu, \sum)$ si sa pdf pour $\mathbf{x} = (x_1, \ldots, x_d) \in \mathbb{R}^d$

$$f(x_1, \ldots, x_d) = \frac{1}{\sqrt{det(2\pi\Sigma)}} \exp\left(-\frac{1}{2} (\mathbf{x} - \mu) \Sigma^{-1} (\mathbf{x} - \mu)^\top \right)$$

avec Σ la matrice de covariance $d \times d$, et $\mu = (\mu_1, \ldots, \mu_d)$ le vecteur moyenne

Propriétés :

- Σ est diagonale $\Leftrightarrow X_1, \ldots, X_d$ sont indépendants
- Si $\mathbf{m} \in \mathbb{R}^d$ et $\mathbf{M}$ une matrice $d \times d$ alors

  $$\mathbf{Y} = \mathbf{m} + \mathbf{M}\mathbf{X}$$

  est une normale multivariée $\mathcal{N}(\mu_\mathbf{Y}, \Sigma_\mathbf{Y})$ avec comme moyenne et covariance :

  $$\mu_\mathbf{Y} = \mathbf{m} + \mathbf{M}\mu$$

  $$\Sigma_Y = \mathbf{M}\Sigma\mathbf{M}^\top$$

Conséquences

- $\mathbf{Y} = \Sigma^{-1/2}\mathbf{X} - \mu$ est $\mathcal{N}(0, I_d)$ (avec $\Sigma^{1/2}$ tel que $\Sigma^{1/2}\Sigma^{1/2\top} = \Sigma$)
- $X_j \sim \mathcal{N}(\mu_j, \sigma_{jj})$

Soit $\mathbf{X} = (\mathbf{X}_A, \mathbf{X}_B)^\top \sim \mathcal{N}(\mu, \Sigma)$ avec $\mathbf{X}_A$ et $\mathbf{X}_B$ de dimensions p et $d-p$. On a

$$\mu = \begin{pmatrix} \mu_A \\ \mu_B \end{pmatrix} \qquad \Sigma = \begin{pmatrix} \Sigma_{AA} & \Sigma_{AB} \\ \Sigma_{BA} & \Sigma_{BB} \end{pmatrix}$$

On a

$$\mu_{B|A}(\mathbf{x}_A) = \mu_B + \Sigma_{BA}\Sigma_{AA}^{-1}(\mathbf{x}_A - \mu_A)$$
$$\Sigma_{B|A}(\mathbf{x}_A) = \Sigma_{BB} - \Sigma_{BA}\Sigma_{AA}^{-1}\Sigma_{AB}$$

et

$$\mathbf{X}_A \sim \mathcal{N}(\mu_A, \Sigma_{AA})$$

et

$$\mathbf{X}_B|\mathbf{X}_A = \mathbf{x}_A \sim \mathcal{N}(\mu_{B|A}(\mathbf{x}_A), \Sigma_{B|A})$$

7 Estimation

Si $X_i \sim (\mu, \sigma)$ alors $\theta = (\mu, \sigma) \in \Theta = \mathbb{R}_+^2$, comment estimer θ
Un **estimateur** de θ, noté $\hat{\theta}$ est une fonction $h(.)$

$$\hat{\theta} = h(X_1, \ldots, X_n) \in \Theta$$

Une **estimation** de θ est une valeur observée d'un **estimateur** calculé à partir d'un échantillon $x_1, \ldots, x_n$

$$\hat{\theta}_{\text{obs}} = h(x_1, \ldots, x_n) \in \Theta$$

L'estimateur est une variable aléatoire
$\hat{\theta}$ est un estimateur non-biaisé de θ si

$$\mathbb{E}(\widehat{\theta}) = \mathbb{E}(h(X_1, \ldots, X_n)) = \theta.$$

Le **biais** est la différence entre l'espérance et la vrai valeur inconnue :

$$B(\hat{\theta}) = \mathbb{E}(\hat{\theta}) - \theta$$

La MSE (mean sqaure error) mesure l'erreur moyenne

$$MSE(\hat{\theta}) = \mathbb{E}\left(\left(\hat{\theta} - \theta\right)^2\right) = B(\hat{\theta})^2 + \mathbb{V}(\hat{\theta})$$

7.1 Méthode des moments

On observe $x_1, \ldots, x_n$ résultats de $X_{i=1:n}$. On pense que $X_{i=1:n}$ a la même pdf $f(x|\theta)$ que X.
Pour estimer $\theta \in \mathbb{R}^d$, on match les d moments

$$\mu_k(\theta) = \mathbb{E}\left((X)^k\right) \qquad k = 1, \ldots, d$$

avec les d moments empiriques

$$M_k = \frac{1}{n}\sum_{i=0}^{n} X_i^k \qquad k = 1, \ldots, d$$

L'estimateur des moments $\hat{\theta}$ est solution d'un system de d équations

$$\mu_k(\hat{\theta}) = M_k \quad k = 1, \ldots, d.$$
$$\mu_k(\hat{\theta}_{\text{obs}}) = m_k \quad k = 1, \ldots, d.$$

$\bar{X}$ est un estimateur non-biaisé de $\mathbb{E}(X)$
Cette méthode est facile à appliquée, mais elle peut avoir des résulats moins précis que d'autres méthodes

7.2 Maximum de vraisemblance

Soit un échantillon aléatoire $X_{1:n} \sim X$. On pense que X a une pdf $f(x|\theta)$ où θ est un vecteur de paramètres aléatoires. On a

$$P(x \leq X \leq x+dx) \approx f(x|\theta)dx$$

Puisque $X_{i:n}$ sont indépendants, la probabilité d'observer les réalisations $x_{1:n}$ de $X_{1:n}$ est

$$\begin{aligned} &P(x_1 \leq X_1 \leq x_1+dx, \ldots, x_n \leq X_n \leq x_n+dx) \\ &= P(x_1 \leq X_1 \leq x_1+dx) \ldots P(x_n \leq X_n \leq x_n+dx) \\ &= \prod_{k=1}^{n} f(x_k|\theta)dx. \end{aligned}$$

La probabilité que l'échantillon observée a été générée par le modèle est proportionnel à la fonction de vraisemblance :

$$L(x_1, \ldots, x_n|\theta) := \Pi_{k=1}^{n} f(x_k|\theta)$$

Le MLE (maximum likelihood estimator) de θ est la valeur qui maximise la vraisemblance de l'échantillon observé

$$\hat{\theta} = \arg\max_{\theta} L(x_1, \ldots, x_n|\theta)$$

Propriétés de la MLE :

- Une MLE est asymptotiquement sans biais, et asynmptotiquement normale
- Une MLE est de variance minimum (par rapport à tout autre estimateur asymptotiquement sans biais)

En discret :

$$\hat{\theta} = \arg\max_{\theta} l(x_1, \ldots, x_n|\theta)$$

où $l(\cdot)$ est la somme des log de la pmf:

$$l(x_1, \ldots, x_n|\theta) = \sum_{i=1}^{n} \ln(p(x_k|\theta))$$

8 Simulations et Bootstrapping

8.1 Variable aléatoire continue

Soit une cdf continue $F(x)$ inversible, on définit

$$X = F^{-1}(U)$$

où U est une variable aléatoire continue et uniforme sur $[0,1]$. Alors X a $F(x)$ comme cdf

8.2 Bootstrapping

Le bootstrapping permet d'estimer la variance d'un estimateur. On a qu'un seul échantillon $X = (X_1, \ldots, X_n)$, on simule donc de nouveaux échantillons en repiochant dans l'échantillon initial.
Soit $X^* = (X_1^*, \ldots, X_n^*)$ tel que $P(X_i^* = X_j) = \frac{1}{n}$ pour $1 \leq i, j \leq n$.
$\hat{\theta}(X^*)$ est une réplication bootstrap de $\hat{\theta}(X)$. Le nombre d'échantillon bootstrap possible est $C_{2n-1}^n = \frac{(2n-1)!}{n!(n-1)!}$
La variance est obtenue en tirant M échantillon bootstrap :

$$\mathbf{X}^{*m} = (X_1^{*m}, \ldots, X_n^{*m}) m = 1 \ldots M$$

θ est estimé par

$$\bar{\theta}^* = \frac{1}{M} \sum_{m=1}^{M} \hat{\theta}(X^{*m})$$

où $\hat{\theta}(X^{*m})$ est la réplication bootstrap de $\hat{\theta}(X)$
La variance empirique de l'estimateur est :

$$S^2(\hat{\theta}) = \frac{1}{M-1} \sum_{m=1}^{M} \left(\hat{\theta}(X^{*m}) - \bar{\theta}^*\right)^2$$

9 Moyenne et déviation standard empirique

9.1 Propriétés de $\bar{X}$ et S^2 (moyenne et variance empirique)

Un **interval de confiance** pour μ au niveau $1-\alpha$ est un interval $[\mu_L, \mu_U]$ tel que μ est dans l'interval avec probabilitée de $1-\alpha$

Considérons n variables aléatoires $X_{i=1:n} \sim X$, $\mu = \mathbb{E}(X)$ et $\sigma^2 = \mathbb{V}(V)$. Le CLT (théorème central limite) dit que quel que soit la distribution de $X_{i=1:n}$, la moyenne empirique tend à une normale

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right) \quad \frac{\bar{X}-\mu}{\sqrt{\sigma^2/n}} \sim N(0,1)$$

Dans ce cas $\bar{X}$ est un estimateur de μ et σ^2 est connu, on peut trouver

$$P\left(z_{\alpha/2} \leq \frac{\bar{X}-\mu}{\sqrt{\sigma^2/n}} \leq z_{1-\alpha/2}\right) = 1-\alpha$$

Comme $-z_{1-\alpha/2} = z_{\alpha/2}$. L'interval de confiance $1-\alpha$ pour μ est

$$\left[\bar{X} - z_{1-\alpha/2}\sqrt{\sigma^2/n}; \bar{X} + z_{1-\alpha/2}\sqrt{\sigma^2/n}\right]$$

- $S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2$ est un estimateur non biaisé de $\mathbb{V}(X)$
- Si $X_i \sim \mathcal{N}(\mu, \sigma^2)$, S^2 et $\bar{X}$ sont indépendants, donc

$$(n-1)\frac{S^2}{\sigma^2} = \sum_{i=1}^{n}\left(\frac{X_i - \bar{X}}{\sigma}\right)^2 \sim \chi^2_{n-1}$$

Si $X \sim N(\mu, \sigma^2)$, alors S^2 est un estimateur de σ. Puisque $(n-1)\frac{S^2}{\sigma^2} \sim \chi^2_{n-1}$, on trouve que

$$P\left(\chi^2_{n-1,\alpha/2} \leq (n-1)\frac{S^2}{\sigma^2} \leq \chi^2_{n-1,1-\alpha/2}\right) = 1-\alpha$$

L'interval de confiance $1-\alpha$ est donc

$$\left[\frac{(n-1)}{\chi^2_{n-1,1-\alpha/2}}S^2; \frac{(n-1)}{\chi^2_{n-1,\alpha/2}}S^2\right]$$

Une variable variable aléatoire Student's T est $= T_n = \frac{Y}{\sqrt{Z/n}}$ où $Z \sim \chi^2_n$ et $Y \sim N(0,1)$, alors :
Si $X_i \sim \mathcal{N}(\mu, \sigma^2)$ alors le ratio suivant est une variable aléaatoire Student's T

$$\frac{\bar{X} - \mu}{\sqrt{\frac{S^2}{n}}} \sim t_{n-1}$$

Dans ce cas, $\bar{X}$ est un estimateur de μ, et σ est inconnu :

$$P\left(t_{n-1,\alpha/2} \leq \frac{\bar{X} - \mu}{\sqrt{S^2/n}} \leq t_{n-1,1-\alpha/2}\right) = 1 - \alpha$$

la Student's T est symmétrique : $-t_{n-1,\alpha/2} = t_{n-1,1-\alpha/2}$. L'interval de confidence $1 - \alpha$ est donc

$$\mu \in \left[\bar{X} - t_{n-1,1-\alpha/2}\sqrt{S^2/n}; \bar{X} + t_{n-1,1-\alpha/2}\sqrt{S^2/n}\right]$$

	Distribution of X	μ	σ^2	Statistics
$\bar{X}$	unknown and large n	ok	ok	$\frac{\bar{X}-\mu}{\sqrt{\sigma^2/n}} \sim \mathcal{N}(0,1)$
S^2	$\mathcal{N}(\mu, \sigma^2)$	-	ok	$(n-1)\frac{S^2}{\sigma^2} \sim \chi^2_{n-1}$
$\bar{X}$	$\mathcal{N}(\mu, \sigma^2)$	ok	-	$\frac{\bar{X}-\mu}{\sqrt{\frac{S^2}{n}}} \sim t_{n-1}$

9.2 Propriétés de $\bar{X}$ et S^2 à 2 populations normales

		μ_1, μ_2	σ_1^2, σ_2^2	Statistics
$\bar{X}_1 - \bar{X}_2$	$\sigma_1^2 \neq \sigma_2^2$	ok	ok	$\frac{(\bar{X}_1-\bar{X}_2)-(\mu_1-\mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1}+\frac{\sigma_2^2}{n_2}}} \sim \mathcal{N}(0,1)$
S^2_{pool}	$\sigma_1^2 = \sigma_2^2$	-	ok	$(n_1+n_2-2)\frac{S^2_{pool}}{\sigma^2} \sim \chi^2_{n_1+n_2-2}$.
S_1^2, S_2^2	$\sigma_1^2 \neq \sigma_2^2$	-	ok	$\frac{S_1^2\sigma_2^2}{S_2^2\sigma_1^2} \sim F_{n_1-1,\, n_2-1}$
$\bar{X}_1 - \bar{X}_2$	$\sigma_1^2 = \sigma_2^2$	ok	-	$\frac{(\bar{X}_1-\bar{X}_2)-(\mu_1-\mu_2)}{S_{pool}\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}} \sim t_{n_1+n_2-2}$

10 Test d'hypothèse à 1 population

Une **hypothèse** est une affirmation à propos d'un paramètre θ d'un échantillon aléatoire. L'**hypothèse nulle** notée $H_0 = \theta \in \Theta_0$ et dit l'affirmation à tester. L'hypothèse alternative est $H_1 = \theta \in \Theta_1$
La décision de rejeter ou non l'hypothèse nulle H_0 est basée sur l'échantillon. Il y a 4 cas possibles :

	Reality	
Decision	H_0 is true	H_1 is true
Accept H_0	Correct	Type 2 error
Reject H_0	Type 1 error	Correct

La probabilitée de faire une erreur de type 1 s'appelle le **niveau de signification** du test, et se dénote α

Si H_0 est "vous n'êtes pas malade" :

- Erreur type 1 : Vous n'êtes pas malade, mais le test est positif (faux positif)
- Erreur type 2 : Vous êtes malade, mais le test est négatif (faux négatif)

10.1 Introduction

La décision de rejeter l'hypothèse nulle est basée sur un test statistique, noté $T(\cdot)$.
Soit un échantillon $\mathbf{X} = \{X_1, \ldots, X_n\}$ d'observations, $T(\mathbf{X}) : \mathbb{R}^n \to \mathbb{R}$. $T(\mathbf{X})$ est tel que sa distribution est connue

- Pour un α choisi, on détermine la région de rejection $R_\alpha \in \mathbb{R}$, tel que $P(\text{type 1}) = \alpha$
- On calcule $t = T(\mathbf{x})$ la valeur observée de $T(\mathbf{X})$ sous H_0
- Décision : Si $t \in R_\alpha$, on rejette, sinon on accepte

10.2 Single mean test, θ^2 inconnu

Soit $X_1, \ldots, X_n \sim \mathcal{N}(\mu, \sigma^2)$ indépendants et identiquement distribués, avec variance inconnue. On test

$$H_0 : \mu = \mu_0$$

contre 3 alternatives :

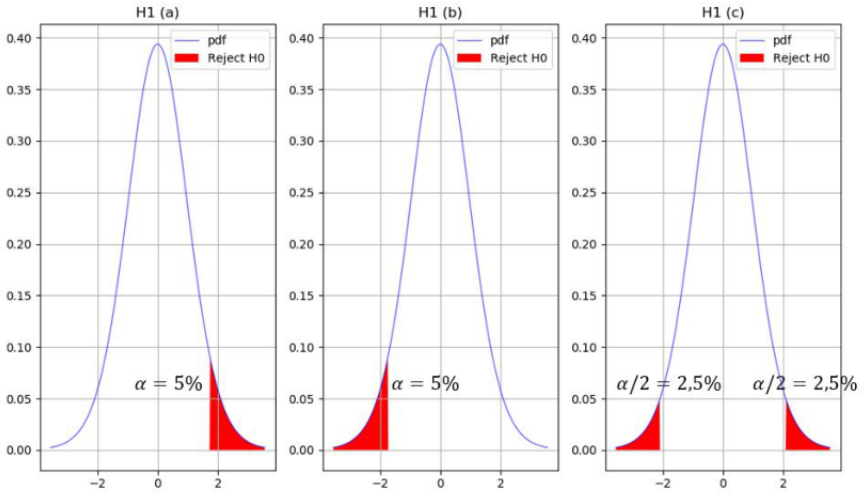
$$H_1 : \mu > \mu_0$$
$$H_1 : \mu < \mu_0$$
$$H_1 : \mu \neq \mu_0$$

Si H_0 est vrai, un bon choix pour la statistique de test est la Student's T :

$$T(\mathbf{X}) = \frac{\bar{X} - \mu_0}{\sqrt{\frac{S^2}{n}}} \sim t_{n-1}$$

On trouve une valeur critique c sous la supposition que H_0 est vrai :

- $P(T(\mathbf{X} > c | H_0 \text{ est vrai})) = \alpha$
- $P(T(\mathbf{X} < c | H_0 \text{ est vrai})) = \alpha$
- $P(T(\mathbf{X}) < -c \text{ ou } T(\mathbf{X}) > c | H_0 \text{ est vrai}) = \alpha$



On rejette H_0 au niveau α si

- Pour $H_1 : \mu > \mu_0$, on rejette H_0 si $T(\mathbf{x}) > t_{n-1,1-\alpha}$.
- Pour $H_1 : \mu < \mu_0$, on rejette H_0 si $T(\mathbf{x}) < t_{n-1,\alpha}$.
- Pour $H_1 : \mu \neq \mu_0$, on rejette H_0 si $T(\mathbf{x}) < t_{n-1,\alpha/2}$ ou $T(\mathbf{x}) > t_{n-1,1-\alpha/2}$.

10.3 Single variance test

Soit $X_1, \ldots, X_n \sim \mathcal{N}(\mu, \sigma^2)$ indépendants et identiquement distribués, avec variance inconnue. On test

$$H_0 : \sigma^2 = \sigma_0^2$$

contre 3 alternatives :

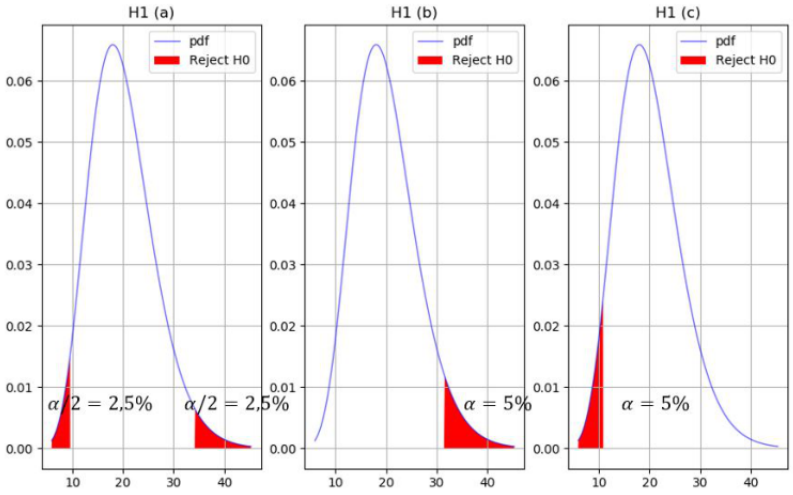
$$H_1 : \sigma^2 \neq \sigma_0^2$$

$$H_1 : \sigma^2 > \sigma_0^2$$

$$H_1 : \sigma^2 < \sigma_0^2$$

Un bon choix pour la statistique de test est la χ^2

$$T(\mathbf{X}) = (n-1)\frac{S^2}{\sigma_0^2} \sim \chi^2_{n-1}$$



On rejette H_0 au niveau α si

- Pour $H_1 : \sigma^2 \neq \sigma_0^2$, on rejette H_0 si $T(\mathbf{x}) < \chi^2_{n-1,\alpha/2}$ ou $T(\mathbf{x}) > \chi^2_{n-1,1-\alpha/2}$.
- Pour $H_1 : \sigma^2 > \sigma_0^2$, on rejette H_0 si $T(\mathbf{x}) > \chi^2_{n-1,1-\alpha}$
- Pour $H_1 : \sigma^2 < \sigma_0^2$, on rejette H_0 si $T(\mathbf{x}) < \chi^2_{n-1,\alpha}$

10.4 P-valeur

La **P-valeur** est le plus bas niveau de signification pour lequel les données indiques une rejection de l'hypothèse nulle

Soit $T(\mathbf{X})$ une statistique de test tel que les petites valeurs de T montre que H_0 est faux. Pour un échantillon donné $\mathbf{x}$, la p-valeur est :

$$p(\mathbf{x}) = P(T(\mathbf{X}) < T(\mathbf{x}) \mid H_0 \text{ est vrai})$$

Soit $T(\mathbf{X})$ une statistique de test tel que les grandes valeurs de T montre que H_0 est faux. Pour un échantillon donné $\mathbf{x}$, la p-valeur est :

$$p(\mathbf{x}) = P(T(\mathbf{X}) > T(\mathbf{x}) \mid H_0 \text{ est vrai})$$

Soit $T(\mathbf{X})$ une statistique de test **symmétrique autour de 0** tel que les petites et grandes valeurs de T montre que H_0 est faux. Pour un échantillon donné $\mathbf{x}$, la p-valeur est :

$$p(\mathbf{x}) = 2P(T(\mathbf{X}) > |T(\mathbf{x})| \mid H_0 \text{ est vrai})$$

Une petite p-valeur indique que H_0 est très peu probable, une grande p-valeur indique que H_0 est probable

11 Test d'hypothèse à 2 populations

11.1 Comparaison de 2 médiane

On considère 2 populations avec la même variance

$$\mathbf{X}_1 = \{X_{1,1}, \ldots, X_{1,n_1}\} \sim N(\mu_1, \sigma^2) \Rightarrow \bar{X}_1 \sim N\left(\mu_1, \frac{\sigma^2}{n_1}\right)$$
$$\mathbf{X}_2 = \{X_{2,1}, \ldots, X_{2,n_2}\} \sim N(\mu_2, \sigma^2) \Rightarrow \bar{X}_2 \sim N\left(\mu_2, \frac{\sigma^2}{n_2}\right)$$

On test si les deux échantillons ont la même médiane :

$$H_0 : \mu_1 - \mu_2 = \delta$$

Contre

$$H_1 : \mu_1 - \mu_2 > \delta$$
$$H_1 : \mu_1 - \mu_2 < \delta$$
$$H_1 : \mu_1 - \mu_2 \neq \delta$$

11.1.1 Cas 1 : σ connu

$$\bar{X}_1 - \bar{X}_2 \sim N\left(\mu_1 - \mu_2, \frac{\sigma^2}{n_1} + \frac{\sigma^2}{n_2}\right)$$

On utilise la statistique de test :

$$T(\mathbf{X}_1, \mathbf{X}_2) = \frac{(\bar{X}_1 - \bar{X}_2) - \delta}{\sigma\sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim \mathcal{N}(0,1)$$

On rejette $H_0 : \mu_1 - \mu_2 = \delta$ au niveau α si

- Pour $H_1 : \mu_1 - \mu_2 > \delta$, on rejette $T(\mathbf{x}_1, \mathbf{x}_2) > z_{1-\alpha}$
- Pour $H_1 : \mu_1 - \mu_2 < \delta$, on rejette $T(\mathbf{x}_1, \mathbf{x}_2) < z_{\alpha}$
- Pour $H_1 : \mu_1 - \mu_2 \neq \delta$, on rejette $T(\mathbf{x}_1, \mathbf{x}_2) < z_{\alpha/2}$ ou $T(\mathbf{x}_1, \mathbf{x}_2) > z_{1-\alpha/2}$

où z_α est le percentile de $Z \sim \mathcal{N}(0,1)(P(Z \leq z_\alpha) = \alpha)$

11.1.2 Cas 2 : σ connu

On utilise la statistique de test :

$$T(\mathbf{X}_1, \mathbf{X}_2) = \frac{(\bar{X}_1 - \bar{X}_2) - \delta}{S_{pool}\sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t_{n_1+n_2-2}$$

On rejette $H_0 : \mu_1 - \mu_2 = \delta$ au niveau α si

- Pour $H_1 : \mu_1 - \mu_2 > \delta$, on rejette $T(\mathbf{x}_1, \mathbf{x}_2) > t_{n_1+n_2-2,1-\alpha}$
- Pour $H_1 : \mu_1 - \mu_2 < \delta$, on rejette $T(\mathbf{x}_1, \mathbf{x}_2) < t_{n_1+n_2-2,\alpha}$
- Pour $H_1 : \mu_1 - \mu_2 \neq \delta$, on rejette $T(\mathbf{x}_1, \mathbf{x}_2) < t_{n_1+n_2-2,\alpha/2}$ ou $T(\mathbf{x}_1, \mathbf{x}_2) > t_{n_1+n_2-2,1-\alpha/2}$

où $t_{n_1+n_2-2,\alpha}$ est le percentile α d'une Student's T

11.2 Comparaison de 2 variances

On considère 2 populations de variance différente :

$$\mathbf{X}_1 = \{X_{1,1}, \ldots, X_{1,n}\} \sim \mathcal{N}(\mu_1, \sigma_1^2)$$
$$\mathbf{X}_2 = \{X_{2,1}, \ldots, X_{2,n}\} \sim \mathcal{N}(\mu_2, \sigma_2^2)$$

On test si les deux échantillons ont la même variance :

$$H_0 : \sigma_1 = \sigma_2$$

Contre

$$H_1 : \sigma_1 \neq \sigma_2$$
$$H_1 : \sigma_1 > \sigma_2$$
$$H_1 : \sigma_1 < \sigma_2$$

On utilise la statistique de test :

$$T(\mathbf{X}_1, \mathbf{X}_2) = \frac{S_1^2}{S_2^2} \sim F_{n_1-1,n_2-1}$$

On rejette $H_0 : \sigma_1^2 = \sigma_2^2$ au niveau α si

- Pour $H_1 : \sigma_1 \neq \sigma_2$, on rejette $T(\mathbf{x}_1, \mathbf{x}_2) < F_{n_1-1,n_2-1,\alpha/2}$ ou $T(\mathbf{x}_1, \mathbf{x}_2) > F_{n_1-1,n_2-1,1-\alpha/2}$
- Pour $H_1 : \sigma_1 > \sigma_2$, on rejette $T(\mathbf{x}_1, \mathbf{x}_2) < F_{n_1-1,n_2-1,1-\alpha}$
- Pour $H_1 : \sigma_1 < \sigma_2$, on rejette $T(\mathbf{x}_1, \mathbf{x}_2) < F_{n_1-1,n_2-1,\alpha}$

où $F_{n_1-1,n_2-1,\alpha}$ est le percentile α d'une Fisher

12 Régression linéaire

On observe n réalisations y_i de Y_i qui est lié à d facteurs $(x_{i,1},\dots,x_{i,d})^\intercal$ pour $i = 1,\dots,n$.

$$Y_i = \beta_0 + \beta_1 x_{i,1} + \cdots + \beta_d x_{i,d} + \varepsilon_i \quad i = 1,\dots,n$$

où $\varepsilon_i \sim \mathcal{N}(0,\sigma^2)$
Notation matricielle :

$$\mathbf{Y} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix} \qquad \beta = \begin{pmatrix} \beta_0 \\ \vdots \\ \beta_d \end{pmatrix} \qquad \mathbf{X} = \begin{pmatrix} 1 & x_{1,1} & \dots & x_{1,d} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n,1} & \dots & x_{n,d} \end{pmatrix}$$

$\mathbf{Y}$ est de taille n, β de taille $d+1$, et $\mathbf{X}$ de taille $n \times (d+1)$
Le vecteur de bruit est noté ε. Le vecteur de réalisation/observation de $\mathbf{Y}$ est $\mathbf{y}$. On obtient

$$\mathbf{Y} = \mathbf{X}\beta + \varepsilon$$

12.1 Moindre carré

La meilleur $\hat{y}$ prédiction de Y pour une valeur $\mathbf{x} = (1, x_1, \dots, x_d)^\intercal$ est

$$\hat{y} = \mathbb{E}(Y|\mathbf{x}) = \mathbf{x}^\top \beta.$$

Mais β et σ^2 sont inconnu, on va les estimer avec la maximisation de vraisemblance :
On a $\theta = (\beta, \sigma)$ et conditionnelement à $\mathbf{x}_i$, la réponse est normale :

$$Y_i|\mathbf{x}_i \sim \mathcal{N}(\mathbf{x}_i^\top \beta; \sigma^2) \quad i = 1,\dots,n$$

L'estimation de θ maximise la fonction de vraisemblance $\log$:

$$\begin{aligned} I(\theta) &= \sum_{i=1}^{n} \ln\left(\frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{1}{2}\frac{(y_i - \mathbf{x}_i^\top\beta)^2}{\sigma^2}\right)\right) \\ &= \sum_{i=1}^{n} \left(-\ln(\sigma\sqrt{2\pi}) - \frac{1}{2}\left(\frac{(y_i - \mathbf{x}_i^\top\beta)^2}{\sigma^2}\right)\right) \\ &\propto \underbrace{-\sum_{i=1}^{n}(y_i - \mathbf{x}_i^\top\beta)^2}_{(*)} \end{aligned}$$

Donc, pour un $\sigma > 0$ donné, l'estimation de β minimise $*$

$$\hat{\beta} = \arg_\beta \min(\mathbf{y} - \mathbf{X}\beta)^\intercal(\mathbf{y} - \mathbf{X}\beta) = \arg_\beta \min \sum_{i=1}^{n}(y_i - \mathbf{x}_i^\intercal\beta)^2$$

$$\hat{\beta} = (\mathbf{X}^\intercal \mathbf{X})^{-1} \mathbf{X}^\intercal \mathbf{y}$$

La meilleur prédiction de Y_i pour un vecteur de facteur $\mathbf{x}_i$ est

$$\hat{y}_i = \mathbf{x_i}^\intercal \hat{\beta} \qquad i = 1, \ldots, n$$

ou sous forme de matrice, si $\hat{\mathbf{y}} = (y_1, \ldots, y_n)^\intercal$, $\hat{\mathbf{y}} = \mathbf{X}\hat{\beta}$. Donc

$$\hat{\mathbf{y}} = \underbrace{\mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1}\mathbf{X}^\top}_{\mathbf{H}} \mathbf{y}$$

où $\mathbf{H}$ est la matrice chapeau, elle est symmétrique et idempotente :

$$\mathbf{H} = \mathbf{H}^\top \qquad ; \qquad \mathbf{HH} = \mathbf{H}$$

L'hypothèse de normalité ne fonctionne pas avec le moindre carré.

12.2 Régression linéaire simple

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

Alors

$$\{\hat{\beta}_0, \hat{\beta}_1\} = \arg\min_{\beta_0, \beta_1} \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i)^2,$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{S_{xy}}{S_{xx}}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Pour mesurer la qualitée du modèle, on sépare la variance des observations en

- Une variance expliquée par le modèle
- Une variance résiduelle

Plus la variance expliquée par le modèle est grande, mieux c'est
Soit $\hat{y}_i = \mathbf{x}_i^\top \hat{\beta}$ alors

$$\underbrace{\sum_{i=1}^{n} (y_i - \bar{y})^2}_{\text{SS Total}} = \underbrace{\sum_{i=1}^{n} (y_i - \hat{y}_i)^2}_{\text{SS Error}} + \underbrace{\sum_{i=1}^{n} (\hat{y}_i - \bar{y})^2}_{\text{SS Regression}}$$

(Pas dans le formulaire mais à connaitre)

13 Propriétés des coefficients de régression

$\hat{\beta}$ est un estimateur Gaussien non biaisé de β :

$$\hat{\beta} \sim \mathcal{N}\left(\beta, \sigma^2 \left(\mathbf{X}^\top \mathbf{X}\right)^{-1}\right)$$

Un estimateur non biaisé de σ^2 est

$$\hat{\sigma}^2 = \frac{1}{n-(d+1)} \underbrace{\left(\mathbf{Y} - \mathbf{X}\hat{\beta}\right)^\top \left(\mathbf{Y} - \mathbf{X}\hat{\beta}\right)}_{SSE}$$

et

$$(n-(d+1))\frac{\hat{\sigma}^2}{\sigma^2} = \frac{SSE}{\sigma^2} \sim \chi^2_{n-(d+1)}$$

13.1 Régression linéaire simple

$\hat{\beta}_0$ et $\hat{\beta}_1$ sont des estimateurs non biaisés ($\mathbb{E}(\hat{\beta}_{0 \text{ ou } 1}) = \beta_{0 \text{ ou } 1}$)
Si $\overline{x^2} = \frac{1}{n}\sum_{i=1}^n x_i^2$, leur variances sont

$$V(\hat{\beta}_0) = \frac{\sigma^2 \overline{x^2}}{S_{xx}} \quad ; \quad V(\hat{\beta}_1) = \frac{\sigma^2}{S_{xx}} \quad ; \quad C(\hat{\beta}_0, \hat{\beta}_1) = \frac{-\sigma^2 \bar{x}}{S_{xx}}$$

où $S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$ (mais σ^2 est inconnu, en pratique on le remplace par $\hat{\sigma}^2$, alors $\hat{\beta}_0$ et $\hat{\beta}_1$ deviennet des student's T)

13.2 Test de signification de régression linéaire

<188>
Puisque $SST = SSE + SSR$ et puisqu'une variabe aléatoire χ^2_n est une somme de n variables aléatoires :

$$\frac{SSR}{\sigma^2} = \frac{1}{\sigma^2}\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 \sim \chi^2_d$$

Alors, si $\beta_1 = \cdots = \beta_d = 0$:

$$F^* = \frac{SSR/d}{SSE/(n-d-1)} \sim F_{d,n-(d+1)}$$

<190>
Soit $c_{j,j}$