Statistiques et science des données (LEPL1109)

Réalisé par
Quentin Aubecq
avec l'aide de

–

relu par
Basile Audeval
Arthur Marot

2026

SYNTEX

Cette synthèse est une **synthèse collaborative**, écrite en LaTeX.
Elle est améliorée régulièrement, grâce à la participation de quelques étudiants.

La version que vous avez sous les yeux n'est sans doute pas la plus récente !

Alors...

...si vous désirez rester au courant des améliorations et corrections...
...si vous trouvez une erreur ou une imprécision...
...si vous souhaitez apporter votre aide à la réalisation...
...ou si vous voulez accéder à des synthèses d'autres cours...
...**rejoignez-nous** sur le serveur SYNTEX !

https://discord.gg/BdFgQbCTag

Remarque

Ce document est un support complémentaire au cours.
Nous déclinons toute responsabilité pour les éventuelles erreurs, omissions ou interprétations susceptibles de vous induire en erreur.
Les images, liens et autres contenus appartiennent exclusivement à leurs détenteurs respectifs.

Table des matières

Statistiques 5

1 Rappels 5
- 1.1 Variable aléatoire . . . 5
- 1.2 Distribution de probabilités . . . 5
- 1.3 Densité de probabilités . . . 5
- 1.4 Espérance . . . 6
- 1.5 Variance . . . 6
- 1.6 Loi des grands nombres (LLN) . . . 6
- 1.7 Quantiles . . . 7
- 1.8 Fonction d'une variable aléatoire . . . 7

2 Statistiques descriptives et outil de visualisation 8
- 2.1 Moyenne, Médiane et Quantiles . . . 8
- 2.2 Range, IQR, Outliers . . . 8
- 2.3 Analyse graphique . . . 8

3 Indépendance et indépendance linéaire 10
- 3.1 Indépendance . . . 10
- 3.2 Covariance . . . 10
- 3.3 Corrélation . . . 11

4 Variable aléatoire normale et théorème central limite 12
- 4.1 Standardisation . . . 12
- 4.2 Théorème Central Limite . . . 12

5 Autres variables aléatoires fondamentales 13
- 5.1 Distribution Chi-square (χ^2) . . . 13
- 5.2 Student's T . . . 13
- 5.3 Fisher-Snedecor . . . 13

6 Variable aléatoires multivariées 14
- 6.1 Distribution marginale . . . 14
- 6.2 Distribution conditionelle . . . 15
- 6.3 Espérances . . . 15
- 6.4 Espérance conditionnelle . . . 16
- 6.5 Covariance . . . 16
- 6.6 Indépendance . . . 17
- 6.7 Distribution normale multivariée . . . 17

7 Estimation 19
- 7.1 Méthode des moments . . . 19
- 7.2 Maximum de vraisemblance . . . 20

8 Simulations et Bootstrapping **20**
8.1 Variable aléatoire continue 20
8.2 Bootstrapping 21

9 Moyenne et déviation standard empirique **22**
9.1 Propriétés de $\bar{X}$ et S^2 (moyenne et variance empirique) 22
9.2 Propriétés de $\bar{X}$ et S^2 à 2 populations normales 23

10 Test d'hypothèse à 1 population **24**
10.1 Introduction 24
10.2 Single mean test, θ^2 inconnu 24
10.3 Single variance test 25
10.4 P-valeur 26

11 Test d'hypothèse à 2 populations **27**
11.1 Comparaison de 2 médiane 27
11.1.1 Cas 1 : σ connu 27
11.1.2 Cas 2 : σ connu 28
11.2 Comparaison de 2 variances 28

12 Régression linéaire **29**
12.1 Moindre carré 29
12.2 Régression linéaire simple 30

13 Propriétés des coefficients de régression **31**
13.1 Régression linéaire simple 31
13.2 Test de signification de régression linéaire 31
13.3 Test de β : Régression linéaire simple 32
13.4 Interval de prédiction, régression simple 33

14 Analyse de Variance (ANOVA) **33**

15 Modèles auto-régressif **33**
15.1 Time-series 33
15.2 Procédé autorégressif 34
15.3 Autoregression 34
15.4 Critère d'information 35

Data **36**

1 Supervised Learning **36**
1.1 Introduction 36
1.1.1 Notations et conventions 36
1.1.2 Regression vs Classification 36
1.1.3 Lier une entrée à une sortie 36

1.2 Modèle linéaire 37
1.2.1 Fitting 37
1.2.2 Classification avec un modèle linéaire 37
1.3 Méthode k-Nearest Neighbors 38
1.3.1 Classification 38
1.3.2 Erreur 38
1.3.3 Nombre effectif de paramètres 38
1.4 Méthode de reéchantillonage 39
1.4.1 Set de validation 39
1.4.2 Leave-One-Out Cross-Validation 40
1.4.3 K-Fold Cross-Validation 40
1.5 Plus sur les méthodes de classification 40
1.5.1 Régression logistique (1D) 40
1.5.2 Entrainement de la régression logistique 41

Statistiques

1 Rappels

1.1 Variable aléatoire

Une **variable aléatoire** est une fonction mesurable d'un espace Ω à un ensemble de nombres réels :

$$X : \Omega \to \mathbb{R}$$

On note $X(\omega) = x$

1.2 Distribution de probabilités

La **pmf** (probability mass function) $p(x)$ d'une variable aléatoire discrète, est une fonction qui associe une probabilité $P(X = x)$ à chaque valeur x de X

$$p(x) = P(X = x)$$

Si le domaine de X est $R = \{x_1, x_2, \dots\}$ alors $p(x) > 0 \; \forall x \in R$ et $p(x) = 0 \; \forall x \notin R$

$$\sum_i p(x_i) = 1$$

1.3 Densité de probabilités

La **pdf** (probability density function) $f(x) \geq 0$ d'une variable aléatoire continue X est une fonction tel que $\forall I \subset \mathbb{R}$

$$P(X \in I) = \int_I f(x)\, dx$$

La **cdf** (cumulative distribution function) $F(x)$ indique la probablité que $X \leq x$

$$F(x) = P(X \leq x)$$

$$F(x) = \sum_{i : x_i \leq x} p(x_i)$$

$$F(x) = \int_{-\infty}^{x} f(u)\, du$$

$$f(x) = \frac{d}{dx} F(x)$$

1.4 Espérance

L'**espérance** d'une variable aléatoire X est notée $\mathbb{E}(X) = \mu_x$

$$\mu_X = \sum_{x \in dom(X)} xp(x)$$

$$\mu_x = \int_{-\infty}^{\infty} xf(x)\,dx$$

Propriétés :

- $\mathbb{E}(X+Y) = \mathbb{E}(X) + \mathbb{E}(Y)$
- $\mathbb{E}(aX+b) = a\mathbb{E}(X) + b$
- $\mathbb{E}(h(X)) = \sum_{x \in dom(X)} h(x)p(x)$
- $\mathbb{E}(h(X)) = \int_{-\infty}^{\infty} h(x)f(x)\,dx$

1.5 Variance

La **variance** d'une variable aléatoire X est

$$\mathbb{V}ar(X) = \mathbb{V}(X) = \sigma_X^2$$

$$\sigma_X^2 = \mathbb{E}\left((X - \mu_X)^2\right)$$

Avec σ_X la déviation standard
Propriétés :

- $\mathbb{V}(X) = \mathbb{E}(X^2) - (\mathbb{E}(X))^2$
- $\mathbb{V}(a) = 0$
- $\mathbb{V}(a+bX) = b^2\mathbb{V}(X)$
- $\mathbb{V}(X+Y) \neq \mathbb{V}(X) + \mathbb{V}(Y)$ Sauf si X et Y indépendant

Si on observe n événements $(x_k)_{k=1\ldots,n}$, la variance empirique est estimée avec

$$\sigma_X^2 \approx \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1} = s^2$$

1.6 Loi des grands nombres (LLN)

Soit $X_{i=1,\ldots,n}$ une séquence d'événements aléatoires indépendants avec la même espérance $\mu_X = \mathbb{E}(X_i)$ et de variance σ_X^2. Lorsque $n \to \infty$, la moyenne $\bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i$ converge vers μ_X

$$\forall \varepsilon > 0 \qquad \lim_{n\to\infty} P(|\bar{X}_n - \mu_X| \geq \varepsilon) = 0$$

On note $\bar{X}_n \xrightarrow{p} \mu_X$

1.7 Quantiles

Soit p une probabilité et X une variable aléatoire. Le nombre q_p satisfaisant la relation

$$P(X \leq q_p) = p$$

est le quantile d'ordre p pour X. Si X est continu et si son cdf $F(x)$ est inversible, alors $q_p = F^{-1}(p)$

1.8 Fonction d'une variable aléatoire

Soit X une variable aléatoire continue de densité (pdf) $f_X(x)$. La densité de $Y = a + bX$ est donnée par

$$f_Y(y) = \frac{1}{|b|} f_X\left(\frac{y-a}{b}\right)$$

2 Statistiques descriptives et outil de visualisation

- **Population** : Collection de tous les résultats possibles qui nous intéressent
- **Échantillon** : Un subset de population
- **Statistiques** descriptives : Branche des statistiques qui s'occupe de l'organisation et de l'affichage des données

2.1 Moyenne, Médiane et Quantiles

- **Moyenne** :

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

- **Médiane** : La valeur $q_{0.5}$ telle que la moitié des résultats sont en dessous, et l'autre moitiée au dessus
- **Quantile** : On trie les résultats par ordre croissant $x_{(1)} \leq \cdots \leq x_{(n)}$, on a

$$q_p = x_{(1+(n-1)p)}$$

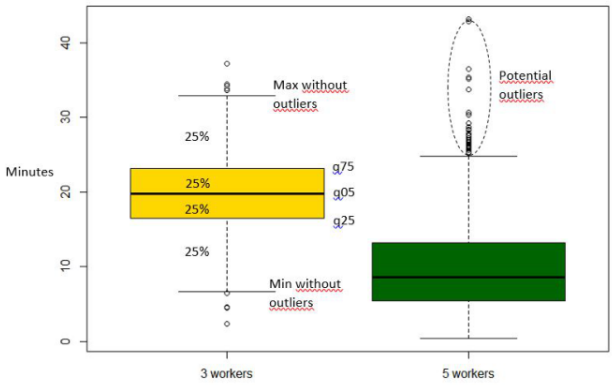
2.2 Range, IQR, Outliers

- **Range** : $x_{max} - x_{min}$
- **Inter-Quartile Range (IQR)** : La différence entre des quartiles symétriques, par exemple $IQR = q_{0.75} - q_{0.25}$
- **Outliers** : Observations qui sont trop loin du reste des données, qui pourraient être due à des erreurs

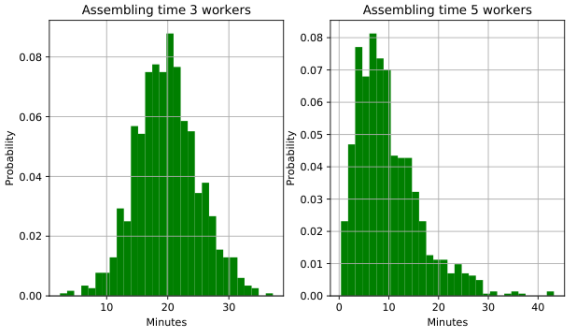
  Une observation est considérée comme susbecte si elle est plus bas que $q_{0.25} - 1.5 \times IQR$ ou plus haut que $q_{0.75} + 1.5 \times IQR$

2.3 Analyse graphique

Boxplot :


Minutes
0
10
20
30
40
Max without outliers
25%
25%
25%
25%
g75
g05
g25
Min without outliers
Potential outliers
3 workers
5 workers

Histogram :


Assembling time 3 workers
Probability
0.00
0.02
0.04
0.06
0.08
10
20
30
Minutes
Assembling time 5 workers
Probability
0.00
0.01
0.02
0.03
0.04
0.05
0.06
0.07
0.08
0
10
20
30
40
Minutes

3 Indépendance et indépendance linéaire

3.1 Indépendance

Deux variables aléatoires X et Y sont **indépendantes** ($X \perp\!\!\!\perp Y$) si $\forall A, B \in \mathbb{R}$:

$$P(X \in A, Y \in B) = P(X \in A)P(Y \in B)$$

Conséquences :

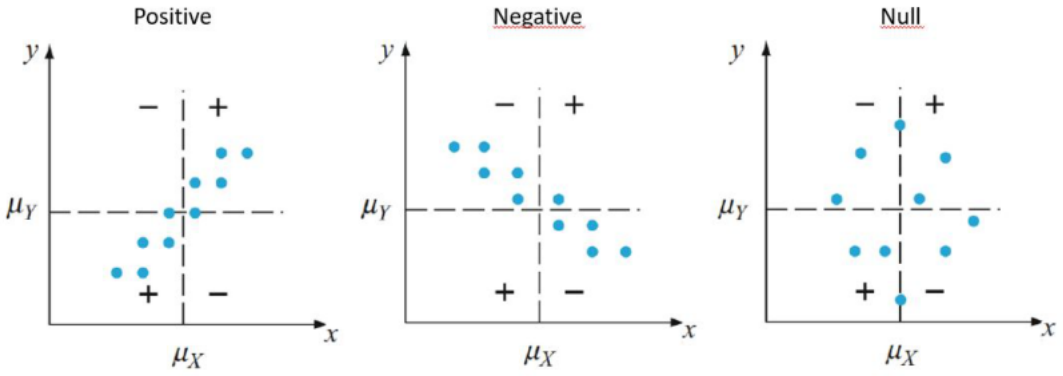
- $p(x,y) = p_X(x)p_Y(y)$ quand X et Y sont discrets
- $f(x,y) = f_X(x)f_Y(y)$ quand X et Y sont continus

3.2 Covariance

$$\begin{aligned}\sigma_{XY} &= \mathbb{C}ov(X,Y) = \mathbb{E}[(X-\mu_X)(Y-\mu_Y)] \\ &= \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y) \\ &= \mu_{XY} - \mu_x\mu_Y\end{aligned}$$

Si on observe n événements $(x_k)_{k=1,\dots,n}$ et $(y_k)_{k=1,\dots,n}$, la covariance empirique est estimée avec

$$\sigma_{XY} \approx s_{XY} = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})$$



Propriétés :

- $\mathbb{C}(X,Y) = \mathbb{C}(Y,X)$
- $\mathbb{C}(X,X) = \mathbb{V}(X)$ et $\mathbb{C}(a,X) = 0 \quad \forall a \in \mathbb{R}$
- Si $X \perp\!\!\!\perp Y$ alors $\mathbb{C}(X,Y) = 0$
- $\mathbb{C}(aX + bY, Z) = a\mathbb{C}(X,Z) + b\mathbb{C}(Y,Z)$

- $\boxed{\mathbb{V}(aX+bY) = a^2\mathbb{V}(X) + b^2\mathbb{V}(Y) + 2ab\mathbb{C}(X,Y)}$

(Attention si $\mathbb{C}(X,Y) = 0 \not\Rightarrow X \perp\!\!\!\perp Y$)

La covariance est une mesure de la dépendance linéaire entre deux variables aléatoires.
La taille d'une covariance dépend de l'échelle des variables : $\mathbb{C}(aX,Y) = a\mathbb{C}(X,Y)$

3.3 Corrélation

La **corrélation** entre X et Y est défini comme

$$\rho_{XY} = \frac{\mathbb{C}(X,Y)}{\sqrt{\mathbb{V}(X)\mathbb{V}(Y)}} = \frac{\sigma_{XY}}{\sigma_X \sigma_Y}$$

L'inégalité de Cauchy Schwarz donne
$|\sigma_{XY}| \leq \sigma_X \sigma_Y$ avec égalité si et seulement si $Y = aX + b$
On en déduit les propriétés suivantes :

- ρ_{XY} est invariant à l'échelle
- $-1 \leq \rho_{XY} \leq 1$
- Si $\rho_{XY} = 1$ alors $Y = a + bX$ avec $b \in \mathbb{R}^+$ (Y proportionnel à X)
- Si $\rho_{XY} = -1$ alors $Y = a + bX$ avec $b \in \mathbb{R}^-$ (Y inversément proportionnel à X)

La corrélation est une mesure the la dépendance linéaire entre deux variables aléatoires.
Elle n'a pas d'unité et est dans $[-1,1]$

On peut estimer la correlation de manière empirique :

$$\rho_{XY} \approx r_{XY} = \frac{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2}\sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(y_i - \bar{y})^2}}$$

4 Variable aléatoire normale et théorème central limite

Une variable aléatoire suit une **distribution normale** si sa densité est donnée par

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right) \quad x \in \mathbb{R}$$

avec $\mu \in \mathbb{R}$ et $\sigma \in \mathbb{R}^+$ des paramètres. On note $X \sim \mathcal{N}(\mu, \sigma^2)$

$$\mathbb{E}(X) = \mu \quad , \quad \mathbb{V}(X) = \sigma^2$$

$$m_X(t) := \mathbb{E}\left(e^{tX}\right) = \exp\left(\mu t + \frac{1}{2}t^2\sigma^2\right)$$

$m_X(t)$ fonction génératrice des moments $\left.\frac{\partial^n m_X(t)}{\partial t^n}\right|_{t=0} = \mathbb{E}(X^n)$

4.1 Standardisation

- Si $X \sim \mathcal{N}(\mu, \sigma^2)$, alors $a + bX \sim \mathcal{N}(a + b\mu, b^2\sigma^2)$
- Si $X \sim \mathcal{N}(\mu_x, \sigma_x^2)$ et $Y \sim \mathcal{N}(\mu_y, \sigma_y^2)$ avec la covariance $\sigma_{x,y} = \mathbb{C}(X, Y)$, alors
$$aX + bY \sim \mathcal{N}(a\mu_x + b\mu_y, a^2\sigma_x^2 + b^2\sigma_y^2 + 2ab\sigma_{x,y})$$
- Si $X \sim \mathcal{N}(\mu, \sigma^2)$ alors $\frac{X-\mu}{\sigma} \sim Z = \mathcal{N}(0, 1)$ et

$$P(X \leq x) = P\left(Z \leq \frac{x-\mu}{\sigma}\right)$$

4.2 Théorème Central Limite

Soit $X_1, \ldots, X_n$ une séquence de variables aléatoires indépendantes et identiquement distribuées, avec $\mathbb{E}(X_i) = \mu$ et $\mathbb{V}(X_i) = \sigma^2$ lorsque $n \to \infty$

$$Z_n = \sqrt{n}\frac{\bar{X}_n - \mu}{\sigma} \xrightarrow{d} Z \sim \mathcal{N}(0, 1)$$

$$P(Z_n \leq z) \xrightarrow{n\to\infty} P(Z \leq z) \forall z$$

5 Autres variables aléatoires fondamentales

5.1 Distribution Chi-square (χ^2)

Une variable aléatoire X définie sur $\mathbb{R}^+$ suit une distribution χ^2 de paramètre n si sa densitée (pdf) est donnée par

$$\frac{1}{2^{n/2}\Gamma(n/2)} x^{n/2-1} e^{-x/2}$$

$$\text{où } \Gamma(\alpha) = \int_0^\infty t^{\alpha-1} e^{-t} dt \quad \text{(Fonction Gamma).}$$

On a $\mathbb{E}(X) = n$ et $\mathbb{V}(X) = 2n$

5.2 Student's T

Soit Z et Y deux variables aléatoires indépendantes $Z \sim \mathcal{N}(0,1)$ et $Y \sim \chi^2_n$ alors

$$T_n = \frac{Z}{\sqrt{Y/n}}$$

est la variable aléatoire **Student'T** avec n degrés de liberté. Sa pdf est

$$f_{T_n}(t) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi}\Gamma\left(\frac{n}{2}\right)} \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}} \qquad t \in \mathbb{R}$$

5.3 Fisher-Snedecor

Soit X et Y deux variables aléatoires χ^2 indépendantes avec n_1 et n_2 degrés de liberté, alors

$$F_{n_1,n_2} = \frac{X/n_1}{Y/n_2}$$

suis la distribution de **Fisher-Snedecor**, sa pdf est

$$f_{F_{n1,n2}}(z) = \frac{\Gamma\left(\frac{n_1+n_2}{2}\right)\left(\frac{n_1}{n_2}\right)^{\frac{n_1}{2}} z^{\left(\frac{n_1}{2}-1\right)}}{\Gamma\left(\frac{n_1}{2}\right)\Gamma\left(\frac{n_2}{2}\right)\left(1+\frac{n_1}{n_2}x\right)^{\frac{n_1+n_2}{2}}} t \in \mathbb{R}$$

6 Variable aléatoires multivariées

Un **vecteur aléatoire** $\mathbf{X} = (X_1, \ldots, X_d)^\top$ est une application $\Omega \to \mathbb{R}^p$

Si $X_1, \ldots, X_d$ sont continues, la fonction de distribution de probablité multivariée (pdf) est

$$\begin{aligned} P(\mathbf{X} \leq \mathbf{x}) &= P(X_1 \leq x_1, \ldots, X_d \leq x_d) \\ &= \int_{-\infty}^{x_d} \cdots \int_{-\infty}^{x_1} f(u_1, \ldots, u_d)\, du_1 \ldots du_d \end{aligned}$$

Si $X_1, \ldots, X_d$ sont discrètes, la fonction de masse multivariée (pmf) est

$$\begin{aligned} P(\mathbf{X} = \mathbf{x}) &= P(X_1 = x_1, \ldots, X_d = x_d) \\ &= p(x_1, \ldots, x_d). \end{aligned}$$

6.1 Distribution marginale

Continu :
Soit $\mathbf{X} = (X_1, \ldots, X_d)^\top$ un vecteur aléatoire continu. La pdf marginale de X_k pour $k = 1, \ldots, d$ est

$$\begin{aligned} P(X_k \leq x) &= P(X_1 \leq \infty, \ldots, X_k \leq x, \ldots, X_d \leq \infty) \\ &= \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{x} \cdots \int_{-\infty}^{+\infty} f(u_1, \ldots, u_d) du_1 \ldots du_d \end{aligned}$$

On a

$$\begin{aligned} f_{X_k}(x) &= \frac{\partial}{\partial x} P(X_k \leq x) \\ &= \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} f(u_1, \ldots, u_{k-1}, x, u_{k+1}, \ldots, u_d) du_1 \ldots du_d. \end{aligned}$$

La distribution bivariée de X_i et X_j est

$$f_{X_i, X_j}(x_i, x_j) = \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} f(u_1, \ldots, X_i, \ldots, X_j, \ldots, u_d)\, du_1 \ldots du_d$$

Discret :
Soit $\mathbf{X} = (X_1, \ldots, X_d)^\top$ un vecteur aléatoire discret. La pmf marginale de X_k pour $k = 1, \ldots, d$ est

$$P(X_k = x_{k,j}) = \sum_{i_d=1}^{m_d} \cdots \sum_{i_{k+1}=1}^{m_{k+1}} \sum_{i_{k-1}=1}^{m_{k-1}} \cdots \sum_{i_1=1}^{m_1} p(x_{1,i_1}, \ldots, x_{k,j}, \ldots, x_{d,i_d})$$
$$= p_{\bullet,\ldots,j,\ldots,\bullet}$$

6.2 Distribution conditionelle

Pour un petit Δ, la pdf peut être interprétée comme une probabilitée

$$f(x_1, \ldots, x_d)\Delta^d \approx P(x_1 \leq X_1 \leq x_1 + \Delta, \ldots, x_d \leq X_d \leq x_d + \Delta)$$

Le théorème de Bayes dit que pour tout sous-ensemble A et B de $\mathbb{R}^p$, la probabilité que $X \in A$, en sachant que $X \in B$ est :

$$P(\mathbf{X} \in A | \mathbf{X} \in B) = \frac{P(\mathbf{X} \in A \cap B)}{P(\mathbf{X} \in B)}$$

Si $d = 2$, on défini la pdf conditionelle de la variable aléatoire $X_1|X_2$:

$$f_{X_1|X_2}(x_1|x_2) = \frac{f(x_1, x_2)}{f_{X_2}(x_2)}$$

$$f_{X_1|X_2}(x_1|x_2)\Delta \approx P(x_1 \leq X_1 \leq x_1 + \Delta | X_2 = x_2)$$

Si on partitionne $\mathbf{X}$ en $\mathbf{X}_A|\mathbf{X}_B$, la pdf conditionnelle est donnée par

$$f_{\mathbf{X}_A|\mathbf{X}_B}(\mathbf{x}_A|\mathbf{x}_B) = \frac{f((\mathbf{x}_A, \mathbf{x}_A))}{f_{\mathbf{X}_B}(\mathbf{x}_B)}$$

$$p_{\mathbf{X}_A|\mathbf{X}_B}(\mathbf{x}_A|\mathbf{x}_B) = \frac{p((\mathbf{x}_A, \mathbf{x}_B))}{p_{\mathbf{X}_B}(\mathbf{x}_B)}$$

6.3 Espérances

Continu :

$$\mathbb{E}(\mathbf{X}) = \begin{pmatrix} \mathbb{E}(X_1) \\ \vdots \\ \mathbb{E}(X_d) \end{pmatrix} = \begin{pmatrix} \int_{-\infty}^{+\infty} x f_1(x)\, dx \\ \vdots \\ \int_{-\infty}^{+\infty} x f_d(x)\, dx \end{pmatrix}$$

Discret :

$$\mathbb{E}(\mathbf{X}) = \begin{pmatrix} \mathbb{E}(X_1) \\ \vdots \\ \mathbb{E}(X_d) \end{pmatrix} = \begin{pmatrix} \sum_{j=1}^{m_1} x_{1,j} p_{j,\bullet,\ldots,\bullet} \\ \vdots \\ \sum_{j=1}^{m_d} x_{d,j} p_{\bullet,\ldots,\bullet,j} \end{pmatrix}$$

Propriétés :

- $\mathbb{E}(\alpha\mathbf{X} + \beta\mathbf{Y}) = \alpha\mathbb{E}(\mathbf{X}) + \beta\mathbb{E}(\mathbf{Y})$
- Si $\mathbf{X}$ et $\mathbf{Y}$ indépendants : $\mathbb{E}(\mathbf{X}^\top\mathbf{Y}) = \mathbb{E}(\mathbf{X})^\top\mathbb{E}(\mathbf{Y})$

6.4 Espérance conditionnelle

On divise $\mathbf{X}$ en deux vecteurs disjoints $\mathbf{X}_A$ et $\mathbf{X}_B$.
L'espérance conditionnelle de $\mathbf{X}_A$ si $\mathbf{X}_B = \mathbf{x}_B$ est

$$\mathbb{E}(\mathbf{X}_A|\mathbf{X}_B = \mathbf{x}_B) = \int_{u\in A} \mathbf{u} f_{\mathbf{X}_A|\mathbf{X}_B}(\mathbf{u}|\mathbf{x}_B) d\mathbf{u},$$
$$\mathbb{E}(\mathbf{X}_A|\mathbf{X}_B = \mathbf{x}_B) = \sum_{u\in A} \mathbf{u} p_{\mathbf{X}_A|\mathbf{X}_B}(\mathbf{u}|\mathbf{x}_B).$$

On a

$$\mathbb{E}(\mathbf{X}_A) = \mathbb{E}(\mathbb{E}(\mathbf{X}_A|\mathbf{X}_B)).$$

Propriété :
Soit $\mathbf{X}_A$ et $\mathbf{X}_B$ des partitions de $\mathbf{X}$. La fonction $g(.)$ solution de

$$\min_g \mathbb{E}\left((\mathbf{X}_A - g(\mathbf{X}_B))^2\right),$$

est $g(\mathbf{X}_B) = \mathbb{E}(\mathbf{X}_A|\mathbf{X}_B)$

6.5 Covariance

Soit $\mu = (\mu_1, \ldots, \mu_d)^\top = \mathbb{E}(\mathbf{X})$ le d-vecteur des espérances.
La **matrice de covariance** de $\mathbf{X}$ est une matrice $d \times d$

$$\begin{aligned} \Sigma &= \mathbb{E}\left((\mathbf{X} - \mu)(\mathbf{X} - \mu)^{\mathrm{T}}\right) \\ &= \mathbb{E}\left(\mathbf{X}\mathbf{X}^{\mathrm{T}}\right) - \mu\mu^{\mathrm{T}} \end{aligned}$$

Soit $\mathbf{X}$ d'espérance μ et covariance $\sum_{\mathbf{X}}$.
Soit M une matrice $p \times d$ et $\mathbf{m}$ un vecteur de taille p.
Alors $\mathbf{Y} = M\mathbf{X} + \mathbf{m}$ est un vecteur aléatoire de taille p tel que

$$\mu_{\mathbf{Y}} = M\mu + \mathbf{m}$$
$$\Sigma_{\mathbf{Y}} = M\Sigma_X M^\top$$

6.6 Indépendance

Les variables aléatoires X_k pour $k = 1, \ldots, d$ sont indépendants ssi la pdf est le produit des pdfs marginaux

$$f(x_1, \ldots, x_d) = \prod_{k=1}^{d} f_{X_k}(x_k).$$

$$p(x_1, \ldots, x_d) = \prod_{k=1}^{d} P(X_k = x_k).$$

Conséquence 1 :

$$\mathbb{E}(\mathbf{X}_A | \mathbf{X}_B = x_B) = \mathbb{E}(\mathbf{X}_A)$$

Conséquence 2 :
La matrice de covariance est diagonal puisque
$f_{X_i,X_j}(x_i, x_j) = f_{X_i}(x_i) f_{X_j}(x_j)$:

$$\begin{aligned}\sigma_{i,j} &= \int\int (x_i - \mu_i)(x_j - \mu_j) f_{X_i,X_j}(x_i, x_j)\, dx_i dx_j \\ &= \underbrace{\int (x_i - \mu_i) f_{X_i}(x_i)\, dx_i}_{=0} \underbrace{\int (x_j - \mu_j) f_{X_j}(x_j)\, dx_j}_{=0}\end{aligned}$$

6.7 Distribution normale multivariée

$\mathbf{X}$ suit une **distribution normale multivariée** $\mathcal{N}(\mu, \sum)$ si sa pdf pour $\mathbf{x} = (x_1, \ldots, x_d) \in \mathbb{R}^d$

$$f(x_1, \ldots, x_d) = \frac{1}{\sqrt{det(2\pi\Sigma)}} \exp\left(-\frac{1}{2} (\mathbf{x} - \mu) \Sigma^{-1} (\mathbf{x} - \mu)^\top \right)$$

avec Σ la matrice de covariance $d \times d$, et $\mu = (\mu_1, \ldots, \mu_d)$ le vecteur moyenne

Propriétés :

- Σ est diagonale $\Leftrightarrow X_1, \ldots, X_d$ sont indépendants
- Si $\mathbf{m} \in \mathbb{R}^d$ et $\mathbf{M}$ une matrice $d \times d$ alors

  $$\mathbf{Y} = \mathbf{m} + \mathbf{M}\mathbf{X}$$

  est une normale multivariée $\mathcal{N}(\mu_\mathbf{Y}, \Sigma_\mathbf{Y})$ avec comme moyenne et covariance :

  $$\mu_\mathbf{Y} = \mathbf{m} + \mathbf{M}\mu$$

  $$\Sigma_Y = \mathbf{M}\Sigma\mathbf{M}^\top$$

Conséquences

- $\mathbf{Y} = \Sigma^{-1/2}\mathbf{X} - \mu$ est $\mathcal{N}(0, I_d)$ (avec $\Sigma^{1/2}$ tel que $\Sigma^{1/2}\Sigma^{1/2\top} = \Sigma$)
- $X_j \sim \mathcal{N}(\mu_j, \sigma_{jj})$

Soit $\mathbf{X} = (\mathbf{X}_A, \mathbf{X}_B)^\top \sim \mathcal{N}(\mu, \Sigma)$ avec $\mathbf{X}_A$ et $\mathbf{X}_B$ de dimensions p et $d-p$. On a

$$\mu = \begin{pmatrix} \mu_A \\ \mu_B \end{pmatrix} \qquad \Sigma = \begin{pmatrix} \Sigma_{AA} & \Sigma_{AB} \\ \Sigma_{BA} & \Sigma_{BB} \end{pmatrix}$$

On a

$$\mu_{B|A}(\mathbf{x}_A) = \mu_B + \Sigma_{BA}\Sigma_{AA}^{-1}(\mathbf{x}_A - \mu_A)$$
$$\Sigma_{B|A}(\mathbf{x}_A) = \Sigma_{BB} - \Sigma_{BA}\Sigma_{AA}^{-1}\Sigma_{AB}$$

et

$$\mathbf{X}_A \sim \mathcal{N}(\mu_A, \Sigma_{AA})$$

et

$$\mathbf{X}_B|\mathbf{X}_A = \mathbf{x}_A \sim \mathcal{N}(\mu_{B|A}(\mathbf{x}_A), \Sigma_{B|A})$$

7 Estimation

Si $X_i \sim (\mu, \sigma)$ alors $\theta = (\mu, \sigma) \in \Theta = \mathbb{R}_+^2$, comment estimer θ
Un **estimateur** de θ, noté $\hat{\theta}$ est une fonction $h(.)$

$$\hat{\theta} = h(X_1, \ldots, X_n) \in \Theta$$

Une **estimation** de θ est une valeur observée d'un **estimateur** calculé à partir d'un échantillon $x_1, \ldots, x_n$

$$\hat{\theta}_{\text{obs}} = h(x_1, \ldots, x_n) \in \Theta$$

L'estimateur est une variable aléatoire
$\hat{\theta}$ est un estimateur non-biaisé de θ si

$$\mathbb{E}(\widehat{\theta}) = \mathbb{E}(h(X_1, \ldots, X_n)) = \theta.$$

Le **biais** est la différence entre l'espérance et la vrai valeur inconnue :

$$B(\hat{\theta}) = \mathbb{E}(\hat{\theta}) - \theta$$

La MSE (mean sqaure error) mesure l'erreur moyenne

$$MSE(\hat{\theta}) = \mathbb{E}\left(\left(\hat{\theta} - \theta\right)^2\right) = B(\hat{\theta})^2 + \mathbb{V}(\hat{\theta})$$

7.1 Méthode des moments

On observe $x_1, \ldots, x_n$ résultats de $X_{i=1:n}$. On pense que $X_{i=1:n}$ a la même pdf $f(x|\theta)$ que X.
Pour estimer $\theta \in \mathbb{R}^d$, on match les d moments

$$\mu_k(\theta) = \mathbb{E}\left((X)^k\right) \qquad k = 1, \ldots, d$$

avec les d moments empiriques

$$M_k = \frac{1}{n}\sum_{i=0}^{n} X_i^k \qquad k = 1, \ldots, d$$

L'estimateur des moments $\hat{\theta}$ est solution d'un system de d équations

$$\mu_k(\hat{\theta}) = M_k \quad k = 1, \ldots, d.$$
$$\mu_k(\hat{\theta}_{\text{obs}}) = m_k \quad k = 1, \ldots, d.$$

$\bar{X}$ est un estimateur non-biaisé de $\mathbb{E}(X)$
Cette méthode est facile à appliquée, mais elle peut avoir des résulats moins précis que d'autres méthodes

7.2 Maximum de vraisemblance

Soit un échantillon aléatoire $X_{1:n} \sim X$. On pense que X a une pdf $f(x|\theta)$ où θ est un vecteur de paramètres aléatoires. On a

$$P(x \leq X \leq x+dx) \approx f(x|\theta)dx$$

Puisque $X_{i:n}$ sont indépendants, la probabilité d'observer les réalisations $x_{1:n}$ de $X_{1:n}$ est

$$\begin{aligned} &P(x_1 \leq X_1 \leq x_1+dx, \ldots, x_n \leq X_n \leq x_n+dx) \\ &= P(x_1 \leq X_1 \leq x_1+dx) \ldots P(x_n \leq X_n \leq x_n+dx) \\ &= \prod_{k=1}^{n} f(x_k|\theta)dx. \end{aligned}$$

La probabilité que l'échantillon observée a été générée par le modèle est proportionnel à la fonction de vraisemblance :

$$L(x_1, \ldots, x_n|\theta) := \Pi_{k=1}^{n} f(x_k|\theta)$$

Le MLE (maximum likelihood estimator) de θ est la valeur qui maximise la vraisemblance de l'échantillon observé

$$\hat{\theta} = \arg\max_{\theta} L(x_1, \ldots, x_n|\theta)$$

Propriétés de la MLE :

- Une MLE est asymptotiquement sans biais, et asynmptotiquement normale
- Une MLE est de variance minimum (par rapport à tout autre estimateur asymptotiquement sans biais)

En discret :

$$\hat{\theta} = \arg\max_{\theta} l(x_1, \ldots, x_n|\theta)$$

où $l(\cdot)$ est la somme des log de la pmf:

$$l(x_1, \ldots, x_n|\theta) = \sum_{i=1}^{n} \ln(p(x_k|\theta))$$

8 Simulations et Bootstrapping

8.1 Variable aléatoire continue

Soit une cdf continue $F(x)$ inversible, on définit

$$X = F^{-1}(U)$$

où U est une variable aléatoire continue et uniforme sur $[0,1]$. Alors X a $F(x)$ comme cdf

8.2 Bootstrapping

Le bootstrapping permet d'estimer la variance d'un estimateur. On a qu'un seul échantillon $X = (X_1, \ldots, X_n)$, on simule donc de nouveaux échantillons en repiochant dans l'échantillon initial.
Soit $X^* = (X_1^*, \ldots, X_n^*)$ tel que $P(X_i^* = X_j) = \frac{1}{n}$ pour $1 \leq i, j \leq n$.
$\hat{\theta}(X^*)$ est une réplication bootstrap de $\hat{\theta}(X)$. Le nombre d'échantillon bootstrap possible est $C_{2n-1}^n = \frac{(2n-1)!}{n!(n-1)!}$
La variance est obtenue en tirant M échantillons bootstrap :

$$\mathbf{X}^{*m} = (X_1^{*m}, \ldots, X_n^{*m}) m = 1 \ldots M$$

θ est estimé par

$$\bar{\theta}^* = \frac{1}{M} \sum_{m=1}^{M} \hat{\theta}(X^{*m})$$

où $\hat{\theta}(X^{*m})$ est la réplication bootstrap de $\hat{\theta}(X)$
La variance empirique de l'estimateur est :

$$S^2(\hat{\theta}) = \frac{1}{M-1} \sum_{m=1}^{M} \left(\hat{\theta}(X^{*m}) - \bar{\theta}^*\right)^2$$

9 Moyenne et déviation standard empirique

9.1 Propriétés de $\bar{X}$ et S^2 (moyenne et variance empirique)

Un **interval de confiance** pour μ au niveau $1-\alpha$ est un interval $[\mu_L, \mu_U]$ tel que μ est dans l'interval avec probabilitée de $1-\alpha$

Considérons n variables aléatoires $X_{i=1:n} \sim X$, $\mu = \mathbb{E}(X)$ et $\sigma^2 = \mathbb{V}(V)$. Le CLT (théorème central limite) dit que quel que soit la distribution de $X_{i=1:n}$, la moyenne empirique tend à une normale

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right) \quad \frac{\bar{X}-\mu}{\sqrt{\sigma^2/n}} \sim N(0,1)$$

Dans ce cas $\bar{X}$ est un estimateur de μ et σ^2 est connu, on peut trouver

$$P\left(z_{\alpha/2} \leq \frac{\bar{X}-\mu}{\sqrt{\sigma^2/n}} \leq z_{1-\alpha/2}\right) = 1-\alpha$$

Comme $-z_{1-\alpha/2} = z_{\alpha/2}$. L'interval de confiance $1-\alpha$ pour μ est

$$\left[\bar{X} - z_{1-\alpha/2}\sqrt{\sigma^2/n}; \bar{X} + z_{1-\alpha/2}\sqrt{\sigma^2/n}\right]$$

- $S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2$ est un estimateur non biaisé de $\mathbb{V}(X)$
- Si $X_i \sim \mathcal{N}(\mu, \sigma^2)$, S^2 et $\bar{X}$ sont indépendants, donc

$$(n-1)\frac{S^2}{\sigma^2} = \sum_{i=1}^{n}\left(\frac{X_i - \bar{X}}{\sigma}\right)^2 \sim \chi^2_{n-1}$$

Si $X \sim N(\mu, \sigma^2)$, alors S^2 est un estimateur de σ. Puisque $(n-1)\frac{S^2}{\sigma^2} \sim \chi^2_{n-1}$, on trouve que

$$P\left(\chi^2_{n-1,\alpha/2} \leq (n-1)\frac{S^2}{\sigma^2} \leq \chi^2_{n-1,1-\alpha/2}\right) = 1-\alpha$$

L'interval de confiance $1-\alpha$ est donc

$$\left[\frac{(n-1)}{\chi^2_{n-1,1-\alpha/2}}S^2; \frac{(n-1)}{\chi^2_{n-1,\alpha/2}}S^2\right]$$

Une variable variable aléatoire Student's T est $= T_n = \frac{Y}{\sqrt{Z/n}}$ où $Z \sim \chi^2_n$ et $Y \sim N(0,1)$, alors :
Si $X_i \sim \mathcal{N}(\mu, \sigma^2)$ alors le ratio suivant est une variable aléaatoire Student's T

$$\frac{\bar{X} - \mu}{\sqrt{\frac{S^2}{n}}} \sim t_{n-1}$$

Dans ce cas, $\bar{X}$ est un estimateur de μ, et σ est inconnu :

$$P\left(t_{n-1,\alpha/2} \leq \frac{\bar{X} - \mu}{\sqrt{S^2/n}} \leq t_{n-1,1-\alpha/2}\right) = 1 - \alpha$$

la Student's T est symmétrique : $-t_{n-1,\alpha/2} = t_{n-1,1-\alpha/2}$. L'interval de confidence $1 - \alpha$ est donc

$$\mu \in \left[\bar{X} - t_{n-1,1-\alpha/2}\sqrt{S^2/n}; \bar{X} + t_{n-1,1-\alpha/2}\sqrt{S^2/n}\right]$$

	Distribution of X	μ	σ^2	Statistics
$\bar{X}$	unknown and large n	ok	ok	$\frac{\bar{X}-\mu}{\sqrt{\sigma^2/n}} \sim \mathcal{N}(0,1)$
S^2	$\mathcal{N}(\mu, \sigma^2)$	-	ok	$(n-1)\frac{S^2}{\sigma^2} \sim \chi^2_{n-1}$
$\bar{X}$	$\mathcal{N}(\mu, \sigma^2)$	ok	-	$\frac{\bar{X}-\mu}{\sqrt{\frac{S^2}{n}}} \sim t_{n-1}$

9.2 Propriétés de $\bar{X}$ et S^2 à 2 populations normales

		μ_1, μ_2	σ_1^2, σ_2^2	Statistics
$\bar{X}_1 - \bar{X}_2$	$\sigma_1^2 \neq \sigma_2^2$	ok	ok	$\frac{(\bar{X}_1-\bar{X}_2)-(\mu_1-\mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1}+\frac{\sigma_2^2}{n_2}}} \sim \mathcal{N}(0,1)$
S^2_{pool}	$\sigma_1^2 = \sigma_2^2$	-	ok	$(n_1+n_2-2)\frac{S^2_{pool}}{\sigma^2} \sim \chi^2_{n_1+n_2-2}$.
S_1^2, S_2^2	$\sigma_1^2 \neq \sigma_2^2$	-	ok	$\frac{S_1^2\sigma_2^2}{S_2^2\sigma_1^2} \sim F_{n_1-1,\, n_2-1}$
$\bar{X}_1 - \bar{X}_2$	$\sigma_1^2 = \sigma_2^2$	ok	-	$\frac{(\bar{X}_1-\bar{X}_2)-(\mu_1-\mu_2)}{S_{pool}\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}} \sim t_{n_1+n_2-2}$

10 Test d'hypothèse à 1 population

Une **hypothèse** est une affirmation à propos d'un paramètre θ d'un échantillon aléatoire. L'**hypothèse nulle** notée $H_0 = \theta \in \Theta_0$ et dit l'affirmation à tester. L'hypothèse alternative est $H_1 = \theta \in \Theta_1$
La décision de rejeter ou non l'hypothèse nulle H_0 est basée sur l'échantillon. Il y a 4 cas possibles :

	Reality	
Decision	H_0 is true	H_1 is true
Accept H_0	Correct	Type 2 error
Reject H_0	Type 1 error	Correct

La probabilitée de faire une erreur de type 1 s'appelle le **niveau de signification** du test, et se dénote α

Si H_0 est "vous n'êtes pas malade" :

- Erreur type 1 : Vous n'êtes pas malade, mais le test est positif (faux positif)
- Erreur type 2 : Vous êtes malade, mais le test est négatif (faux négatif)

10.1 Introduction

La décision de rejeter l'hypothèse nulle est basée sur un test statistique, noté $T(\cdot)$.
Soit un échantillon $\mathbf{X} = \{X_1, \ldots, X_n\}$ d'observations, $T(\mathbf{X}) : \mathbb{R}^n \to \mathbb{R}$. $T(\mathbf{X})$ est tel que sa distribution est connue

- Pour un α choisi, on détermine la région de rejection $R_\alpha \in \mathbb{R}$, tel que $P(\text{type 1}) = \alpha$
- On calcule $t = T(\mathbf{x})$ la valeur observée de $T(\mathbf{X})$ sous H_0
- Décision : Si $t \in R_\alpha$, on rejette, sinon on accepte

10.2 Single mean test, θ^2 inconnu

Soit $X_1, \ldots, X_n \sim \mathcal{N}(\mu, \sigma^2)$ indépendants et identiquement distribués, avec variance inconnue. On test

$$H_0 : \mu = \mu_0$$

contre 3 alternatives :

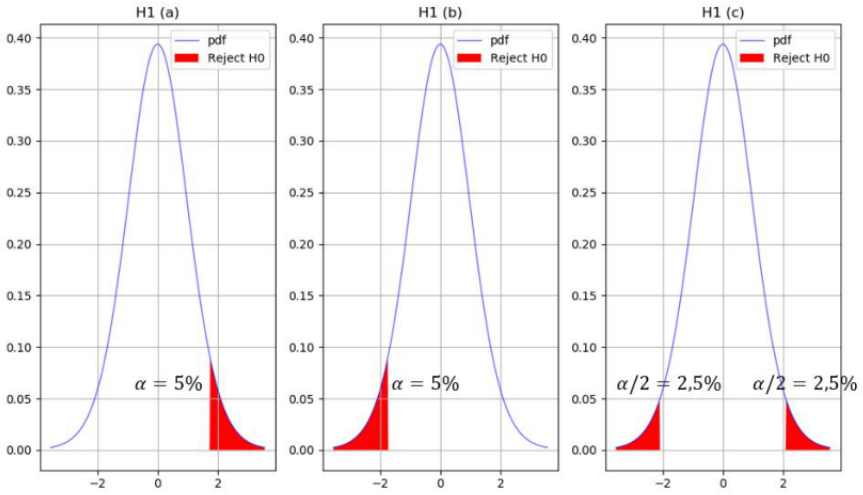
$$H_1 : \mu > \mu_0$$
$$H_1 : \mu < \mu_0$$
$$H_1 : \mu \neq \mu_0$$

Si H_0 est vrai, un bon choix pour la statistique de test est la Student's T :

$$T(\mathbf{X}) = \frac{\bar{X} - \mu_0}{\sqrt{\frac{S^2}{n}}} \sim t_{n-1}$$

On trouve une valeur critique c sous la supposition que H_0 est vrai :

- $P(T(\mathbf{X}) > c | H_0 \text{ est vrai}) = \alpha$
- $P(T(\mathbf{X}) < c | H_0 \text{ est vrai}) = \alpha$
- $P(T(\mathbf{X}) < -c \text{ ou } T(\mathbf{X}) > c | H_0 \text{ est vrai}) = \alpha$



On rejette H_0 au niveau α si

- Pour $H_1 : \mu > \mu_0$, on rejette H_0 si $T(\mathbf{x}) > t_{n-1,1-\alpha}$.
- Pour $H_1 : \mu < \mu_0$, on rejette H_0 si $T(\mathbf{x}) < t_{n-1,\alpha}$.
- Pour $H_1 : \mu \neq \mu_0$, on rejette H_0 si $T(\mathbf{x}) < t_{n-1,\alpha/2}$ ou $T(\mathbf{x}) > t_{n-1,1-\alpha/2}$.

10.3 Single variance test

Soit $X_1, \ldots, X_n \sim \mathcal{N}(\mu, \sigma^2)$ indépendants et identiquement distribués, avec variance inconnue. On test

$$H_0 : \sigma^2 = \sigma_0^2$$

contre 3 alternatives :

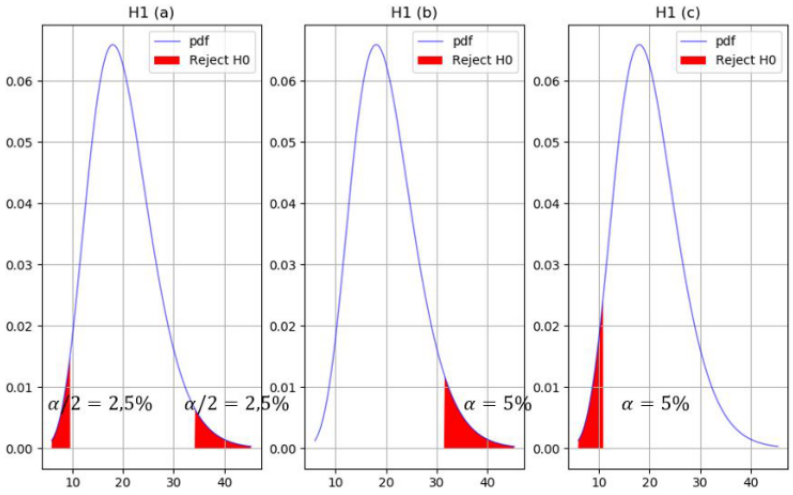
$$H_1 : \sigma^2 \neq \sigma_0^2$$

$$H_1 : \sigma^2 > \sigma_0^2$$

$$H_1 : \sigma^2 < \sigma_0^2$$

Un bon choix pour la statistique de test est la χ^2

$$T(\mathbf{X}) = (n-1)\frac{S^2}{\sigma_0^2} \sim \chi^2_{n-1}$$



On rejette H_0 au niveau α si

- Pour $H_1 : \sigma^2 \neq \sigma_0^2$, on rejette H_0 si $T(\mathbf{x}) < \chi^2_{n-1,\alpha/2}$ ou $T(\mathbf{x}) > \chi^2_{n-1,1-\alpha/2}$.
- Pour $H_1 : \sigma^2 > \sigma_0^2$, on rejette H_0 si $T(\mathbf{x}) > \chi^2_{n-1,1-\alpha}$
- Pour $H_1 : \sigma^2 < \sigma_0^2$, on rejette H_0 si $T(\mathbf{x}) < \chi^2_{n-1,\alpha}$

10.4 P-valeur

La **P-valeur** est le plus bas niveau de signification pour lequel les données indiques une rejection de l'hypothèse nulle

Soit $T(\mathbf{X})$ une statistique de test tel que les petites valeurs de T montre que H_0 est faux. Pour un échantillon donné $\mathbf{x}$, la p-valeur est :

$$p(\mathbf{x}) = P(T(\mathbf{X}) < T(\mathbf{x}) \mid H_0 \text{ est vrai})$$

Soit $T(\mathbf{X})$ une statistique de test tel que les grandes valeurs de T montre que H_0 est faux. Pour un échantillon donné $\mathbf{x}$, la p-valeur est :

$$p(\mathbf{x}) = P(T(\mathbf{X}) > T(\mathbf{x}) \mid H_0 \text{ est vrai})$$

Soit $T(\mathbf{X})$ une statistique de test **symmétrique autour de 0** tel que les petites et grandes valeurs de T montre que H_0 est faux. Pour un échantillon donné $\mathbf{x}$, la p-valeur est :

$$p(\mathbf{x}) = 2P(T(\mathbf{X}) > |T(\mathbf{x})| \mid H_0 \text{ est vrai})$$

Une petite p-valeur indique que H_0 est très peu probable, une grande p-valeur indique que H_0 est probable

11 Test d'hypothèse à 2 populations

11.1 Comparaison de 2 médiane

On considère 2 populations avec la même variance

$$\mathbf{X}_1 = \{X_{1,1}, \ldots, X_{1,n_1}\} \sim N(\mu_1, \sigma^2) \Rightarrow \bar{X}_1 \sim N\left(\mu_1, \frac{\sigma^2}{n_1}\right)$$
$$\mathbf{X}_2 = \{X_{2,1}, \ldots, X_{2,n_2}\} \sim N(\mu_2, \sigma^2) \Rightarrow \bar{X}_2 \sim N\left(\mu_2, \frac{\sigma^2}{n_2}\right)$$

On test si les deux échantillons ont la même médiane :

$$H_0 : \mu_1 - \mu_2 = \delta$$

Contre

$$H_1 : \mu_1 - \mu_2 > \delta$$
$$H_1 : \mu_1 - \mu_2 < \delta$$
$$H_1 : \mu_1 - \mu_2 \neq \delta$$

11.1.1 Cas 1 : σ connu

$$\bar{X}_1 - \bar{X}_2 \sim N\left(\mu_1 - \mu_2, \frac{\sigma^2}{n_1} + \frac{\sigma^2}{n_2}\right)$$

On utilise la statistique de test :

$$T(\mathbf{X}_1, \mathbf{X}_2) = \frac{(\bar{X}_1 - \bar{X}_2) - \delta}{\sigma\sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim \mathcal{N}(0,1)$$

On rejette $H_0 : \mu_1 - \mu_2 = \delta$ au niveau α si

- Pour $H_1 : \mu_1 - \mu_2 > \delta$, on rejette $T(\mathbf{x}_1, \mathbf{x}_2) > z_{1-\alpha}$
- Pour $H_1 : \mu_1 - \mu_2 < \delta$, on rejette $T(\mathbf{x}_1, \mathbf{x}_2) < z_{\alpha}$
- Pour $H_1 : \mu_1 - \mu_2 \neq \delta$, on rejette $T(\mathbf{x}_1, \mathbf{x}_2) < z_{\alpha/2}$ ou $T(\mathbf{x}_1, \mathbf{x}_2) > z_{1-\alpha/2}$

où z_α est le percentile de $Z \sim \mathcal{N}(0,1)(P(Z \leq z_\alpha) = \alpha)$

11.1.2 Cas 2 : σ connu

On utilise la statistique de test :

$$T(\mathbf{X}_1, \mathbf{X}_2) = \frac{(\bar{X}_1 - \bar{X}_2) - \delta}{S_{pool}\sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t_{n_1+n_2-2}$$

On rejette $H_0 : \mu_1 - \mu_2 = \delta$ au niveau α si

- Pour $H_1 : \mu_1 - \mu_2 > \delta$, on rejette $T(\mathbf{x}_1, \mathbf{x}_2) > t_{n_1+n_2-2,1-\alpha}$
- Pour $H_1 : \mu_1 - \mu_2 < \delta$, on rejette $T(\mathbf{x}_1, \mathbf{x}_2) < t_{n_1+n_2-2,\alpha}$
- Pour $H_1 : \mu_1 - \mu_2 \neq \delta$, on rejette $T(\mathbf{x}_1, \mathbf{x}_2) < t_{n_1+n_2-2,\alpha/2}$ ou $T(\mathbf{x}_1, \mathbf{x}_2) > t_{n_1+n_2-2,1-\alpha/2}$

où $t_{n_1+n_2-2,\alpha}$ est le percentile α d'une Student's T

11.2 Comparaison de 2 variances

On considère 2 populations de variance différente :

$$\mathbf{X}_1 = \{X_{1,1}, \ldots, X_{1,n}\} \sim \mathcal{N}(\mu_1, \sigma_1^2)$$
$$\mathbf{X}_2 = \{X_{2,1}, \ldots, X_{2,n}\} \sim \mathcal{N}(\mu_2, \sigma_2^2)$$

On test si les deux échantillons ont la même variance :

$$H_0 : \sigma_1 = \sigma_2$$

Contre

$$H_1 : \sigma_1 \neq \sigma_2$$
$$H_1 : \sigma_1 > \sigma_2$$
$$H_1 : \sigma_1 < \sigma_2$$

On utilise la statistique de test :

$$T(\mathbf{X}_1, \mathbf{X}_2) = \frac{S_1^2}{S_2^2} \sim F_{n_1-1,n_2-1}$$

On rejette $H_0 : \sigma_1^2 = \sigma_2^2$ au niveau α si

- Pour $H_1 : \sigma_1 \neq \sigma_2$, on rejette $T(\mathbf{x}_1, \mathbf{x}_2) < F_{n_1-1,n_2-1,\alpha/2}$ ou $T(\mathbf{x}_1, \mathbf{x}_2) > F_{n_1-1,n_2-1,1-\alpha/2}$
- Pour $H_1 : \sigma_1 > \sigma_2$, on rejette $T(\mathbf{x}_1, \mathbf{x}_2) < F_{n_1-1,n_2-1,1-\alpha}$
- Pour $H_1 : \sigma_1 < \sigma_2$, on rejette $T(\mathbf{x}_1, \mathbf{x}_2) < F_{n_1-1,n_2-1,\alpha}$

où $F_{n_1-1,n_2-1,\alpha}$ est le percentile α d'une Fisher

12 Régression linéaire

On observe n réalisations y_i de Y_i qui est lié à d facteurs $(x_{i,1},\dots,x_{i,d})^\intercal$ pour $i = 1,\dots,n$.

$$Y_i = \beta_0 + \beta_1 x_{i,1} + \cdots + \beta_d x_{i,d} + \varepsilon_i \quad i = 1,\dots,n$$

où $\varepsilon_i \sim \mathcal{N}(0,\sigma^2)$
Notation matricielle :

$$\mathbf{Y} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix} \qquad \beta = \begin{pmatrix} \beta_0 \\ \vdots \\ \beta_d \end{pmatrix} \qquad \mathbf{X} = \begin{pmatrix} 1 & x_{1,1} & \dots & x_{1,d} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n,1} & \dots & x_{n,d} \end{pmatrix}$$

$\mathbf{Y}$ est de taille n, β de taille $d+1$, et $\mathbf{X}$ de taille $n \times (d+1)$
Le vecteur de bruit est noté ε. Le vecteur de réalisation/observation de $\mathbf{Y}$ est $\mathbf{y}$. On obtient

$$\mathbf{Y} = \mathbf{X}\beta + \varepsilon$$

12.1 Moindre carré

La meilleur $\hat{y}$ prédiction de Y pour une valeur $\mathbf{x} = (1, x_1, \dots, x_d)^\intercal$ est

$$\hat{y} = \mathbb{E}(Y|\mathbf{x}) = \mathbf{x}^\top \beta.$$

Mais β et σ^2 sont inconnu, on va les estimer avec la maximisation de vraisemblance :
On a $\theta = (\beta, \sigma)$ et conditionnelement à $\mathbf{x}_i$, la réponse est normale :

$$Y_i|\mathbf{x}_i \sim \mathcal{N}(\mathbf{x}_i^\top \beta; \sigma^2) \quad i = 1,\dots,n$$

L'estimation de θ maximise la fonction de vraisemblance $\log$:

$$\begin{aligned} I(\theta) &= \sum_{i=1}^{n} \ln\left(\frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{1}{2}\frac{(y_i - \mathbf{x}_i^\top\beta)^2}{\sigma^2}\right)\right) \\ &= \sum_{i=1}^{n} \left(-\ln(\sigma\sqrt{2\pi}) - \frac{1}{2}\left(\frac{(y_i - \mathbf{x}_i^\top\beta)^2}{\sigma^2}\right)\right) \\ &\propto \underbrace{-\sum_{i=1}^{n}(y_i - \mathbf{x}_i^\top\beta)^2}_{(*)} \end{aligned}$$

Donc, pour un $\sigma > 0$ donné, l'estimation de β minimise $*$

$$\hat{\beta} = \arg_\beta \min(\mathbf{y} - \mathbf{X}\beta)^\intercal(\mathbf{y} - \mathbf{X}\beta) = \arg_\beta \min \sum_{i=1}^{n}(y_i - \mathbf{x}_i^\intercal\beta)^2$$

$$\hat{\beta} = (\mathbf{X}^\intercal \mathbf{X})^{-1} \mathbf{X}^\intercal \mathbf{y}$$

La meilleur prédiction de Y_i pour un vecteur de facteur $\mathbf{x}_i$ est

$$\hat{y}_i = \mathbf{x_i}^\intercal \hat{\beta} \qquad i = 1, \ldots, n$$

ou sous forme de matrice, si $\hat{\mathbf{y}} = (y_1, \ldots, y_n)^\intercal$, $\hat{\mathbf{y}} = \mathbf{X}\hat{\beta}$. Donc

$$\hat{\mathbf{y}} = \underbrace{\mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1}\mathbf{X}^\top}_{\mathbf{H}} \mathbf{y}$$

où $\mathbf{H}$ est la matrice chapeau, elle est symmétrique et idempotente :

$$\mathbf{H} = \mathbf{H}^\top \qquad ; \qquad \mathbf{HH} = \mathbf{H}$$

L'hypothèse de normalité ne fonctionne pas avec le moindre carré.

12.2 Régression linéaire simple

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

Alors

$$\{\hat{\beta}_0, \hat{\beta}_1\} = \arg\min_{\beta_0, \beta_1} \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i)^2,$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{S_{xy}}{S_{xx}}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Pour mesurer la qualitée du modèle, on sépare la variance des observations en

- Une variance expliquée par le modèle
- Une variance résiduelle

Plus la variance expliquée par le modèle est grande, mieux c'est
Soit $\hat{y}_i = \mathbf{x}_i^\top \hat{\beta}$ alors

$$\underbrace{\sum_{i=1}^{n} (y_i - \bar{y})^2}_{\text{SS Total}} = \underbrace{\sum_{i=1}^{n} (y_i - \hat{y}_i)^2}_{\text{SS Error}} + \underbrace{\sum_{i=1}^{n} (\hat{y}_i - \bar{y})^2}_{\text{SS Regression}}$$

(Pas dans le formulaire mais à connaitre)

13 Propriétés des coefficients de régression

$\hat{\beta}$ est un estimateur Gaussien non biaisé de β :

$$\hat{\beta} \sim \mathcal{N}\left(\beta, \sigma^2 \left(\mathbf{X}^\top \mathbf{X}\right)^{-1}\right)$$

Un estimateur non biaisé de σ^2 est

$$\hat{\sigma}^2 = \frac{1}{n-(d+1)} \underbrace{\left(\mathbf{Y} - \mathbf{X}\hat{\beta}\right)^\top \left(\mathbf{Y} - \mathbf{X}\hat{\beta}\right)}_{SSE}$$

et

$$(n-(d+1))\frac{\hat{\sigma}^2}{\sigma^2} = \frac{SSE}{\sigma^2} \sim \chi^2_{n-(d+1)}$$

13.1 Régression linéaire simple

$\hat{\beta}_0$ et $\hat{\beta}_1$ sont des estimateurs non biaisés ($\mathbb{E}(\hat{\beta}_{0 \text{ ou } 1}) = \beta_{0 \text{ ou } 1}$)
Si $\overline{x^2} = \frac{1}{n}\sum_{i=1}^n x_i^2$, leur variances sont

$$V(\hat{\beta}_0) = \frac{\sigma^2 \overline{x^2}}{S_{xx}} \quad ; \quad V(\hat{\beta}_1) = \frac{\sigma^2}{S_{xx}} \quad ; \quad C(\hat{\beta}_0, \hat{\beta}_1) = \frac{-\sigma^2 \bar{x}}{S_{xx}}$$

où $S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$ (mais σ^2 est inconnu, en pratique on le remplace par $\hat{\sigma}^2$, alors $\hat{\beta}_0$ et $\hat{\beta}_1$ deviennet des student's T)

13.2 Test de signification de régression linéaire

$$H_0 : \beta_1 = \cdots = \beta_d = 0$$
$$H_1 : \beta_j \neq 0 \quad \text{pour un} j \in \{1, \ldots, d\}$$

Statistique de test F^* :

$$F^* = \frac{MSR}{MSE} = \frac{SSR/d}{SSE/(n-d-1)} \sim F_{d,n-(d+1)}$$

Rejeter H_0 au niveau de confiance α

- Si $F^* > F_{d,n-(d+1),1-\alpha}$
- Ou si la p-valeur $p_{val} = P(F^* < F_{d,n-(d+1)})$ est plus bas que α

Soit $c_{j,j}$ l'élément diagonal j de $(\mathbf{X}^\top \mathbf{X})^{-1}$. Les estimateurs des coefficients de régression linéaire $\hat{\beta} = (\hat{\beta}_0, \ldots, \hat{\beta}_d)^\top$ sont des Student's T :

$$\frac{\hat{\beta}_j - \beta_j}{\hat{\sigma}\sqrt{c_{jj}}} \sim t_{n-(d+1)}$$

On utilise ce résultat pour tester la signification de chaque β_j :

$$H_0 : \quad \beta_j = \beta_{j,0}$$

contre 3 alternatives :

$$H_1 : \beta_j > \beta_{j,0}$$
$$H_1 : \beta_j < \beta_{j,0}$$
$$H_1 : \beta_j \neq \beta_{j,0}$$

avec la statistique de test $T_j^* = \frac{\hat{\beta}_j - \beta_j}{\hat{\sigma}\sqrt{c_{jj}}} \sim t_{n-(d+1)}$
On rejette H_0 au niveau α si

- Pour $H_1 : \beta_j > \beta_{j,0}$, on rejette $T_j^* > t_{n-d-1,1-\alpha}$
- Pour $H_1 : \beta_j < \beta_{j,0}$, on rejette $T_j^* < t_{n-d-1,\alpha}$
- Pour $H_1 : \beta_j \neq \beta_{j,0}$, on rejette $T_j^* < t_{n-d-1,\alpha/2}$ ou $T_j^* > t_{n-d-1,1-\alpha/2}$

Un **interval de confiance** pour β_j au niveau $1-\alpha$ est un interval $[\beta_{j,L}, \beta_{j,U}]$ tel que β_j est dans cet interval avec probabilité $1-\alpha$
Puisque c'est $\sim$ à une student's T, on peut trouver

$$\left[\widehat{\beta}_j + t_{n-d-1,\alpha/2}\widehat{\sigma}\sqrt{c_{jj}}; \widehat{\beta}_j + t_{n-d-1,1-\alpha/2}\widehat{\sigma}\sqrt{c_{jj}}\right]$$

13.3 Test de β : Régression linéaire simple

Lorsque $d = 1, Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$, les coefficients $c_{0,0}$ et $c_{1,1}$ sont simple à calculer :

$$c_{0,0} = \frac{\overline{x^2}}{S_{xx}} \qquad c_{1,1} = \frac{1}{S_{xx}}$$

où $\overline{x^2} = \frac{1}{2}\sum_{i=1}^n x_i^2$, et $S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$

- On test

$$H_0 : \beta_1 = \beta_{1,0}$$
$$H_1 : \beta_1 \neq \beta_{1,0}$$

avec la statistique de test $T_1^* = \frac{\hat{\beta}_1 - \beta_{1,0}}{\hat{\sigma}\sqrt{S_{xx}^{-1}}} \sim t_{n-2}$. L'interface de confiance est

$$\beta_1 \in \left[\widehat{\beta}_1 - t_{n-d-1,1-\alpha/2}\,\widehat{\sigma}\sqrt{S_{xx}^{-1}}\,;\,\widehat{\beta}_1 + t_{n-d-1,1-\alpha/2}\,\widehat{\sigma}\sqrt{S_{xx}^{-1}}\right]$$

- On test

$$H_0 : \beta_0 = \beta_{0,0}$$
$$H_1 : \beta_0 \neq \beta_{0,0}$$

avec la statistique de test $T_0^* = \frac{\hat{\beta}_0 - \beta_{0,0}}{\hat{\sigma}\sqrt{\overline{x^2}S_{xx}^{-1}}} \sim t_{n-2}$. L'interface de confiance est

$$\beta_0 \in \left[\widehat{\beta}_0 - t_{n-d-1,1-\alpha/2}\,\widehat{\sigma}\sqrt{\overline{x^2}S_{xx}^{-1}}\,;\,\widehat{\beta}_0 + t_{n-d-1,1-\alpha/2}\,\widehat{\sigma}\sqrt{\overline{x^2}S_{xx}^{-1}}\right]$$

13.4 Interval de prédiction, régression simple

Pour un modèle $Y = \beta_0 + \beta_1 X + \varepsilon$, la prédiction pour une valeur non observée $X = x_0$ est

$$\hat{y_0} = \hat{\beta}_0 + \hat{\beta}_1 x_0$$

L'**interval de prédiction** pour Y_0 au niveau α est donné par

$$\left[\hat{y}_0 - S_{pred}\,t_{n-2;1-\frac{\alpha}{2}}\;;\;\hat{y}_0 + S_{pred}\,t_{n-2;1-\frac{\alpha}{2}}\right]$$

où

$$S_{pred}^2 = \hat{\sigma}^2\left(1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}\right)$$

14 Analyse de Variance (ANOVA)

Globalement juste de la régression linéaire

15 Modèles auto-régressif

15.1 Time-series

Une **time-series** est un vecteur indexé par temps : $\mathbf{x} = (x_t)_{t=1,2,\ldots,T}$, ddes réalisations de la variable aléatoire $(X_t)_{t=1,2,\ldots,T}$.
Si la pdf de X_t est $f_t(x)$, la fonction moyenne est :

$$\mu_t = \mathbb{E}(X_t) = \int_{-\infty}^{+\infty} x f_t(x)\,dx,$$

La fonction d'**autocovariance** $\gamma(t,s)$ est définie comme la covariance entre X_t et X_s :

$$\gamma(t,s) = \mathbb{E}[(X_t - \mu_t)(X_s - \mu_s)] \quad \forall t,s \in \mathbb{N}.$$

La fonction d'**autocorrelation** $\rho(t,s)$ est :

$$\rho(t,s) = \frac{\gamma(t,s)}{\sqrt{\gamma(t,t)\gamma(s,s)}} \quad \forall t,s \in \mathbb{N}.$$

15.2 Procédé autorégressif

$\mathbf{AR(p)}$: un procédé autoregressif d'ordre p :

$$\begin{aligned} X_t &= \beta_1 X_{t-1} + \beta_2 X_{t-2} + \cdots + \beta_p X_{t-p} + \varepsilon_t, \\ &= \beta^\top \mathbf{x}_{t-1:t-p} + \varepsilon_t, \end{aligned}$$

où ε_t est un procédé gaussien de moyenne nulle et de variance σ^2

15.3 Autoregression

Si on a n observations, ce modèle est estimé comme une régression linéaire standard

$$\mathbf{y} = \begin{pmatrix} x_{p+1} \\ \vdots \\ x_n \end{pmatrix} \qquad \mathbf{X} = \begin{pmatrix} x_p & \dots & x_1 \\ \vdots & \ddots & \vdots \\ x_{n-1} & \dots & x_{n-p} \end{pmatrix}$$

L'estimateur de β est obtenu par maximisation de vraisemblance log :

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}.$$

L'estimation de $X_t | \mathbf{x}_{t-1:t-p}$ est alors

$$\widehat{x_t} = \widehat{\beta}^{\mathrm{T}} \mathbf{x}_{t-1:t-p}$$

le variance de prédictions est estimée par

$$\widehat{\sigma}^2 = \frac{1}{(T-p)-1} \sum_{t=p+1}^{T} (x_t - \widehat{x_t})^2$$

On peut aussi prédire k période à l'avance

$$\hat{x}_{t+k} = \hat{\beta}^\top \hat{\mathbf{x}}_{(t+k)-1:(t+k)-p}$$

Comment choisir le nombre optimal de "lags" (le nombre de données utilisés pour prédire). Comme tout modèle, la qualité d'un $AR(p)$ peut être mesuré par sa log-vraisemblance, $\ln L(p)$.

Si on a T observations et un modèle $AR(p)$:

$$L(p) := \prod_{t=p+1}^{T} f\left(x_t \mid \hat{\beta}\right)$$

où $f(\hat{x}_t|\hat{\beta})$ est la pdf d'une distribution normale $\mathcal{N}(\hat{x}_t, \hat{\sigma}^2)$

$$f(\hat{x}_t|\hat{\beta}) = \frac{1}{\hat{\sigma}\sqrt{2\pi}} \exp\left(-\frac{1}{2}\frac{(x_t - \hat{x}_t)^2}{\hat{\sigma}^2}\right)$$

15.4 Critère d'information

- Critère d'information **Akaike** (AIC) :

$$AIC = 2p - 2\ln(L(p))$$

- Critère d'information **Bayesian** (BIC) :

$$BIC = \ln(n)p - 2\ln(L(p))$$

où n est le nombre de données, p le nombre de paramètres dans le modèle et $L(p)$ le maximum de la fonction de vraisemblance du modèle
Le minimum indique le nombre optimal de lags

Data

1 Supervised Learning

Hyper paramètre : Paramètre pas appris lors de l'entrainement, mais en utilisant plusieurs entrainement par exemple

1.1 Introduction

1.1.1 Notations et conventions

La dimension "N" est réservée pour la taille d'un set (de données)
Toutes les matrices (et vecteurs) avec N lignes sont en **gras**
Les variables aléatoires sont noté en majuscule
La pmf/pdf d'un fonction discrète/continue, avec la variable aléatoire X est "p_X"

1.1.2 Regression vs Classification

- Regression : prédiction de valeurs ordonnées (ou quantitatives)
- Classification : prédiction de classes ou catégories (ou qualitatives)

Dummy variable (one-hot encoding) : Valeur qualitative $\rightarrow$ quantitative, en faisant une dimension par catégorie (vecteur avec un seul 1 pour une catégorie)

1.1.3 Lier une entrée à une sortie

Entrée $X = (X_1, \ldots, X_p)^\top \in \mathbb{R}^p$
Sortie $Y \in \mathscr{Y}$ (quantitatif ou qualitatif)
Hypothèse : Y et X sont liés imparfaitement (avec un peu de bruit)
Il existe une fonction $f : \mathbb{R}^p \rightarrow \mathscr{Y}$ tel que :

- Pour une régression ($\mathscr{Y} = \mathbb{R}$) :
$$Y = f(X) + \varepsilon$$
pour un bruit aléatoire $\varepsilon \in \mathbb{R}$
- Pour une classification binaire (par exemple $\mathscr{Y} = \mathscr{G} := \{0, 1\}$)
$$P(Y = f(X)) = 1 - \eta$$
$$P(Y \neq f(X)) = \eta$$
pour une erreur de misclassification $0 \leq \eta \leq 1$

En théorie : On trouve une estimation $\hat{f}$ de f pour faire des prédictions (ou inférences) de Y en sachant X
En pratique : On trouve un estimateur fiable $\hat{f}$ de f pour faire des prédictions (ou inférences) d'un échantillon de Y en sachant un échantillon de X (le dataset)

1.2 Modèle linéaire

$$\hat{Y} = f_{\hat{\beta}}(X) := \sum_{j=1}^{p} X_j \hat{\beta}_j = (X_1 \quad \dots \quad X_p) \begin{pmatrix} \hat{\beta}_1 \\ \vdots \\ \hat{\beta}_p \end{pmatrix} = X^\top \hat{\beta}$$

(On peut ajouter un β_0)

1.2.1 Fitting

Soit le set

$$\mathscr{T} := \{(x_i, y_i)\}_{i=1}^{N} \subset \mathbb{R}^p \times \mathbb{R}$$

On choisit de noter le minimiseur $\hat{\beta}$, et on définit le **risque empirique** :

$$\hat{R}(\beta) := \frac{1}{N} \sum_{i=1}^{N} (y_i - x_i^\top \beta)^2 = \frac{1}{N} \|\mathbf{y} - \mathbf{X}\beta\|_2^2.$$

avec
$\mathbf{X} = (x_1, \dots, x_N)^\top \in \mathbb{R}^{N \times p}$
$\mathbf{y} = (y_1, \dots, y_N)^\top, ||\mathbf{u}||_2^2 := \mathbf{u}^\top \mathbf{u}$
(On minimise la somme des distances verticales carrée, pas la distance entre $\mathscr{T}$ et $\mathscr{P}$ (l'hyperplan fitté))
Solution :
$\hat{R}$ minimum sur $\hat{\beta}$ si

$$\nabla_\beta \hat{R}(\hat{\beta}) = 2\mathbf{X}^\top (\mathbf{y} - \mathbf{X}\hat{\beta}) = 0 \implies \hat{\beta} := \mathbf{X}^\dagger \mathbf{y} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$$

(On suppose $N > p$ et $\mathbf{X}^\top \mathbf{X}$ inversible)
Fitting :

$$\hat{\mathbf{y}} = \mathbf{X}\hat{\beta} = (x_1^\top \hat{\beta}, \dots, x_N^\top \hat{\beta}) = \mathbf{H}\mathbf{y} = \mathbf{X}\mathbf{X}^\dagger \mathbf{y}$$

1.2.2 Classification avec un modèle linéaire

On introduit $\mathscr{B}_\tau$ qui converti un nombre continu en une valeur binaire $Y \in \{0, 1\}$
La classe estimée $\hat{G}$ de x est

$$\hat{G}(x) = \mathscr{B}_\tau(x^\top \hat{\beta}) := \begin{cases} 1 & \text{si } (x^\top \hat{\beta}) > \tau \\ 0 & \text{si } (x^\top \hat{\beta}) \leq \tau \end{cases}$$

1.3 Méthode k-Nearest Neighbors

Soit un nombre de voisins $k \in \mathbb{N}$, on définit

$$N_k(x) : \text{L'ensemble de } k \text{ points les plus proches de } x \text{ dans } \{x_i\}_{i=1}^N \subset \mathbb{R}^p$$

$$\hat{Y}(x) = \frac{1}{k} \sum_{i:\, x_i \in N_k(x)} y_i$$

La prédiction est la moyenne local, elle est non-paramétrique

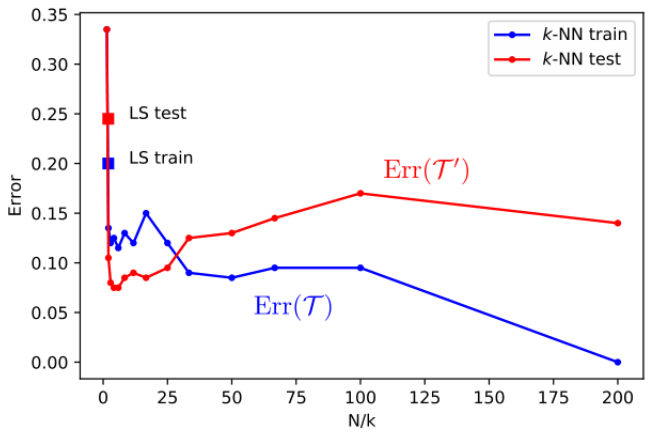
1.3.1 Classification

On peut utiliser $\mathscr{B}_\tau$ à nouveau
Si $\tau = 0.5$, on a juste un "vote de majorité"

Pour $K \geq 2$ nombre de classes, on applique le "one-hot encoding" à tout les y_i, puis on applique la régression k-NN, et on assigne à x l'indice du maximum

1.3.2 Erreur

$$\text{Error} := \text{Err}(\mathscr{T}) = \frac{1}{N} \sum_{i=1}^{N} I(y_i \neq \hat{f}(x_i))$$



Training error of LS and k-NN classifiers.

1.3.3 Nombre effectif de paramètres

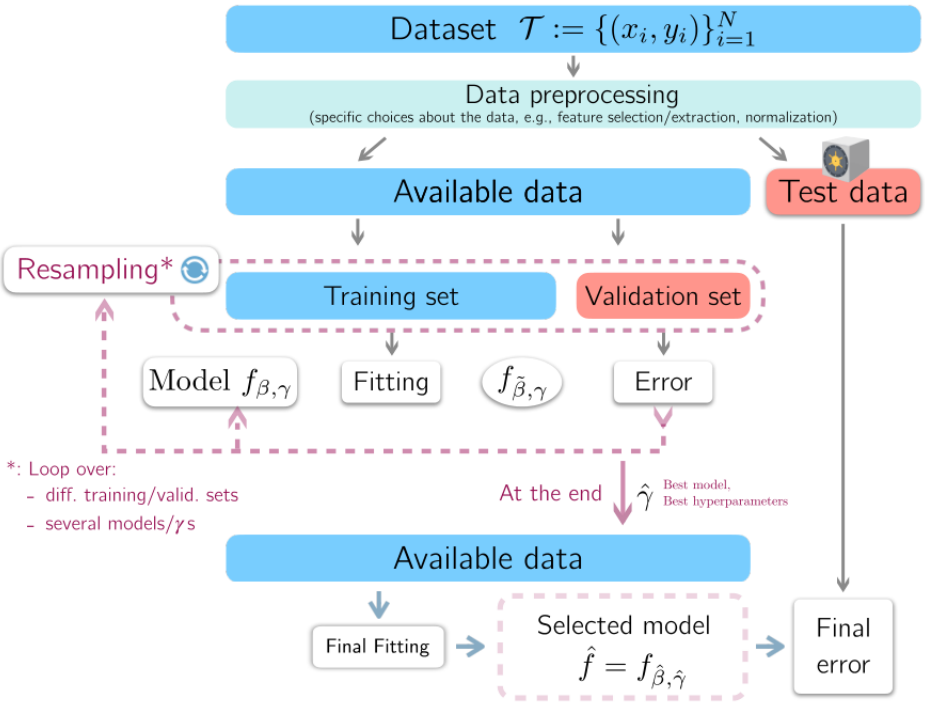
Le nombre effectif de paramètres (ou flexibilité) de k-NN est

$$\boxed{\frac{N}{k}}$$

1.4 Méthode de reéchantillonage

Si on doit trouver un hyperparamètre γ mais qu'on ne dispose pas d'un autre dataset, on peut utiliser le reéchantillonage :

- On prend des échantillons aléatoirement dans le set d'entrainement
- On réentraine le modèle sur ces échantillons



1.4.1 Set de validation

Le set de validation permet d'estimer l'erreur de test
Pour une séparation 50/50 :

- Soit un nombre N d'observations $\{(x_i, y_i)\}_{i=1}^N$, un modèle $\hat{f}$, et une permutation aléatoire $\pi : [N] \to [N]$, on forme
  - Set d'entrainement : $T_{tr} = \{(x_{\pi(i)}, y_{\pi(i)})\}_{i=1}^{N/2}$
  - Set de validation : $T_v = \{(x_{pi(i)}, y_{\pi(i)})\}_{i=N/2+1}^{N}$

- On entraine $\hat{f}$ sur T_{tr}, et on calcul l'erreur de validation :

$$\text{MSE}_v := \text{MSE}(T_v) = \frac{2}{N} \sum_{i=(N/2)+1}^{N} (y_{\pi(i)} - \hat{f}(x_{\pi(i)}))^2 \qquad \text{(régression)}$$

$$\text{Err}_v := \text{Err}(T_v) = \frac{2}{N} \sum_{i=(N/2)+1}^{N} I(y_{\pi(i)} \neq \hat{f}(x_{\pi(i)})) \qquad \text{(classification)}$$

1.4.2 Leave-One-Out Cross-Validation

Set d'entrainement de taille $N-1$, set de validation de taille 1

- On définit $\mathscr{T}_i := \{(x_j, y_i) : j \in [N], j \neq i\}$ for $1 \leq i \leq N$
- On entraine le modèle ($\hat{f}_i$) sur $\mathscr{T}_i$ et on calcul l'erreur de validation :

$$\text{MSE}_i := \text{MSE}(\{(x_i, y_i)\}) = (y_i - \hat{f}_i(x_i))^2 \qquad \text{(régression)}$$

$$\text{Err}_i := \text{Err}(\{(x_i, y_i)\}) = I(y_i \neq \hat{f}_i(x_i)) \qquad \text{(classification)}$$

L'estimation de l'erreur de test est la moyenne de toutes les erreurs de prédiction

Avantages : Bonne estimation de l'erreur de test, plus simple de détecter les paramètres optimaux (k dans k-NN)
Désavantages : Il faut entrainer N fois

1.4.3 K-Fold Cross-Validation

Pareil que Leave-One-Out, avec le set séparé en K, et chaque fois une des parties pour la validation

1.5 Plus sur les méthodes de classification

La régression linéaire ne fonctionne pas bien pour la classification

1.5.1 Régression logistique (1D)

Au lieu de prédire Y directement, on prédit la probabilitée de $Y = 1$ (ou 0)
Une ligne n'est pas bornée ($[0,1]$), on utilise donc une sigmoid :

$$h(X) = h_\beta(X) := S(\beta_0 + \beta_1 X) := \frac{\exp(\beta_0 + \beta_1 X)}{1 + \exp(\beta_0 + \beta_1 X)}$$

Pour classifier, on prend ensuite un seuil p^*, si la probabilitée donnée par le modèle est plus haute, l'élément fait parti de la classe

La classe estimée $\hat{G}(x)$ de $x \in \mathbb{R}$ est :

$$\begin{aligned}\hat{G}(x) &= \begin{cases} 1 & \text{si } P(Y=1|X=x) \geq p^*, \\ 0 & \text{sinon} \end{cases} \\ &= \begin{cases} 1 & \text{si } \log \frac{P(Y=1|X=x)}{P(Y=0|X=x)} \geq \tau^* := \log \frac{p^*}{1-p^*}, \\ 0 & \text{sinon} \end{cases} \\ &= \begin{cases} 1 & \text{si } \beta_0 + \beta_1 x \geq \tau^*, \\ 0 & \text{sinon} \end{cases}\end{aligned}$$

On définit le **logit** tel que, avec $h(X) = S(\beta_0 + \beta_1 X)$:

$$\text{logit}(h(X)) := S^{-1}(h(X)) = \log\left(\frac{h(X)}{1-h(X)}\right) = \log\left(\frac{P(Y=1|X)}{P(Y=0|X)}\right) = \beta_0 + \beta_1 X \in \mathbb{R}$$

Si $\text{logit}(h(X)) >> 0$, $Y = 1$ est certain
Si $\text{logit}(h(X)) << 0$, $Y = 0$ est certain
Si $\text{logit}(h(X)) = 0$, les deux sont équiprobables

Pour p entrées/dimensions :

$$h(X) = \frac{\exp(\beta^\top X)}{1 + \exp(\beta^\top X)}$$

avec β_0 l'intercept et $(\beta_1, \ldots, \beta_p)^\top$

1.5.2 Entrainement de la régression logistique

On utilise l'estimation du maximum de vraisemblance (MLE)

- $Y|X$ est binaire, et $p(Y=1|X=x) = h_\beta(x) \ \rightarrow \ Y|X \approx \text{Ber}(h_\beta(x))$
- Sous le modèle de régression logistique, la vraisemblance de $Y = y$ en sachant $X = x$ est :

$$P(Y=y|X=x) = \begin{cases} h_\beta(x) & \text{si } y = 1 \\ 1 - h_\beta(x) & \text{si } y = 0 \end{cases} = h_\beta(x)^y (1 - h_\beta(x))^{1-y}$$

- Soit la base de donnée $\mathscr{T} = \{(x_i, y_i)\}_{i=1}^N$, la vraisemblance de $\mathscr{T}$ est :

$$\begin{aligned} L(y_1, \ldots, y_N | \beta, x_1, \ldots, x_N) &:= p(Y_1 = y_1, \ldots, Y_N = y_N | X_1 = x_1, \ldots, X_N = x_N) \\ &= \prod_{i=1}^N p(Y_i = y_i | X_i = x_i) \\ &= \prod_{i=1}^N h_\beta(x_i)^{y_i} (1 - h_\beta(x_i))^{1-y_i} \end{aligned}$$

Maximiser L est équivalent à minimiser la log-vraisemblance négative $\mathscr{L}(\beta)$:

$$\begin{aligned}\mathscr{L}(\beta) = \mathscr{L}(\beta;\mathscr{T}) &:= -\log L(y_1,\dots,y_N|\beta,x_1,\dots,x_N) \\ &:= -\left(\sum_{i=1}^{N} y_i \log h_\beta(x_i) + (1-y_i)\log(1-h_\beta(x_i))\right) \\ &:= \sum_{i=1}^{N} \log(1+e^{\beta^\top x_i}) - y_i \beta^\top x_i\end{aligned}$$

$\mathscr{L}$ est convexe, on peut donc trouver un minimum

On obtient donc $\hat{\beta}$ avec

$$\hat{\beta} := \arg\min_{\beta} \mathscr{L}(\beta) = \sum_{i=1}^{N} \log(1+e^{\beta^\top x_i}) - y_i \beta^\top x_i$$

On peut montrer

$$\nabla_\beta \mathscr{L}(\beta) = \sum_{i=1}^{N} (S(\beta^\top x_i) - y_i) x_i \Rightarrow \text{gradient simple}$$