

Statistiques et science des données (LEPL1109)

Réalisé par
Quentin Aubecq
avec l'aide de

—
relu par

—
2026

SYNTEX

Cette synthèse est une **synthèse collaborative**, écrite en L^AT_EX.
Elle est améliorée régulièrement, grâce à la participation de quelques étudiants.

La version que vous avez sous les yeux n'est sans doute pas la plus récente !

Alors...

...si vous désirez rester au courant des améliorations et corrections...

...si vous trouvez une erreur ou une imprécision...

...si vous souhaitez apporter votre aide à la réalisation...

...ou si vous voulez accéder à des synthèses d'autres cours...

...**rejoignez-nous** sur le serveur SYNTEX !



<https://discord.gg/BdFgQbCTag>

Remarque

Ce document est un support complémentaire au cours.
Nous déclinons toute responsabilité pour les éventuelles erreurs, omissions ou interprétations susceptibles de vous induire en erreur.
Les images, liens et autres contenus appartiennent exclusivement à leurs détenteurs respectifs.

Table des matières

1	Rappels	3
1.1	Variable aléatoire	3
1.2	Distribution de probabilités	3
1.3	Densité de probabilités	3
1.4	Espérance	4
1.5	Variance	4
1.6	Loi des grands nombres (LLN)	4
1.7	Quantiles	5
1.8	Fonction d'une variable aléatoire	5
2	Statistiques descriptives et outil de visualisation	6
2.1	Moyenne, Médiane et Quantiles	6
2.2	Range, IQR, Outliers	6
2.3	Analyse graphique	7
2.3.1	Boxplot	7
2.3.2	Histogram	7
3	Indépendance et indépendance linéaire	8
3.1	Indépendance	8
3.2	Covariance	8
3.3	Corrélation	9

1 Rappels

1.1 Variable aléatoire

Une **variable aléatoire** est une fonction mesurable d'un espace Ω à un ensemble de nombres réels :

$$X : \Omega \rightarrow \mathbb{R}$$

On note $X(\omega) = x$

1.2 Distribution de probabilités

La **pmf** (probability mass function) $p(x)$ d'une variable aléatoire discrète, est une fonction qui associe une probabilité $P(X = x)$ à chaque valeur x de X

$$p(x) = P(X = x)$$

Si le domaine de X est $R = \{x_1, x_2, \dots\}$ alors $p(x) > 0 \forall x \in R$ et $p(x) = 0 \forall x \notin R$

$$\sum_i p(x_i) = 1$$

1.3 Densité de probabilités

La **pdf** (probability density function) $f(x) \geq 0$ d'une variable aléatoire continue X est une fonction tel que $\forall I \subset \mathbb{R}$

$$P(X \in I) = \int_I f(x) dx$$

La **cdf** (cumulative distribution function) $F(x)$ indique la probabilité que $X \leq x$

$$F(x) = P(X \leq x)$$

$$F(x) = \sum_{i: x_i \leq x} p(x_i)$$

$$F(x) = \int_{-\infty}^x f(u) du$$

$$f(x) = \frac{d}{dx} F(x)$$

1.4 Espérance

L'espérance d'une variable aléatoire X est notée $\mathbb{E}(X) = \mu_X$

$$\mu_X = \sum_{x \in \text{dom}(X)} xp(x)$$
$$\mu_X = \int_{-\infty}^{\infty} xf(x) dx$$

Propriétés :

- $\mathbb{E}(X + Y) = \mathbb{E}(X) + \mathbb{E}(Y)$
- $\mathbb{E}(aX + b) = a\mathbb{E}(X) + b$
- $\mathbb{E}(h(X)) = \sum_{x \in \text{dom}(X)} h(x)p(x)$
- $\mathbb{E}(h(X)) = \int_{-\infty}^{\infty} h(x)f(x) dx$

1.5 Variance

La variance d'une variable aléatoire X est

$$\text{Var}(X) = \mathbb{V}(X) = \sigma_X^2$$
$$\sigma_X^2 = \mathbb{E}((X - \mu_X)^2)$$

Avec σ_X la déviation standard

Propriétés :

- $\mathbb{V}(X) = \mathbb{E}(X^2) - (\mathbb{E}(X))^2$
- $\mathbb{V}(a) = 0$
- $\mathbb{V}(a + bX) = b^2\mathbb{V}(X)$
- $\mathbb{V}(X + Y) \neq \mathbb{V}(X) + \mathbb{V}(Y)$ Sauf si X et Y indépendants

Si on observe n événements $(x_k)_{k=1, \dots, n}$, la variance empirique est estimée avec

$$\sigma_X^2 \approx \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1} = s^2$$

1.6 Loi des grands nombres (LLN)

Soit $X_{i=1, \dots, n}$ une séquence d'événements aléatoires indépendants avec la même espérance $\mu_X = \mathbb{E}(X_i)$ et de variance σ_X^2 . Lorsque $n \rightarrow \infty$, la moyenne $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ converge vers μ_X

$$\forall \varepsilon > 0 \quad \lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu_X| \geq \varepsilon) = 0$$

On note $\bar{X}_n \xrightarrow{p} \mu_X$

1.7 Quantiles

Soit p une probabilité et X une variable aléatoire. Le nombre q_p satisfaisant la relation

$$P(X \leq q_p) = p$$

est le quantile d'ordre p pour X . Si X est continu et si son cdf $F(x)$ est inversible, alors $q_p = F^{-1}(p)$

1.8 Fonction d'une variable aléatoire

Soit X une variable aléatoire continue de densité (pdf) $f_X(x)$. La densité de $Y = a + bX$ est donnée par

$$f_Y(y) = \frac{1}{|b|} f_X\left(\frac{y-a}{b}\right)$$

2 Statistiques descriptives et outil de visualisation

- **Population** : Collection de tout les résultats possible qui nous intéressent
- **Échantillon** : Un subset de population
- **Statistiques** descriptives : Branche des statistiques qui s'occupe de l'organisation et de l'affichage des données

2.1 Moyenne, Médiane et Quantiles

- **Moyenne** :

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

- **Médiane** : La valeur $q_{0.5}$ telle que la moitié des résultats sont en dessous, et l'autre moitié au dessus
- **Quantile** : On trie les résultats par ordre croissant $x_{(1)} \leq \dots \leq x_{(n)}$, on a

$$q_p = x_{(1+(n-1)p)}$$


2.2 Range, IQR, Outliers

- **Range** : $x_{max} - x_{min}$
- **Inter-Quartile Range (IQR)** : La différence entre des quartiles symétriques, par exemple $IQR = q_{0.75} - q_{0.25}$
- **Outliers** : Observations qui sont trop loin du reste des données, qui pourraient être due à des erreurs


Une observation est considérée comme suspecte si elle est plus bas que $q_{0.25} - 1.5 \times IQR$ ou plus haut que $q_{0.75} + 1.5 \times IQR$

2.3 Analyse graphique

2.3.1 Boxplot



2.3.2 Histogram



3 Indépendance et indépendance linéaire

3.1 Indépendance

Deux variables aléatoires X et Y sont **indépendantes** ($X \perp\!\!\!\perp Y$) si $\forall A, B \in \mathbb{R}$:

$$P(X \in A, Y \in B) = P(X \in A)P(Y \in B)$$

Conséquences :


- $p(x, y) = p_X(x)p_Y(y)$ quand X et Y sont discrets
- $f(x, y) = f_X(x)f_Y(y)$ quand X et Y sont continus

3.2 Covariance

$$\begin{aligned}\sigma_{XY} &= \text{Cov}(X, Y) = \mathbb{E}[(X - \mu_X)(Y - \mu_Y)] \\ &= \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y) \\ &= \mu_{XY} - \mu_X\mu_Y\end{aligned}$$

Si on observe n événements $(x_k)_{k=1, \dots, n}$ et $(y_k)_{k=1, \dots, n}$, la covariance empirique est estimée avec

$$\sigma_{XY} \approx s_{XY} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$



Propriétés :

- $\mathbb{C}(X, Y) = \mathbb{C}(Y, X)$
- $\mathbb{C}(X, X) = \mathbb{V}(X)$ et $\mathbb{C}(a, X) = 0 \quad \forall a \in \mathbb{R}$
- Si $X \perp\!\!\!\perp Y$ alors $\mathbb{C}(X, Y) = 0$
- $\mathbb{C}(aX + bY, Z) = a\mathbb{C}(X, Z) + b\mathbb{C}(Y, Z)$

- $\boxed{\mathbb{V}(aX + bY) = a^2\mathbb{V}(X) + b^2\mathbb{V}(Y) + 2ab\mathbb{C}(X, Y)}$

(Attention si $\mathbb{C}(X, Y) = 0 \nRightarrow X \perp\!\!\!\perp Y$)

La covariance est une mesure de la dépendance linéaire entre deux variables aléatoires.

La taille d'une covariance dépend de l'échelle des variables : $\mathbb{C}(aX, Y) = a\mathbb{C}(X, Y)$

3.3 Corrélation

La **corrélation** entre X et Y est défini comme

$$\rho_{XY} = \frac{\mathbb{C}(X, Y)}{\sqrt{\mathbb{V}(X)\mathbb{V}(Y)}} = \frac{\sigma_{XY}}{\sigma_X \sigma_Y}$$

L'inégalité de Cauchy Schwarz donne

$|\sigma_{XY}| \leq \sigma_X \sigma_Y$ avec égalité si et seulement si $Y = aX + b$

On en déduit les propriétés suivantes :

- ρ_{XY} est invariant à l'échelle
- $-1 \leq \rho_{XY} \leq 1$
- Si $\rho_{XY} = 1$ alors $Y = a + bX$ avec $b \in \mathbb{R}^+$ (Y proportionnel à X)
- Si $\rho_{XY} = -1$ alors $Y = a + bX$ avec $b \in \mathbb{R}^-$ (Y inversement proportionnel à X)

La corrélation est une mesure de la dépendance linéaire entre deux variables aléatoires.

Elle n'a pas d'unité et est dans $[-1, 1]$

On peut estimer la corrélation de manière empirique :

$$\rho_{XY} \approx r_{XY} = \frac{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2}}$$